Pipelines de Dados com Apache HOP

Eduardo Manuel de Freitas Jorge

Descrição

Esta atividade etapa simula um exemplo de ETL (Extração Transformação e Carga) através da ferramenta Apache Hop.

De forma prática será apresentado como orquestrar cargas de base de dados operacionais através de pipelines e fluxos de dados visuais bem documentados.

Para exemplificar a aplicação da ferramenta Apache Hop será desenvolvido um case demonstrado a extração do Currículo Lattes.

Resultado da Atividade: Gráfico de Artigos Indexados

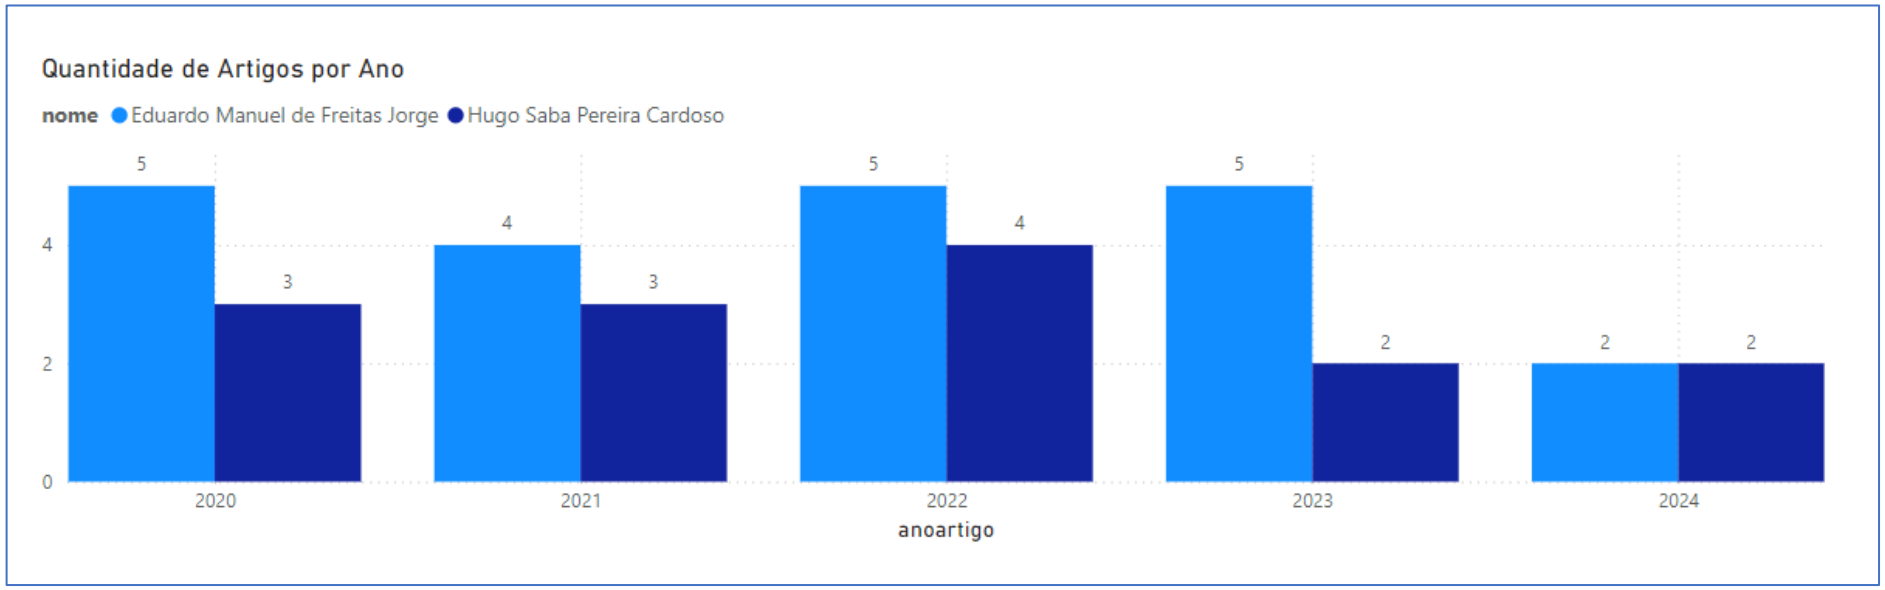

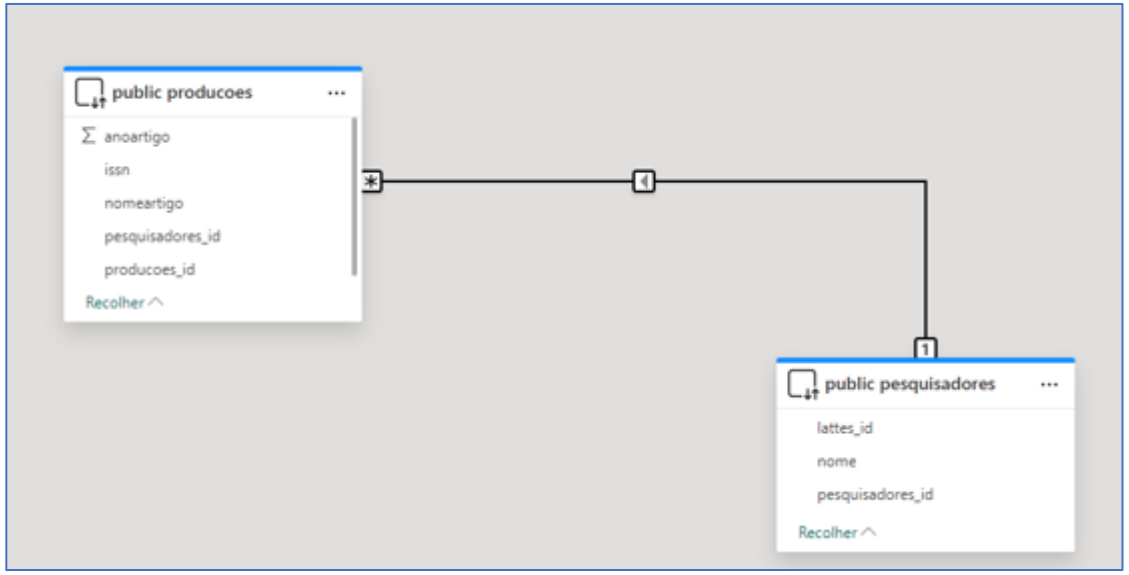

Etapa I:Criação do Banco de Dados PostgreSQL no Docker

Instale o Docker

Criação da Imagem Docker

- Crie o arquivo dockerfile
- .

```
# Use a imagem oficial do pgvector
FROM pgvector/pgvector:pg17

# Variáveis de ambiente para o PostgreSQL
ENV POSTGRES_USER=postgres
ENV POSTGRES_PASSWORD=qualquer_uma
ENV POSTGRES_DB=BD_PESQUISADOR
ENV POSTGRES_HOST_AUTH_METHOD=trust

# Copie o arquivo script de inicialização para o container
COPY init_db.sh /docker-entrypoint-initdb.d/init_db.sh

# Concede permissão de execução ao script de
inicialização
RUN chmod +x /docker-entrypoint-initdb.d/init_db.sh

# Expõe a porta 5437
EXPOSE 5437
```

Etapa I:Criação do Banco de Dados PostgreSQL no Docker

- Crie o arquivo init_db.sh

```
#!/bin/bash

# Cria o banco de dados
psql -U postgres -d postgres -c "CREATE DATABASE
BD_PESQUISADOR
    WITH
    OWNER = postgres
    ENCODING = 'UTF8'
    LC_COLLATE = 'Portuguese_Brazil.1252'
    LC_CTYPE = 'Portuguese_Brazil.1252'
    TABLESPACE = pg_default
    CONNECTION LIMIT = -1
    IS_TEMPLATE = False;"
```

Etapa I:Criação do Banco de Dados PostgreSQL no Docker

- docker build -t docker_simcc .
- docker run -d --name docker_simcc -p 5437:5432 docker_simcc

Instale HeidiSQL

Conecte usando o HeidiSQL

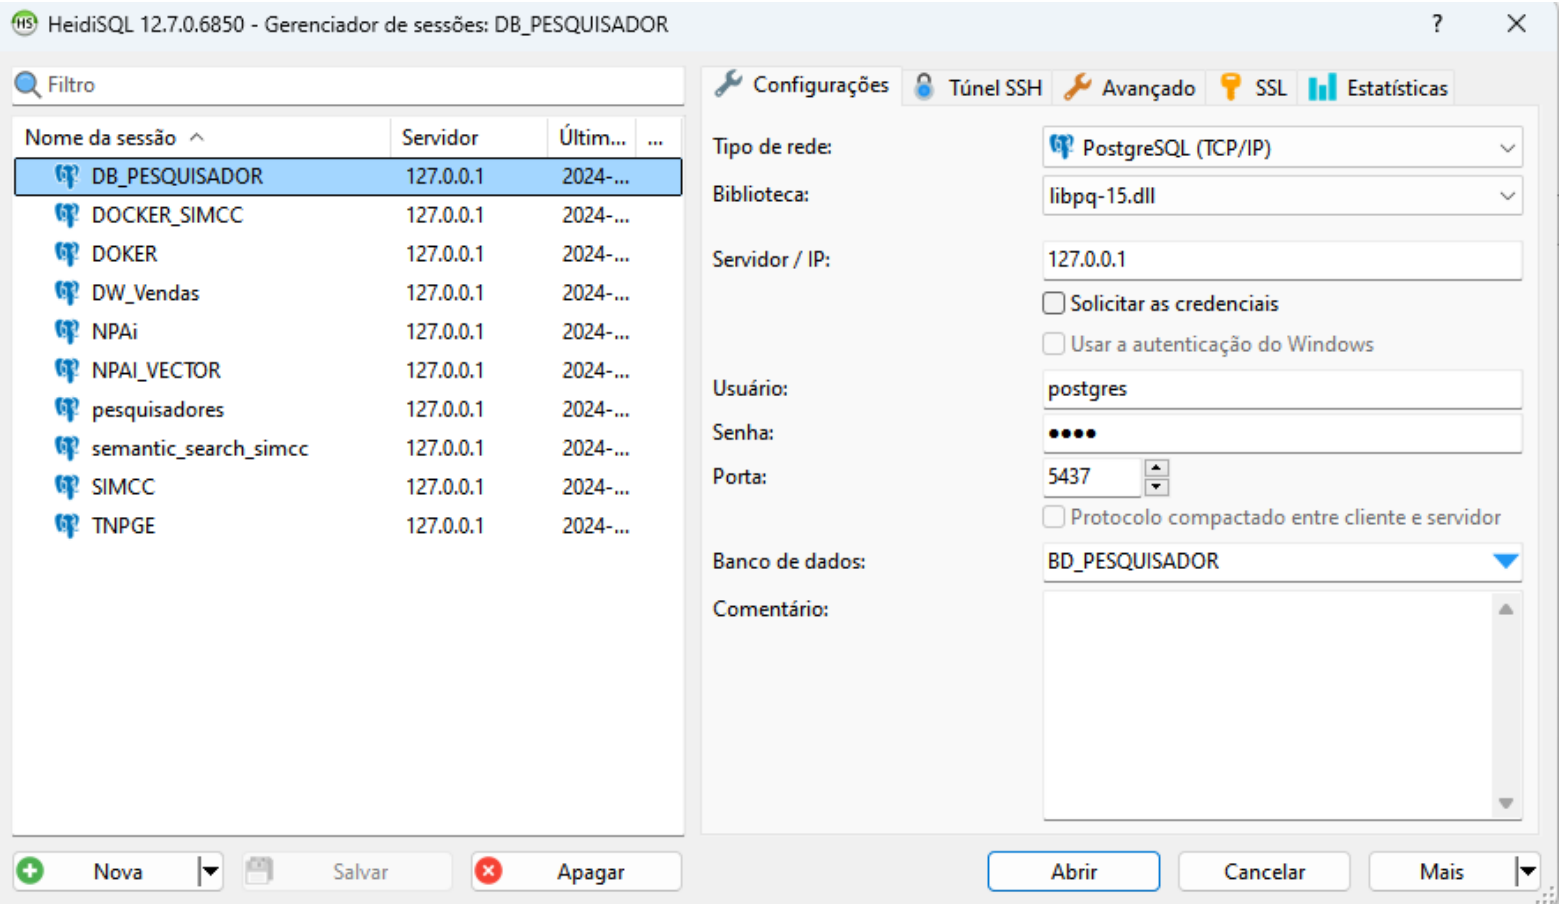

Conecte no banco de dados pesquisadores e crie as tabelas pesquisadores e produções

```sql
CREATE EXTENSION "uuid-ossp";

CREATE TABLE IF NOT EXISTS pesquisadores (
  pesquisadores_id UUID NOT NULL DEFAULT uuid_generate_v4(),
  lattes_id VARCHAR(16) NOT NULL,
  nome VARCHAR(200) NOT NULL,
 PRIMARY KEY (pesquisadores_id ));


CREATE TABLE IF NOT EXISTS producoes (
  producoes_id UUID NOT NULL DEFAULT uuid_generate_v4(),
  pesquisadores_id UUID NOT NULL,
  issn VARCHAR(16) NOT NULL,
  nomeArtigo TEXT NOT NULL,
  anoArtigo INTEGER NOT NULL,
  PRIMARY KEY (producoes_id),
  CONSTRAINT fkey FOREIGN KEY ( pesquisadores_id)
  REFERENCES pesquisadores (pesquisadores_id) ON UPDATE NO ACTION ON DELETE NO ACTION);
```

Exemplo I

Obtendo o Nome do Pesquisador do Lattes

Novo Projeto (Lattes)

C: > apache-hop-client-2.1.0 > hop > config > projects > Teste > metadata > dataset > xml > 88185575568.xml


```xml
<root type="object">
  <horaAtualizacao type="string">211132</horaAtualizacao>
  <sistemaOrigemXml type="string">LATTES_OFFLINE</sistemaOrigemXml>
  <dataAtualizacao type="string">17012022</dataAtualizacao>
  <numeroIdentificador type="string">6716225567627323</numeroIdentificador>
  <dadosGerais type="object">
    <tipoLista type="string">dadosGerais</tipoLista>
    <paisDeNacionalidade type="string">Brasil</paisDeNacionalidade>
    <paisDeNascimento type="string">Portugal</paisDeNascimento>
    <siglaPaisNacionalidade type="string">BRA</siglaPaisNacionalidade>
    <permissaoDeDivulgacao type="string">NAO</permissaoDeDivulgacao>
    <nacionalidade type="string">B</nacionalidade>
    <nomeCompleto type="string">Eduardo Manuel de Freitas Jorge</nomeCompleto>
    <nomeEmCitacoesBibliograficas type="string">JORGE, E. M. F.;JORGE, EDUARDO;JO
    <cidadeNascimento type="string">Lisboa</cidadeNascimento>
    <orcidId type="string">https://orcid.org/0000-0002-8597-5805</orcidId>
    <resumoCv type="object">
```

Etapa II: Instale o ApacheHop

- https://hop.apache.org/

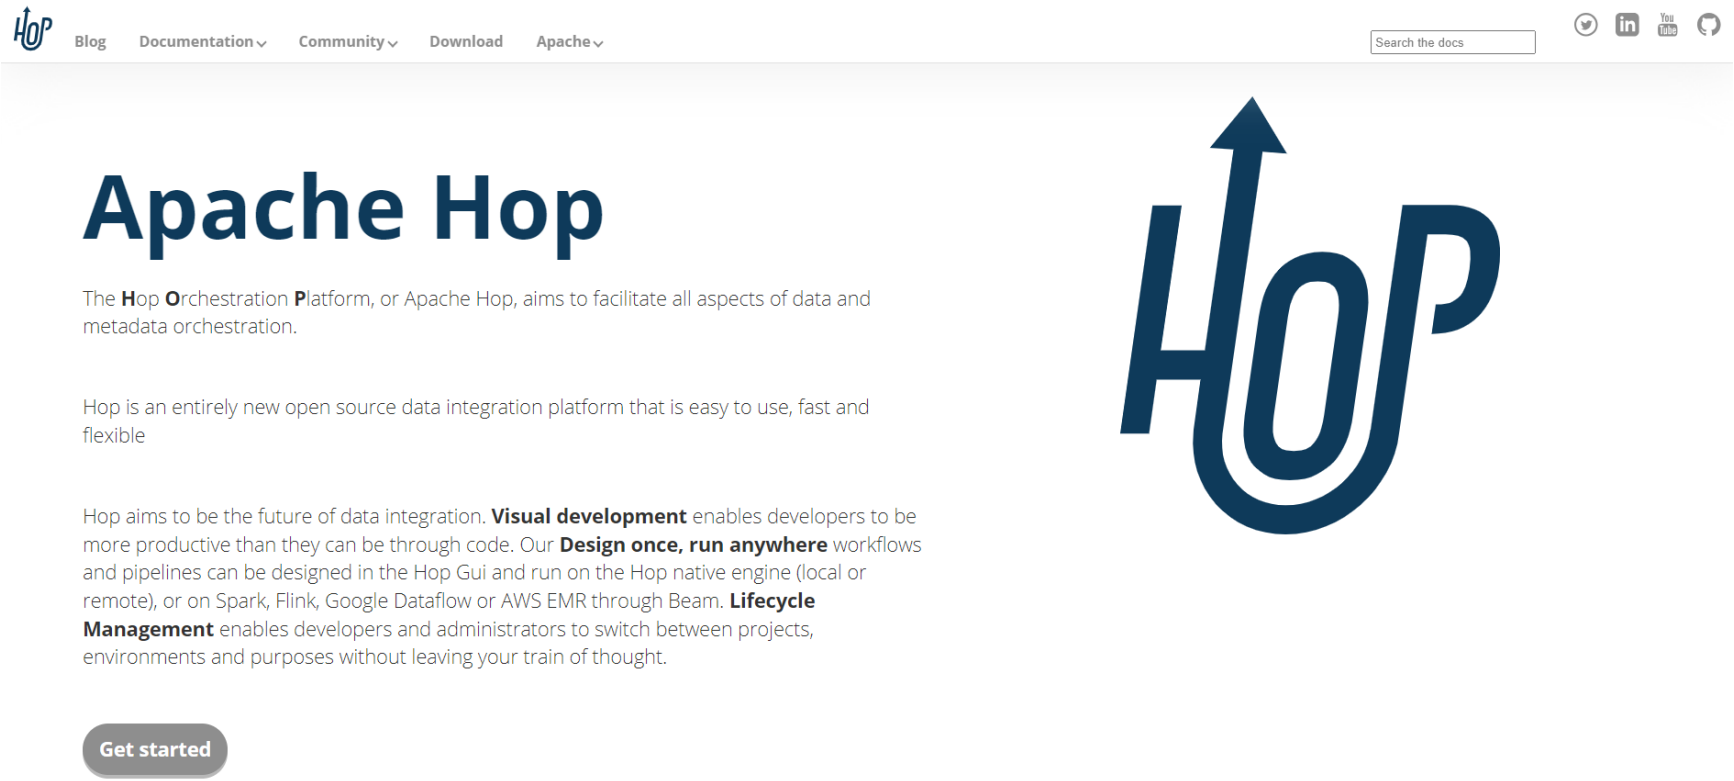

Novo Projeto (Lattes) no Apache Hop
Para executar o hop -> hop-gui.bat

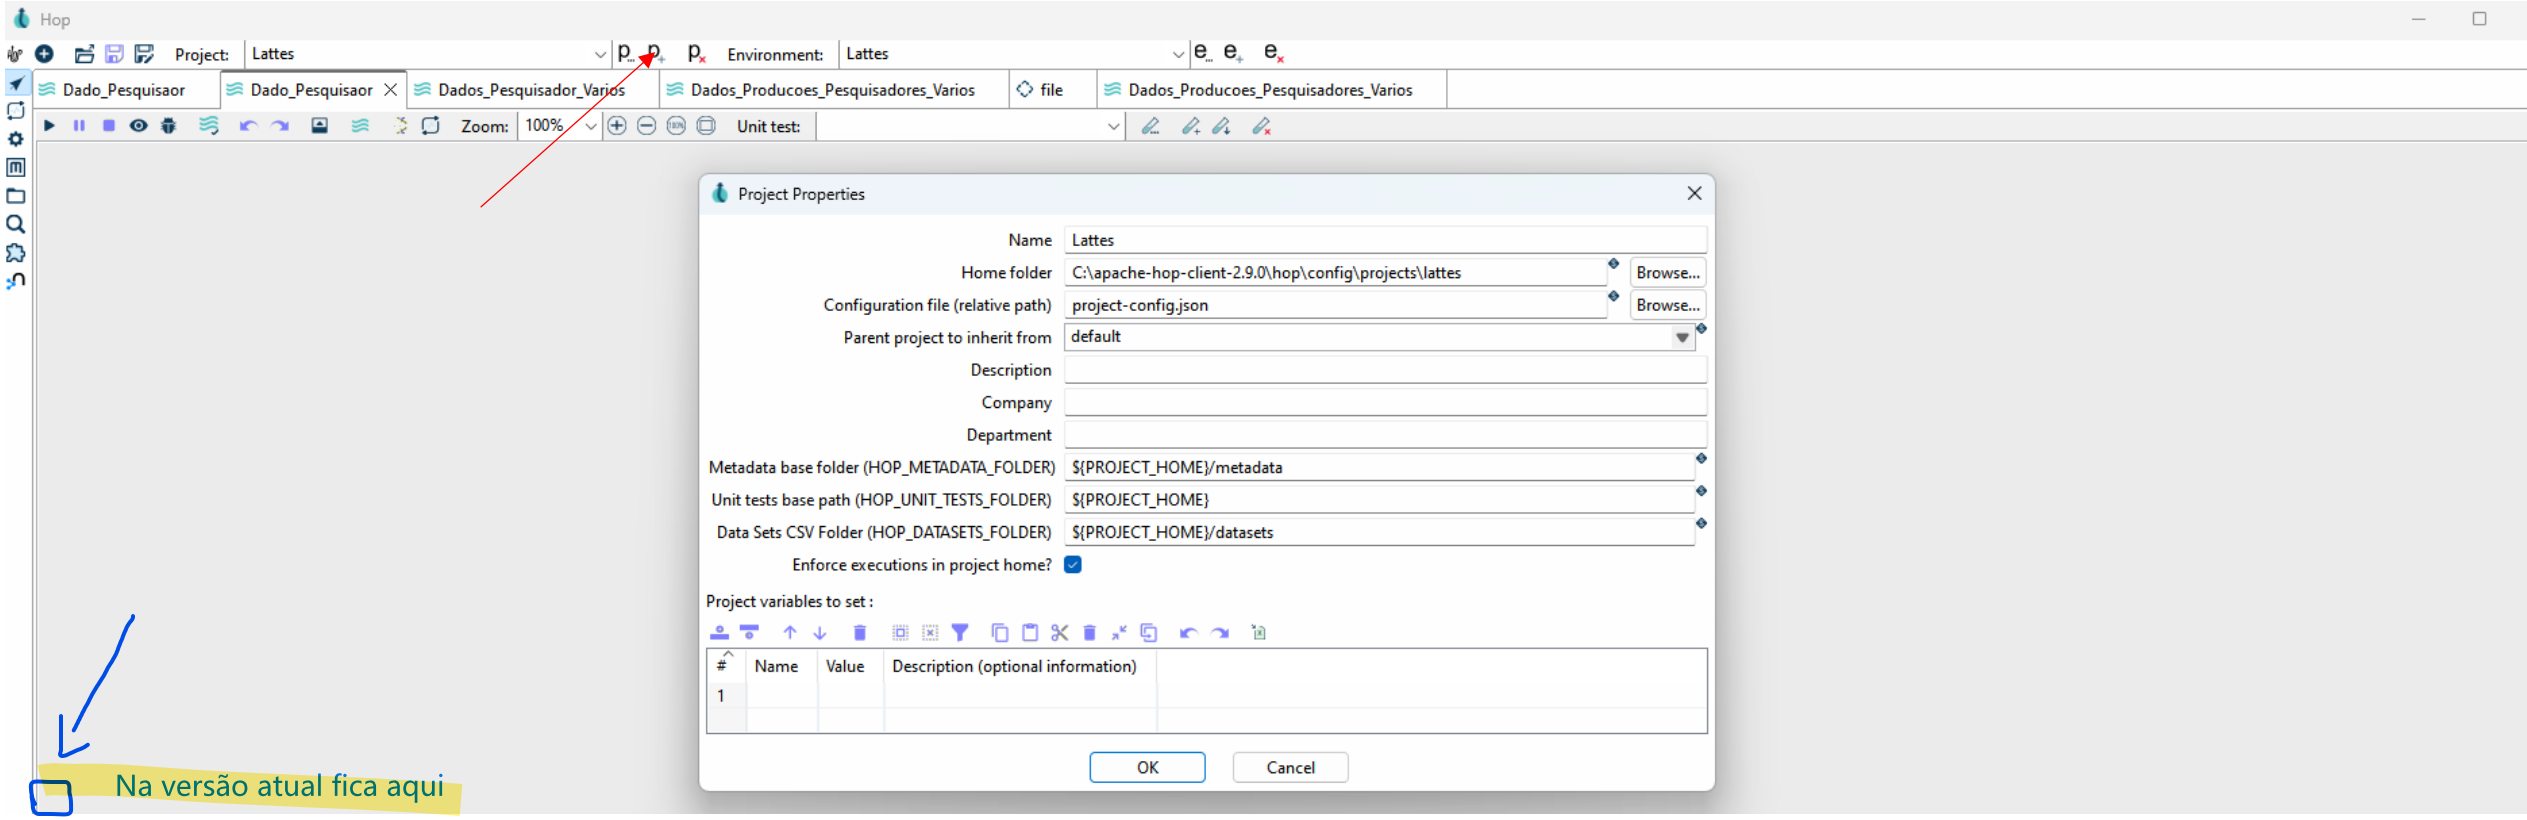

Configure e Teste a Conexão com o Banco de Dados

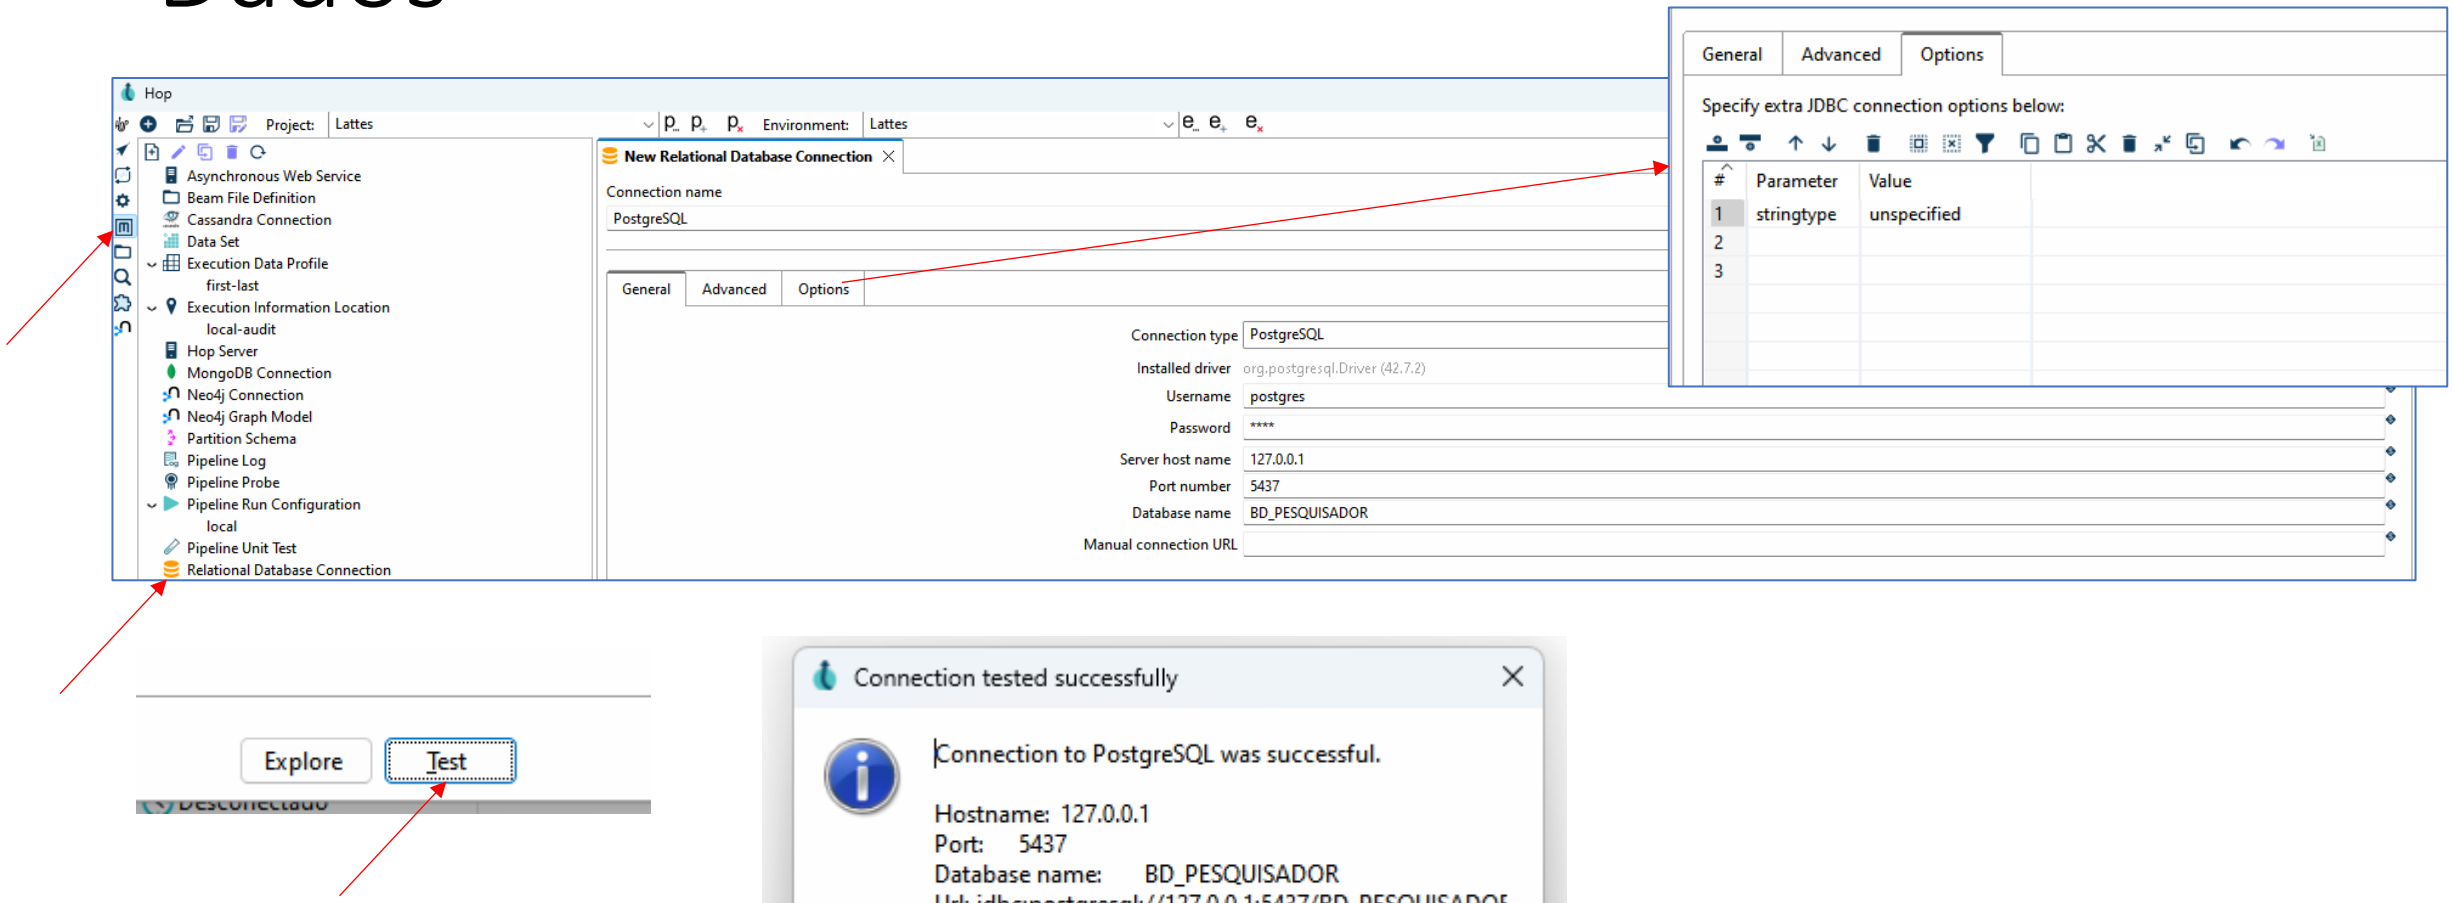

Pipeline (Lattes)

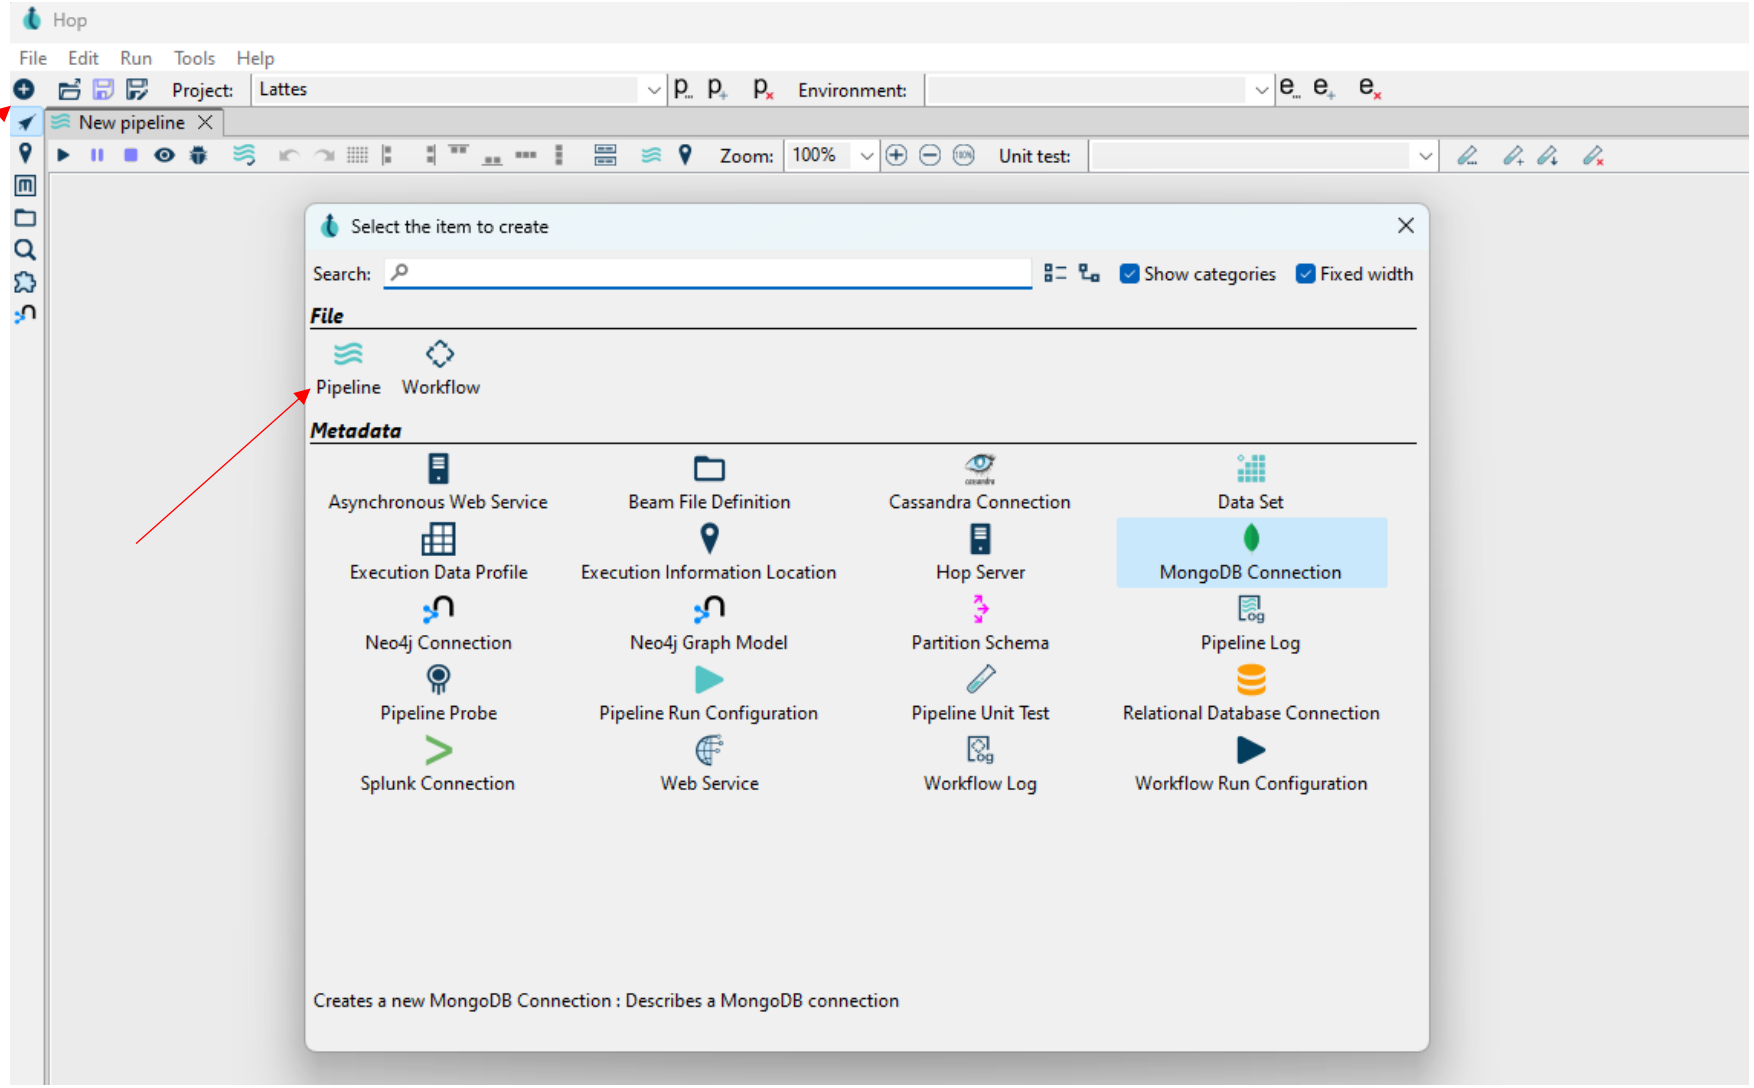

Novo Pipeline (Lattes)

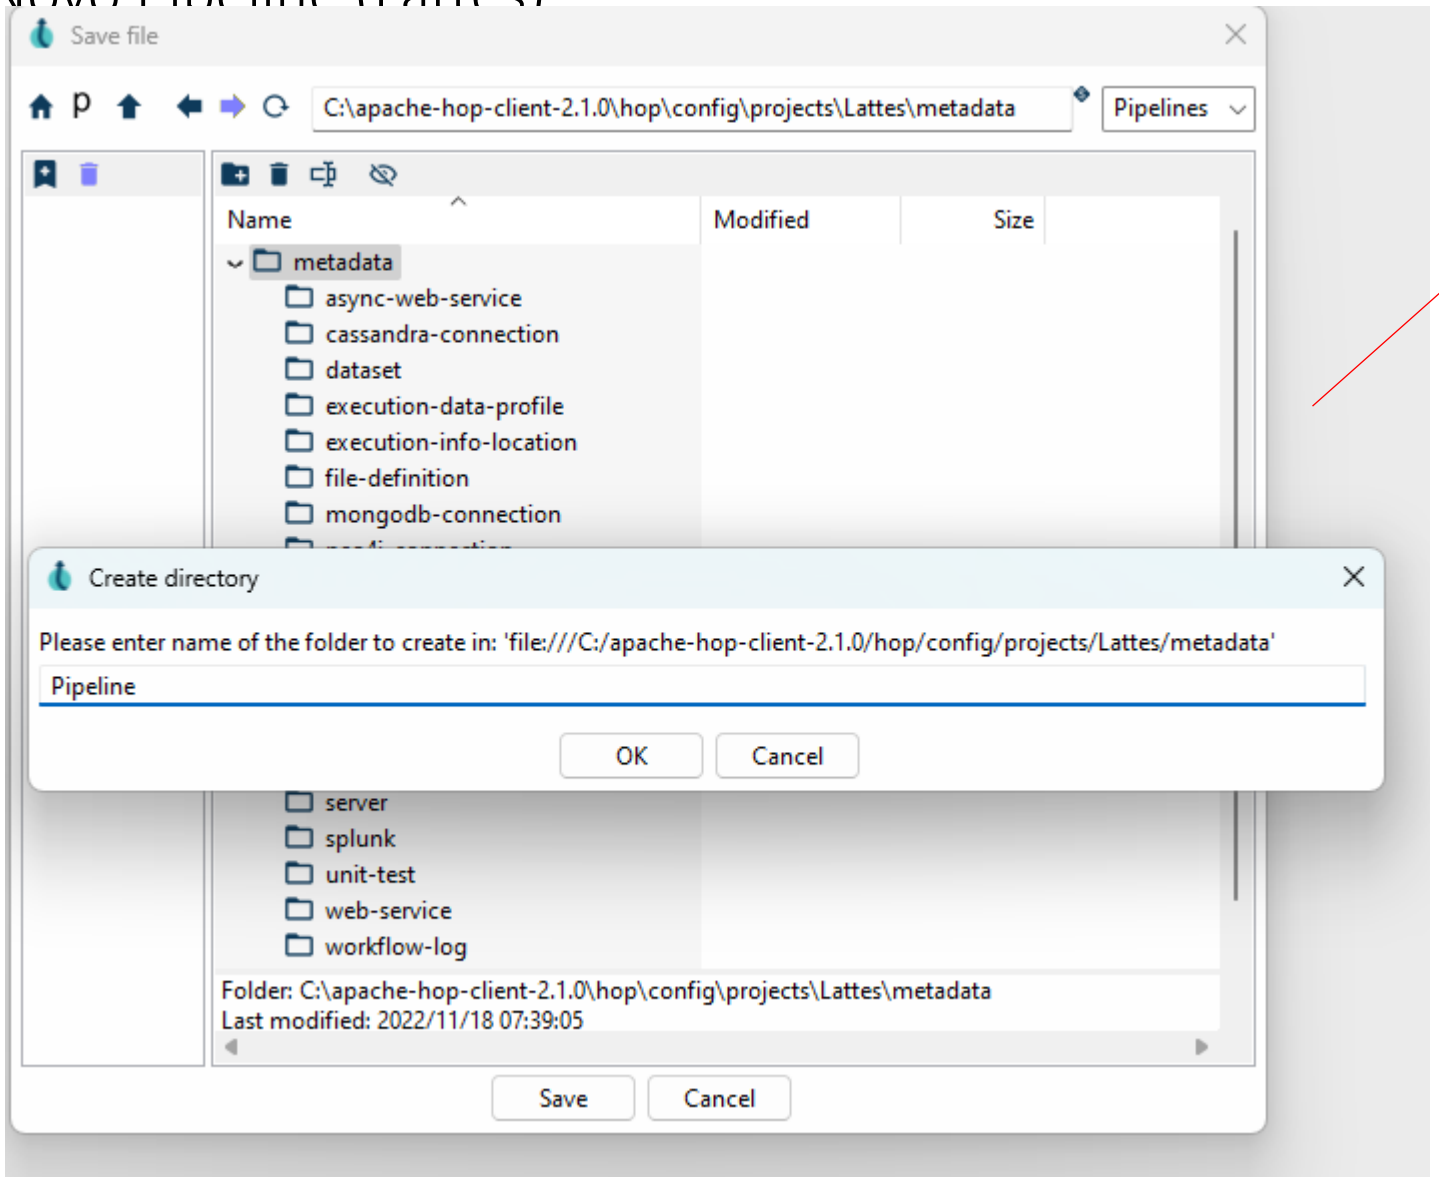

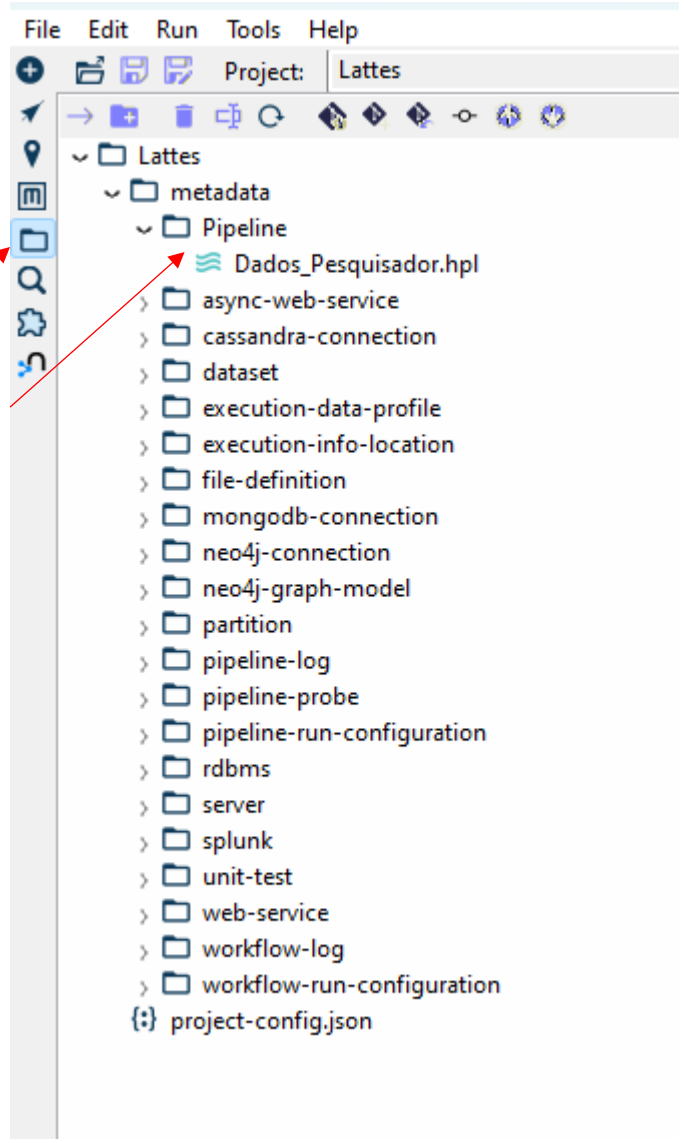

Pipeline Dados do Pesquisador (Lattes)

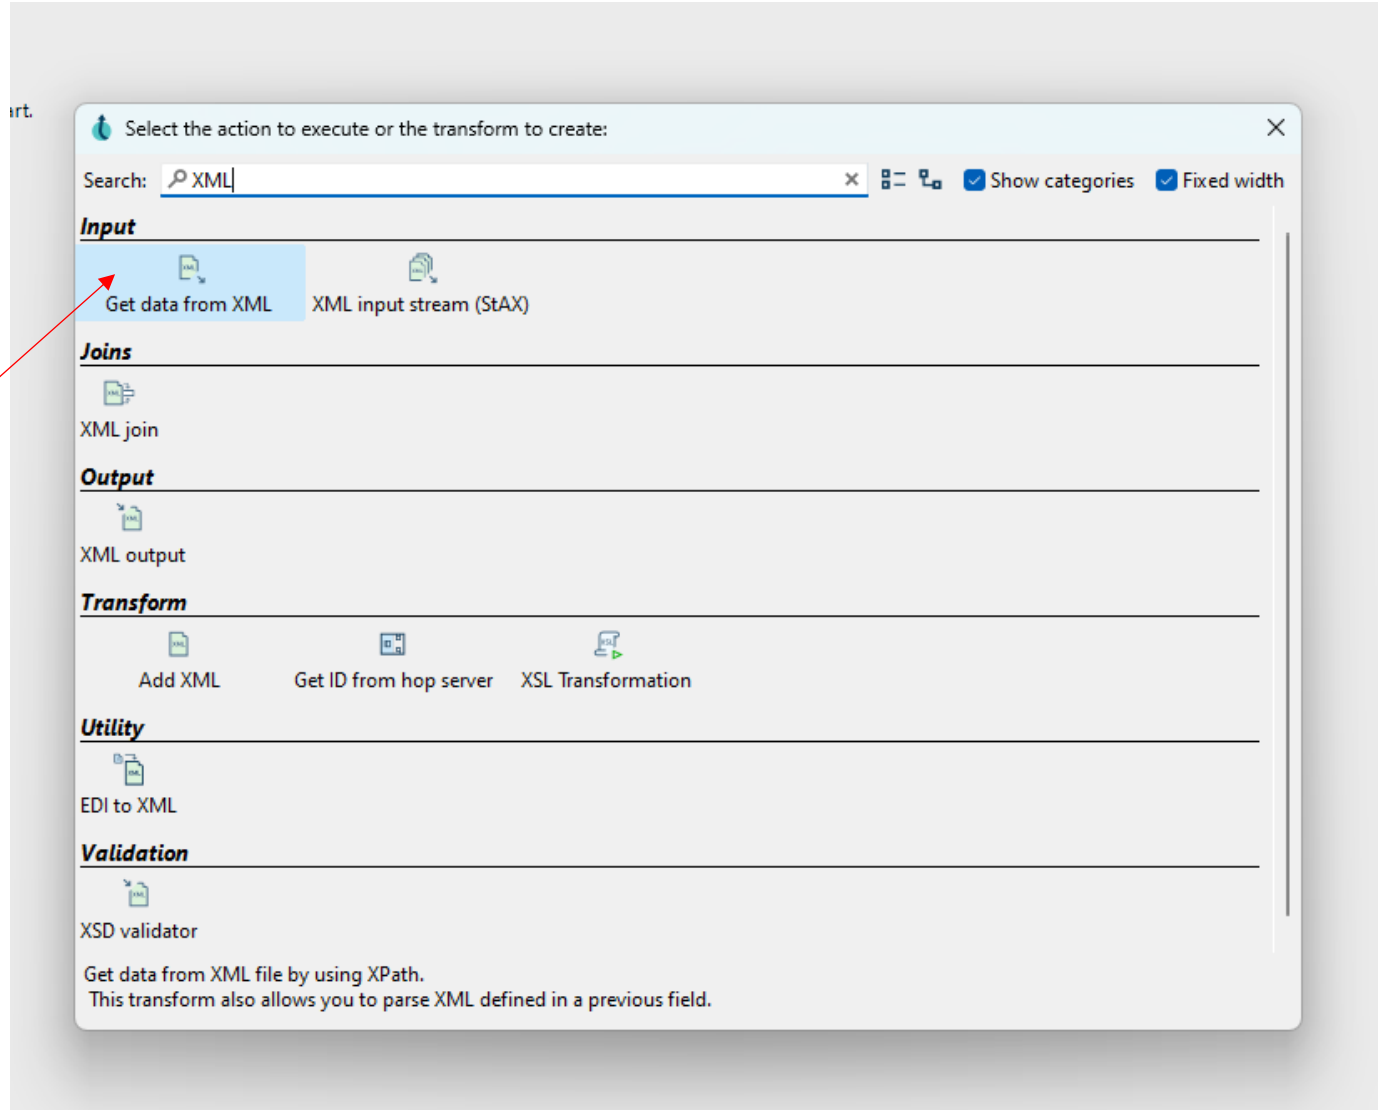

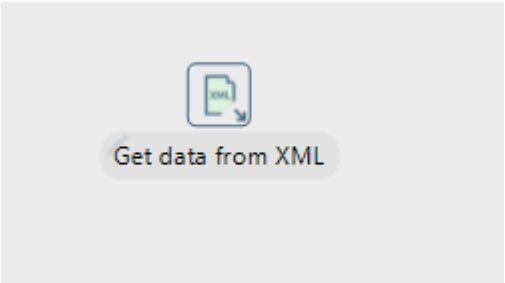

Pipeline Dados do Pesquisador (Lattes) - Arquivo XML para Obtenção de Dados

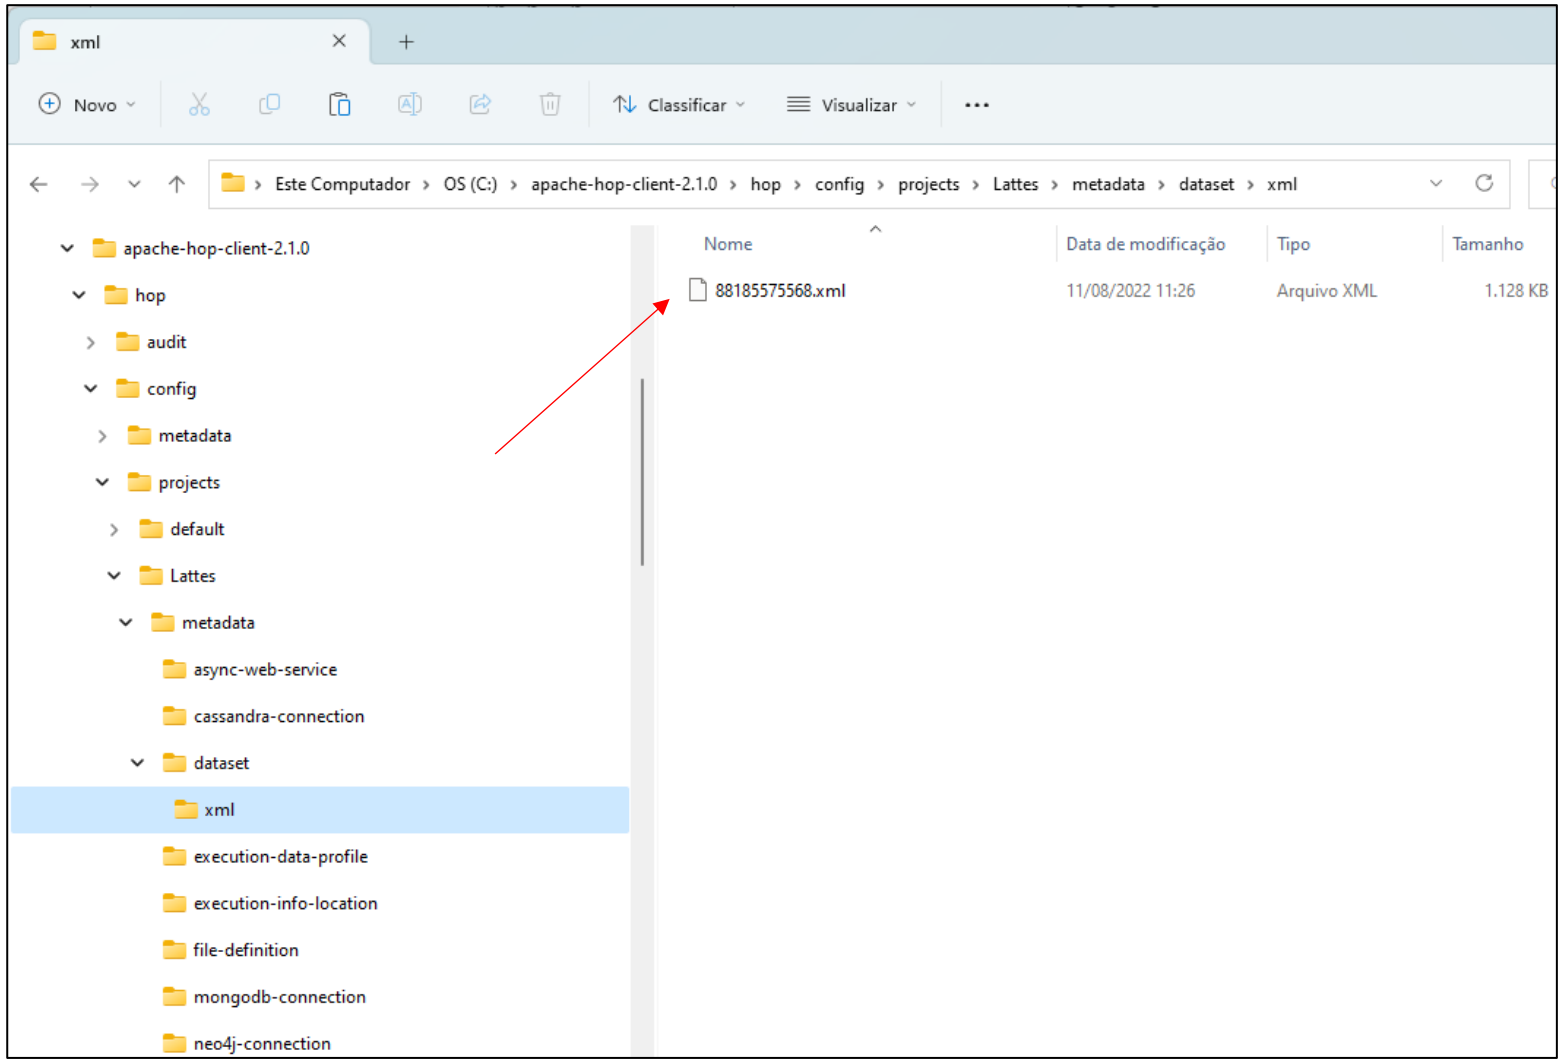

Pipeline Dados do Pesquisador (Lattes)

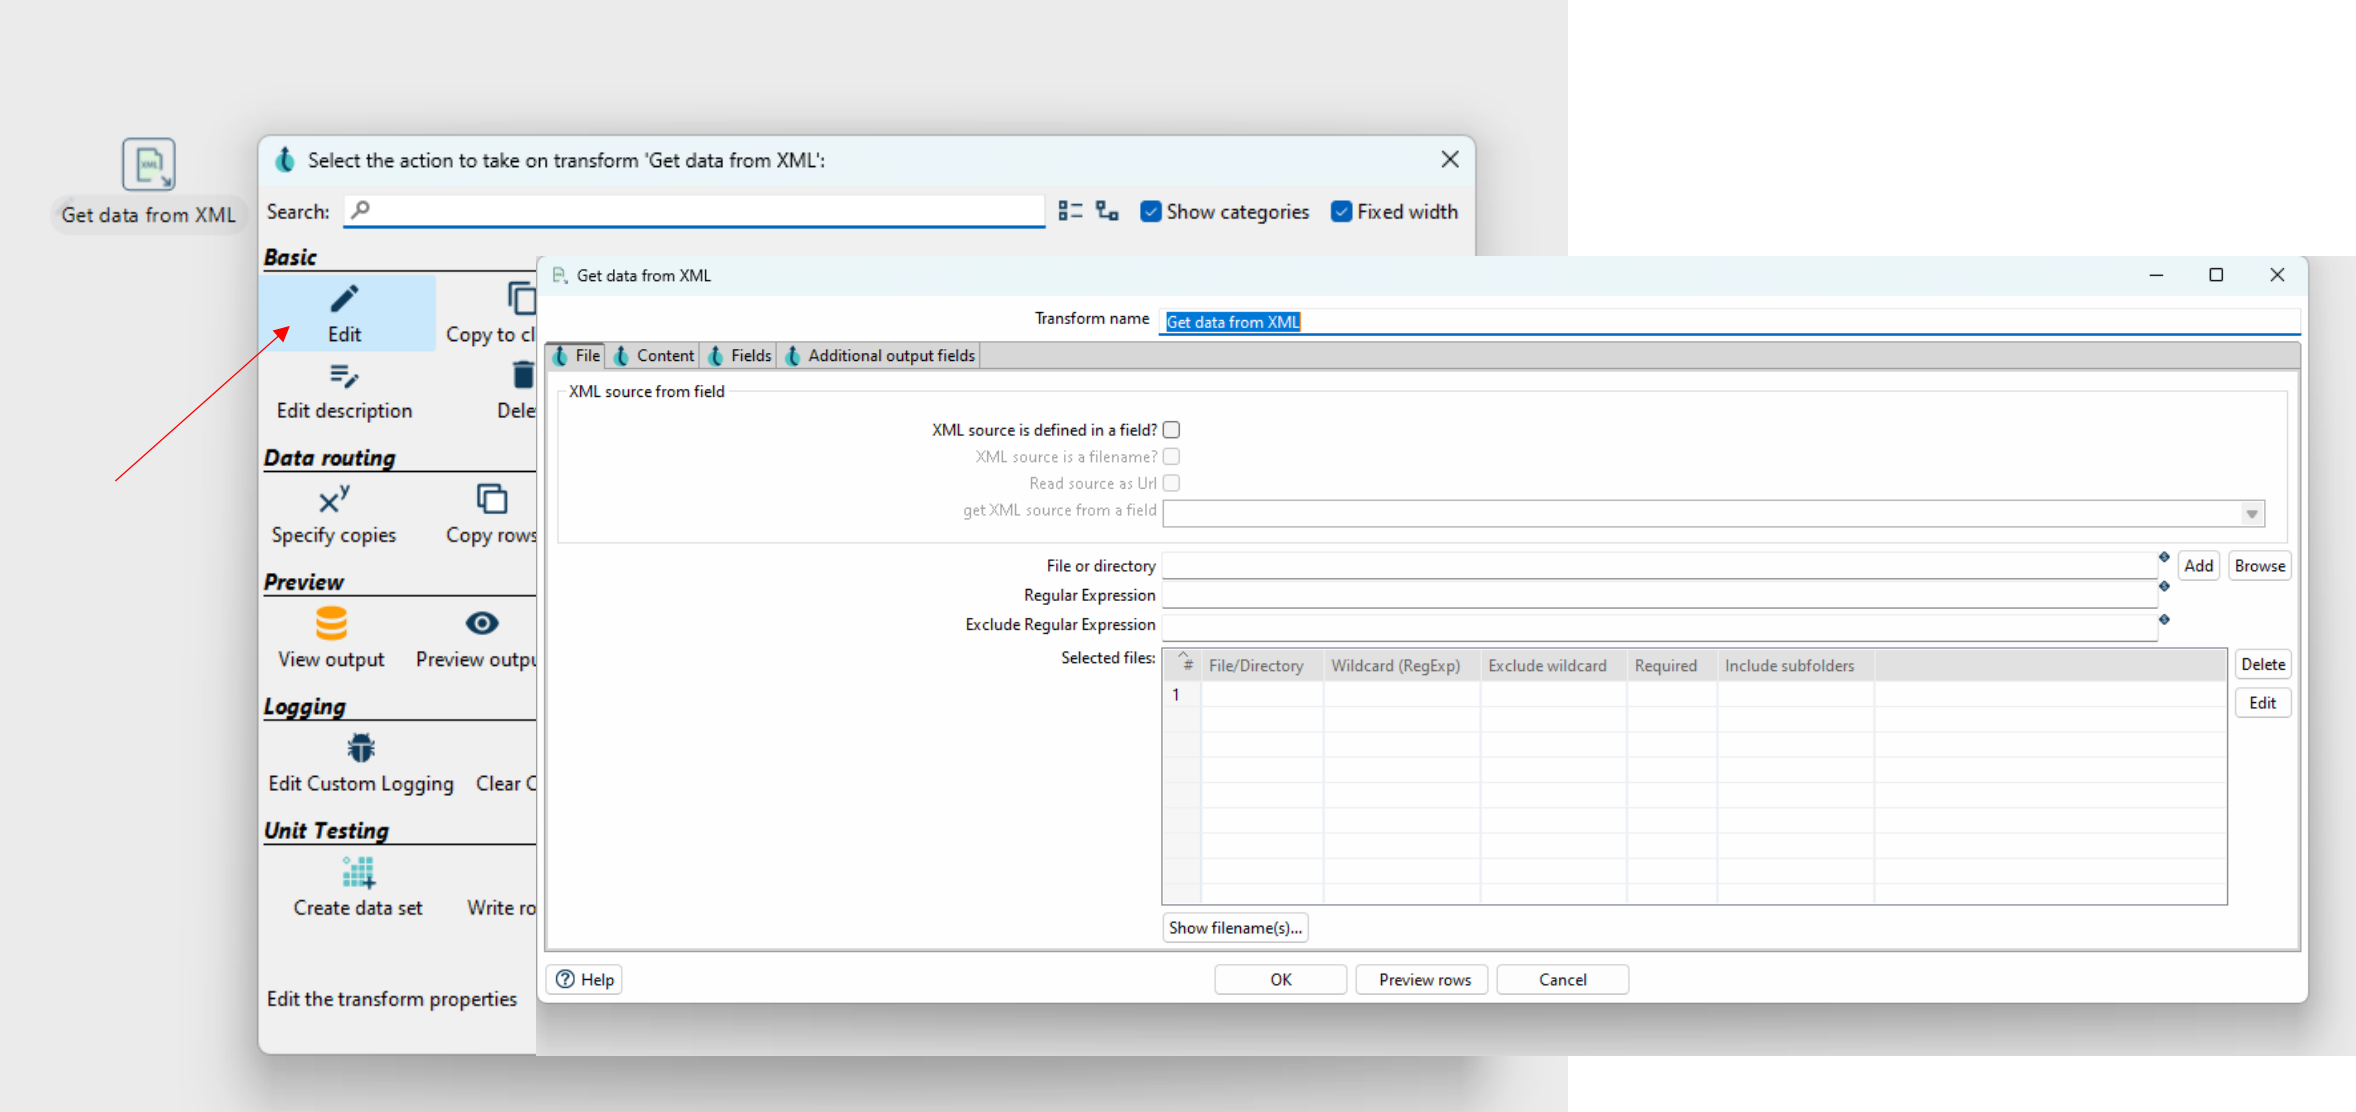

Pipeline Dados do Pesquisador (Lattes) - Arquivo XML para Obtenção de Dados

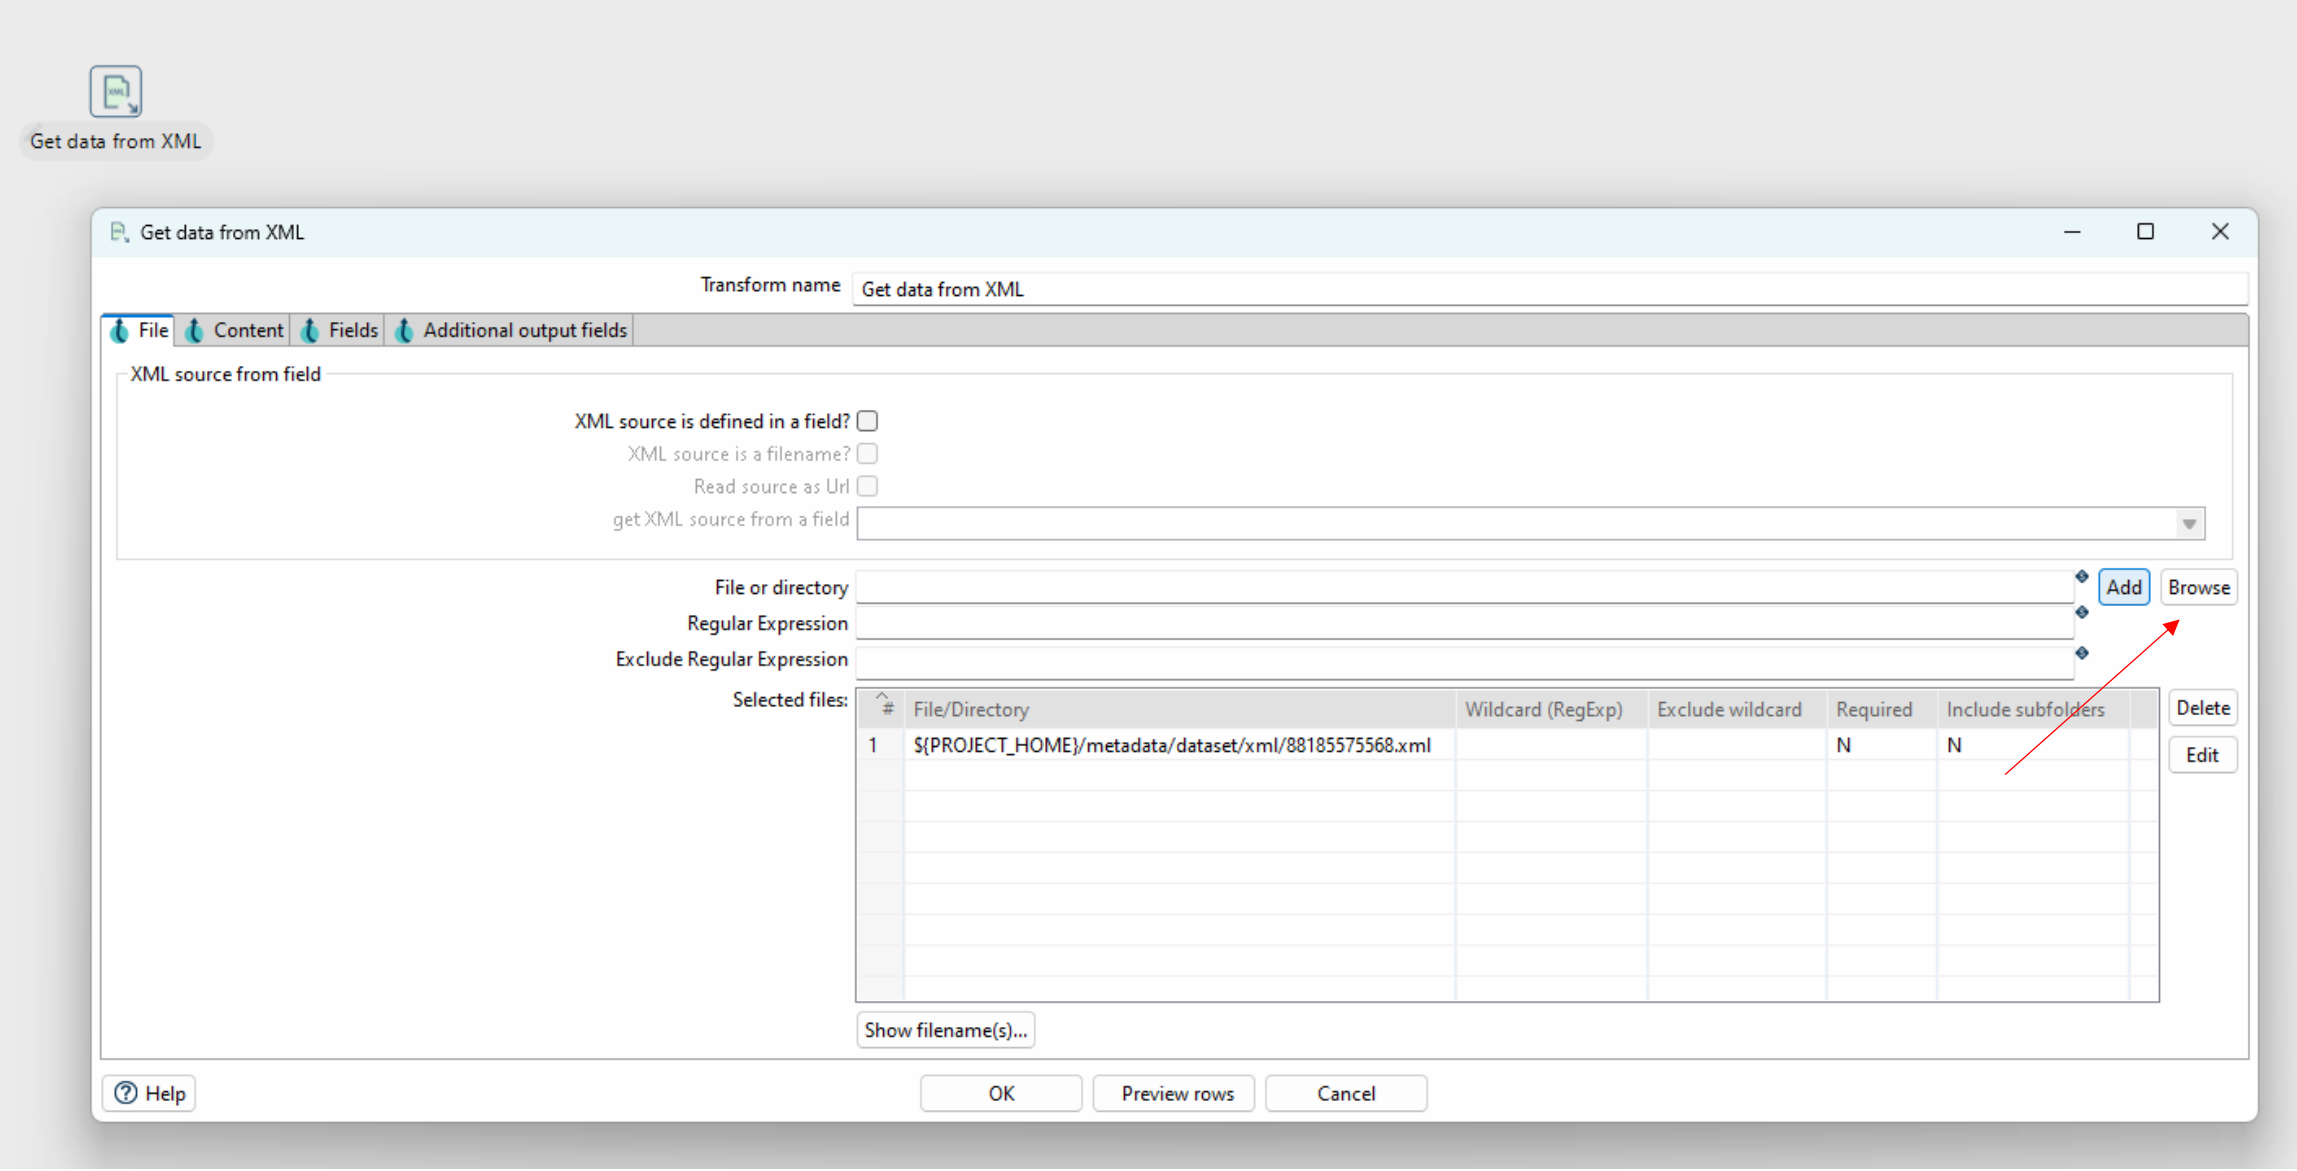

Pipeline Dados do Pesquisador (Lattes) - Arquivo XML para Obtenção de Dados

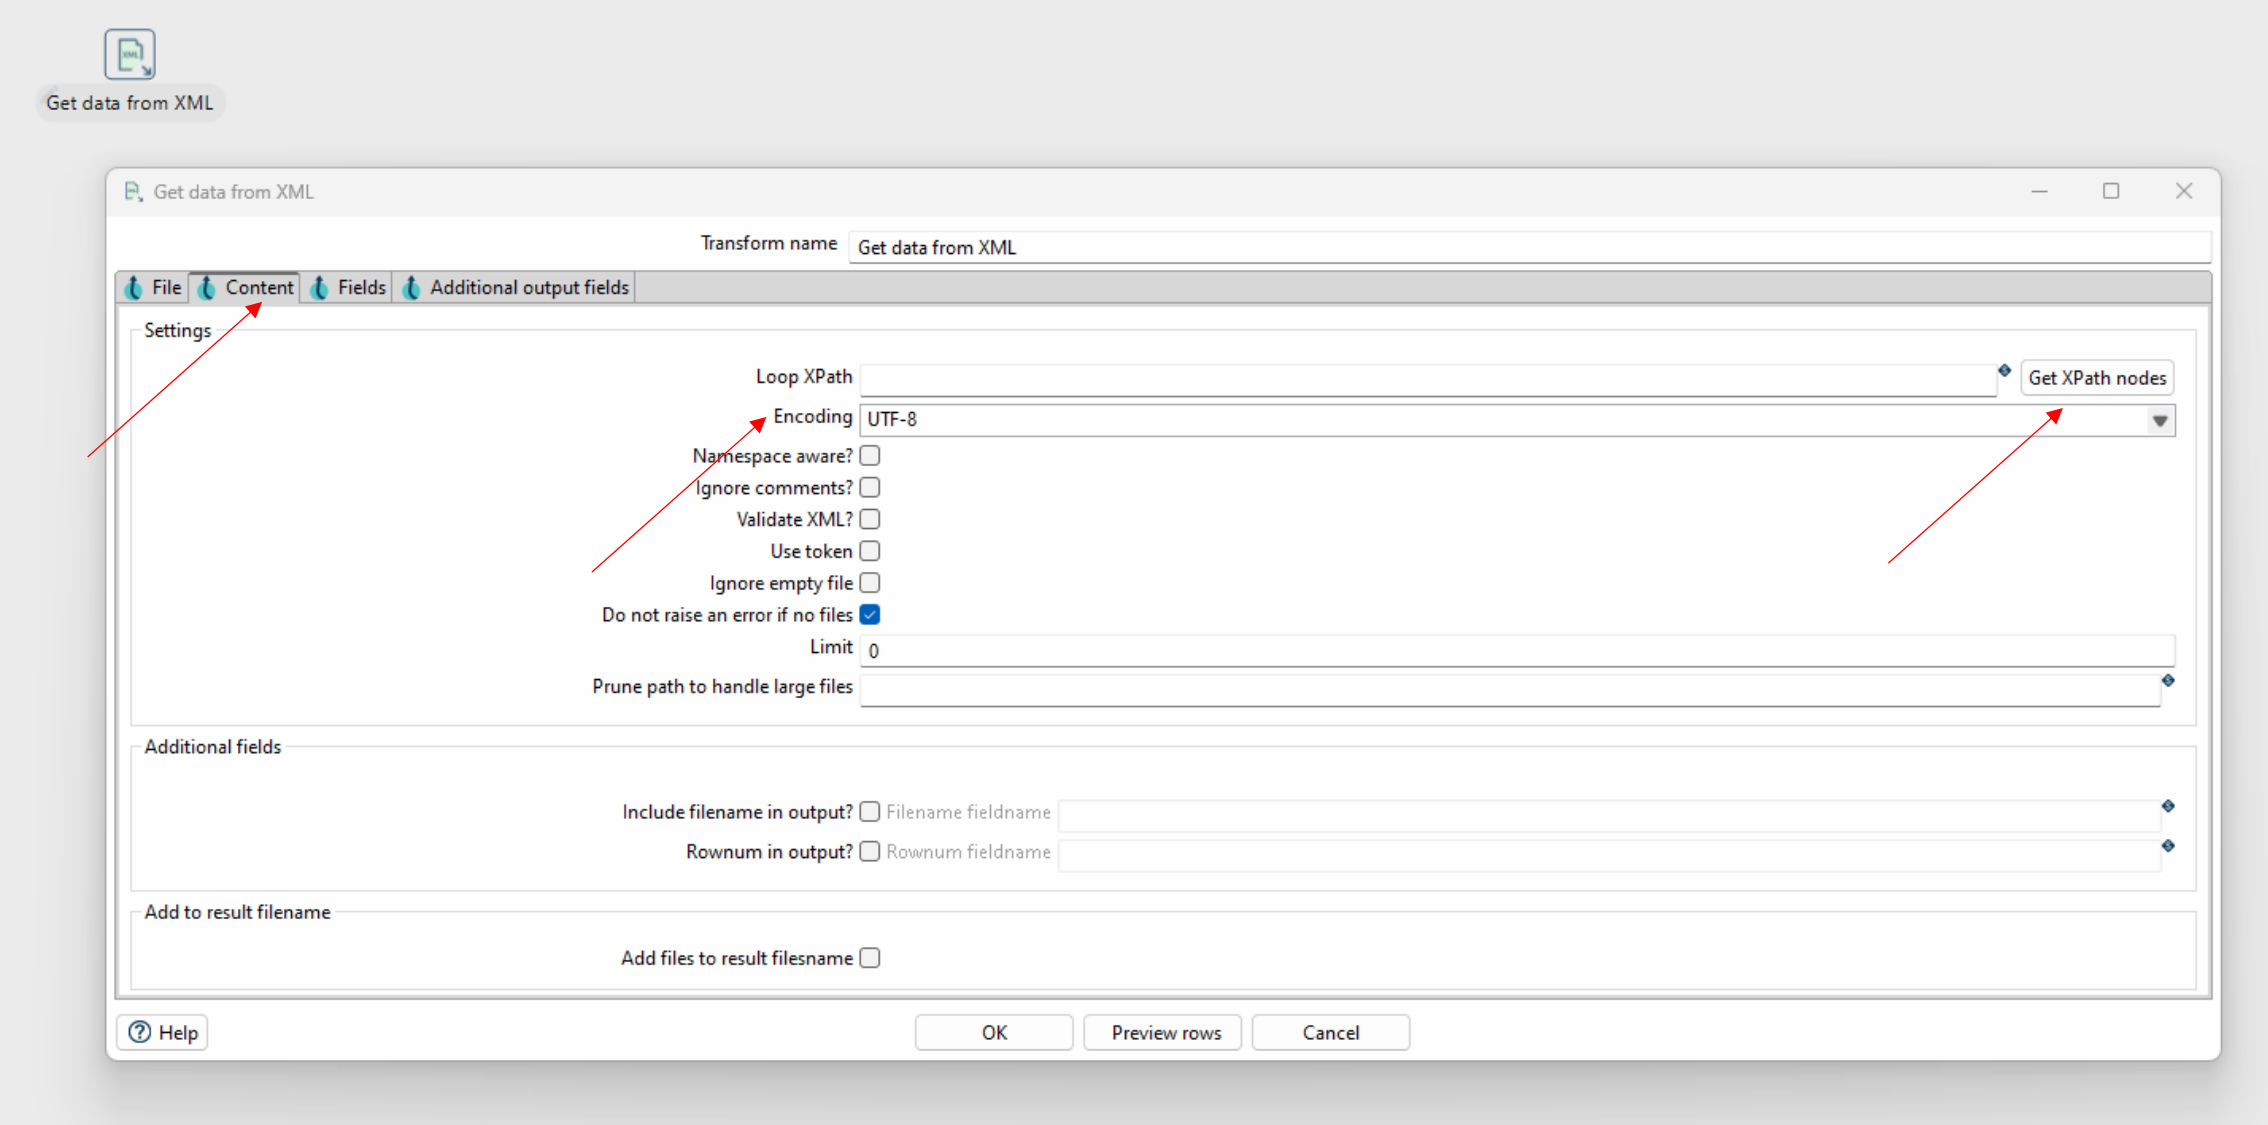

Pipeline Dados do Pesquisador (Lattes) - Arquivo XML para Obtenção de Dados

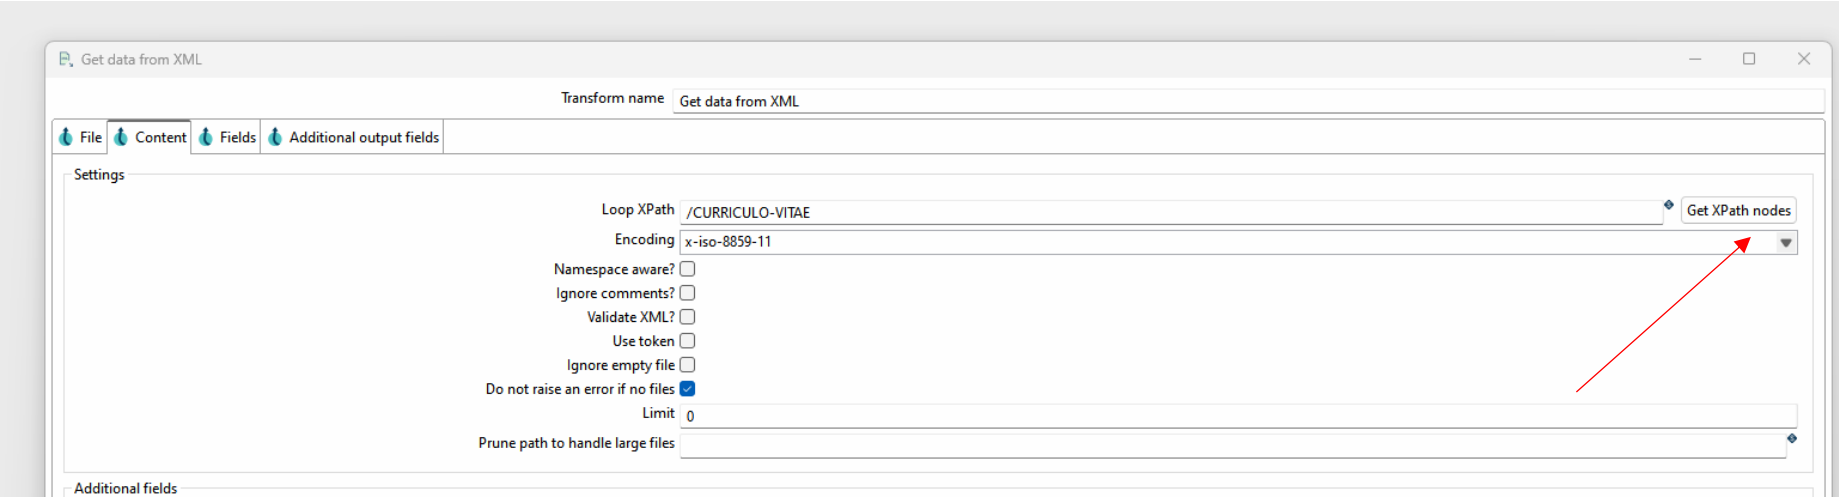

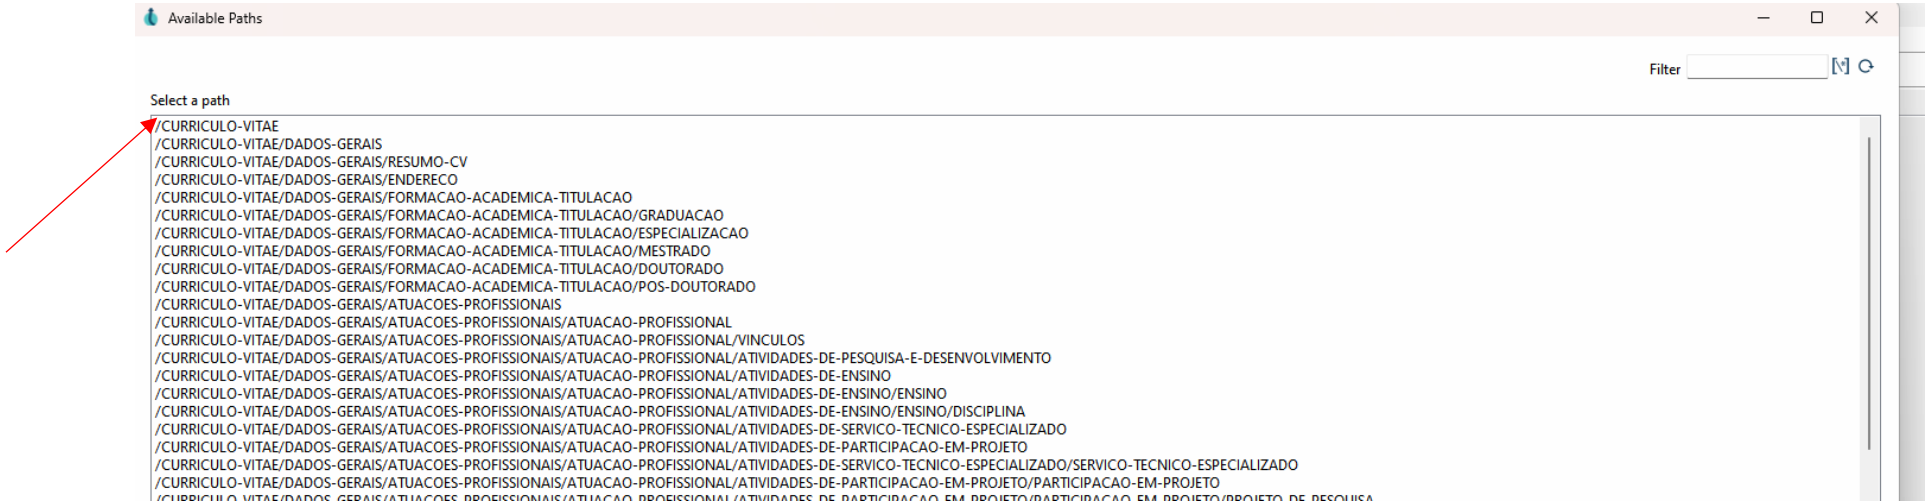

Projeto (Lattes) – Obtendo o número identificador do Lattes para Link com outros dados

File Edit Selection View Go Run Terminal Help Search

stricted Mode is intended for safe code browsing. Trust this window to enable all features. Manage Learn More

curriculo.xml

C: > apache-hop-client-2.9.0 > hop > config > projects > lattes > metadata > dataset > xml > 6716225567627323 > curriculo.xml

C:\apache-hop-client-2.9.0\hop


```
1   <?xml version="1.0" ndalone="no"?><CURRICULO-VITAE SISTEMA-ORIGEM-XML="LATTES_OFFLINE" NUMERO-IDENTIFICADOR="6716225567627323" DATA-ATUALIZACAO="16052024"
    HORA-ATUALIZACAO="094955"><DADOS-GERAIS NOME-COMPLETO="Eduardo Manuel de Freitas Jorge" NOME-EM-CITACOES-BIBLIOGRAFICAS="JORGE, E. M. F.;JORGE, EDUARDO;JORGE, EDUARDO MANOEL DE FREITAS;JORGE, EDUARDO MANUEL F.;
    JORGE, EDUARDO MANUEL DE FREITAS;EDUARDO MANOEL DE FREITAS JORGE;JORGE, EDUARDO MANOEL DE FREITAS JORGE;FREITAS, EDUARDO MANOEL JORGE DE;JORGE, EDUARDO M. F.;JORGE, EDUARDO M.F.;MANUEL DE FREITAS JORGE, EDUARDO"
    NACIONALIDADE="B" PAIS-DE-NASCIMENTO="Portugal" UF-NASCIMENTO="" CIDADE-NASCIMENTO="Lisboa" PERMISSAO-DE-DIVULGACAO="NAO" DATA-FALECIMENTO="" SIGLA-PAIS-NACIONALIDADE="BRA" PAIS-DE-NACIONALIDADE="Brasil"
    ORCID-ID="https://orcid.org/0000-0002-8597-5805"><RESUMO-CV TEXTO-RESUMO-CV-RH="Doutor em Difus►o do Conhecimento no programa multi institucional pela UFBA e mestre em Ci►ncia da Computa►►o pela Universidade Feder
    de Campina Grande  PB. ►  professor Titular da (Universidade Estadual da Bahia) UNEB  - Departamento de Ci►ncias Extas e da Terra Campus I/Salvador. Atuou  como  Gerente de Pesquisa da Pr►-Reitoria de Pesquisa e
    Ensino de P►s-Gradua►►o - PPG UNEB  e como coordenador do programa de Inicia►►o Cient►fica da UNEB junto ao CNPQ e a FAPESB. ► professor do curso de doutorado em Difus►o do Conhecimento, no mestrado em Estudos
    Territoriais da UNEB e l►der do Grupo de Pesquisa Aplicada e Inova►►o.  Foi coordenador da Ag►ncia Uneb de Inova►►o e tem trabalhado nos ►ltimos anos em Institutos de Pesquisa e Desenvolvimento em projetos de
    pesquisa aplicada com a Samsung, Ford, Totvs, Embraer, etc gerando mais de 16 patentes concedidas e solicitadas como autor intelectual e uma transfer►ncia de tecnologia realizada com o Sistema Online de Inicia►►o
    Cient►fica UNEB. Atua no grupo Data Science BR que reestruturou a Plataforma Nilo Pe►anha do Minist►rio da Educa►►o.  Por fim, foi um dos pesquisadores que reestruturou a Pol►tica de Inova►►o da UNEB."
    TEXTO-RESUMO-CV-RH-EN="PhD in Knowledge Diffusion in the multi-institutional program by UFBA and Master in Computer Science by the Federal University of Campina Grande PB. He is a Full Professor at (State University
    of Bahia) UNEB - Department of Extas and Earth Sciences Campus I/Salvador. He currently works as Research Manager at the Dean of Research and Postgraduate Teaching - PPG UNEB and as coordinator of the Scientific
```

Pipeline Dados do Pesquisador (Lattes) - Arquivo XML para Obtenção de Dados (Get Fields)

curriculo.xml

C: > apache-hop-client-2.9.0 > hop > config > projects > lattes > metadata > dataset > xml > 6716225567627323 > curr

Tokenization is skipped for long lines for performance reasons. This can be configured via editor.maxTokenizationLineLength.


```
1 <?xml version="1.0" encoding="ISO-8859-1" standalone="no"?><CURRICULO-VITAE SISTEMA-OR
HORA-ATUALIZACAO="094955"><DADOS-GERAIS NOME-COMPLETO="Eduardo Manuel de Freitas Jorge" NOME-EM-CITACOES-BIBLIOGRAFICAS="JORGE, E. M. F.;JORGE, EDUARDO;JORGE, EDUARDO MANOEL DE FREITAS;JORGE, EDUARDO MANUEL F.;
JORGE, EDUARDO MANUEL DE FREITAS;EDUARDO MANOEL DE FREITAS JORGE;JORGE, EDUARDO MANOEL DE FREITAS JORGE;FREITAS, EDUARDO MANOEL JORGE DE;JORGE, EDUARDO M. F.;JORGE, EDUARDO M.F.;MANUEL DE FREITAS JORGE, EDUARDO"
NACIONALIDADE="B" PAIS-DE-NASCIMENTO="Portugal" UF-NASCIMENTO="" CIDADE-NASCIMENTO="Lisboa" PERMISSAO-DE-DIVULGACAO="NAO" DATA-FALECIMENTO="" SIGLA-PAIS-NACIONALIDADE="BRA" PAIS-DE-NACIONALIDADE="Brasil"
ORCID-ID="https://orcid.org/0000-0002-8597-5805"><RESUMO-CV TEXTO-RESUMO-CV-RH="Doutor em Difus►o do Conhecimento no programa multi institucional pela UFBA e mestre em Ci►ncia da Computa►►o pela Universidade Federa
de Campina Grande  PB. ►  professor Titular da (Universidade Estadual da Bahia) UNEB  - Departamento de Ci►ncias Extas e da Terra Campus I/Salvador. Atuou  como  Gerente de Pesquisa da Pr►-Reitoria de Pesquisa e
Ensino de P►s-Gradua►►o - PPG UNEB  e como coordenador do programa de Inicia►►o Cient►fica da UNEB junto ao CNPQ e a FAPESB. ► professor do curso de doutorado em Difus►o do Conhecimento, no mestrado em Estudos
Territoriais da UNEB e l►der do Grupo de Pesquisa Aplicada e Inova►►o.  Foi coordenador da Ag►ncia Uneb de Inova►►o e tem trabalhado nos ►ltimos anos em Institutos de Pesquisa e Desenvolvimento em projetos de
pesquisa aplicada com a Samsung, Ford, Totvs, Embraer, etc gerando mais de 16 patentes concedidas e solicitadas como autor intelectual e uma transfer►ncia de tecnologia realizada com o Sistema Online de Inicia►►o
Cient►fica UNEB. Atua no grupo Data Science BR que reestruturou a Plataforma Nilo Pe►anha do Minist►rio da Educa►►o.  Por fim, foi um dos pesquisadores que reestruturou a Pol►tica de Inova►►o da UNEB."
TEXTO-RESUMO-CV-RH-EN="PhD in Knowledge Diffusion in the multi-institutional program by UFBA and Master in Computer Science by the Federal University of Campina Grande PB. He is a Full Professor at (State University
of Bahia) UNEB - Department of Extas and Earth Sciences Campus I/Salvador. He currently works as Research Manager at the Dean of Research and Postgraduate Teaching - PPG UNEB and as coordinator of the Scientific
Initiation program at UNEB with CNPQ and FAPESB. He is a professor of the doctoral course in Knowledge Diffusion, in the Masters in Territorial Studies at UNEB and leader of the Applied Research and Innovation
Group. He was coordinator of the Uneb Innovation Agency and has worked in recent years at Research and Development Institutes in applied research projects with Samsung, Ford, Totvs, Embraer, etc., generating more
than 16 patents granted and requested as an intellectual author and a transfer of technology carried out with the UNEB Scientific Initiation Online System. He works in the Data Science BR group that restructured the
Nilo Pe►anha Platform of the Ministry of Education. Finally, he was one of the researchers who restructured UNEB's Innovation Policy."/><ENDERECO FLAG-DE-PREFERENCIA="ENDERECO_INSTITUCIONAL"><ENDERECO-PROFISSIONAL
CODIGO-INSTITUICAO-EMPRESA="584200000007" NOME-INSTITUICAO-EMPRESA="Universidade do Estado da Bahia" CODIGO-ORGAO="584203000008" NOME-ORGAO="Departamento de Ci►ncias Exatas e da Terra" CODIGO-UNIDADE="584203001993"
NOME-UNIDADE="Colegiado Sistema de Infroma►►o" LOGRADOURO-COMPLEMENTO="Rua Silveira Martins" PAIS="Brasil" UF="BA" CEP="41150000" CIDADE="Salvador" BAIRRO="Cabula" DDD="71" TELEFONE="31172200" RAMAL="" FAX=""
```


Get data from XML

Transform name: Get data from XML

File | Content | Fields | Additional output fields

#	Name	XPath	Element	Result type	Type	Format	Length	Precision	Currency	Decimal	Group	Trim type	Repeat
1	NOME	DADOS-GERAIS/@NOME-COMPLETO	Node	Value of	String							none	N

Projeto (Lattes) – Obtendo o número identificador do Lattes para Link com outros dados

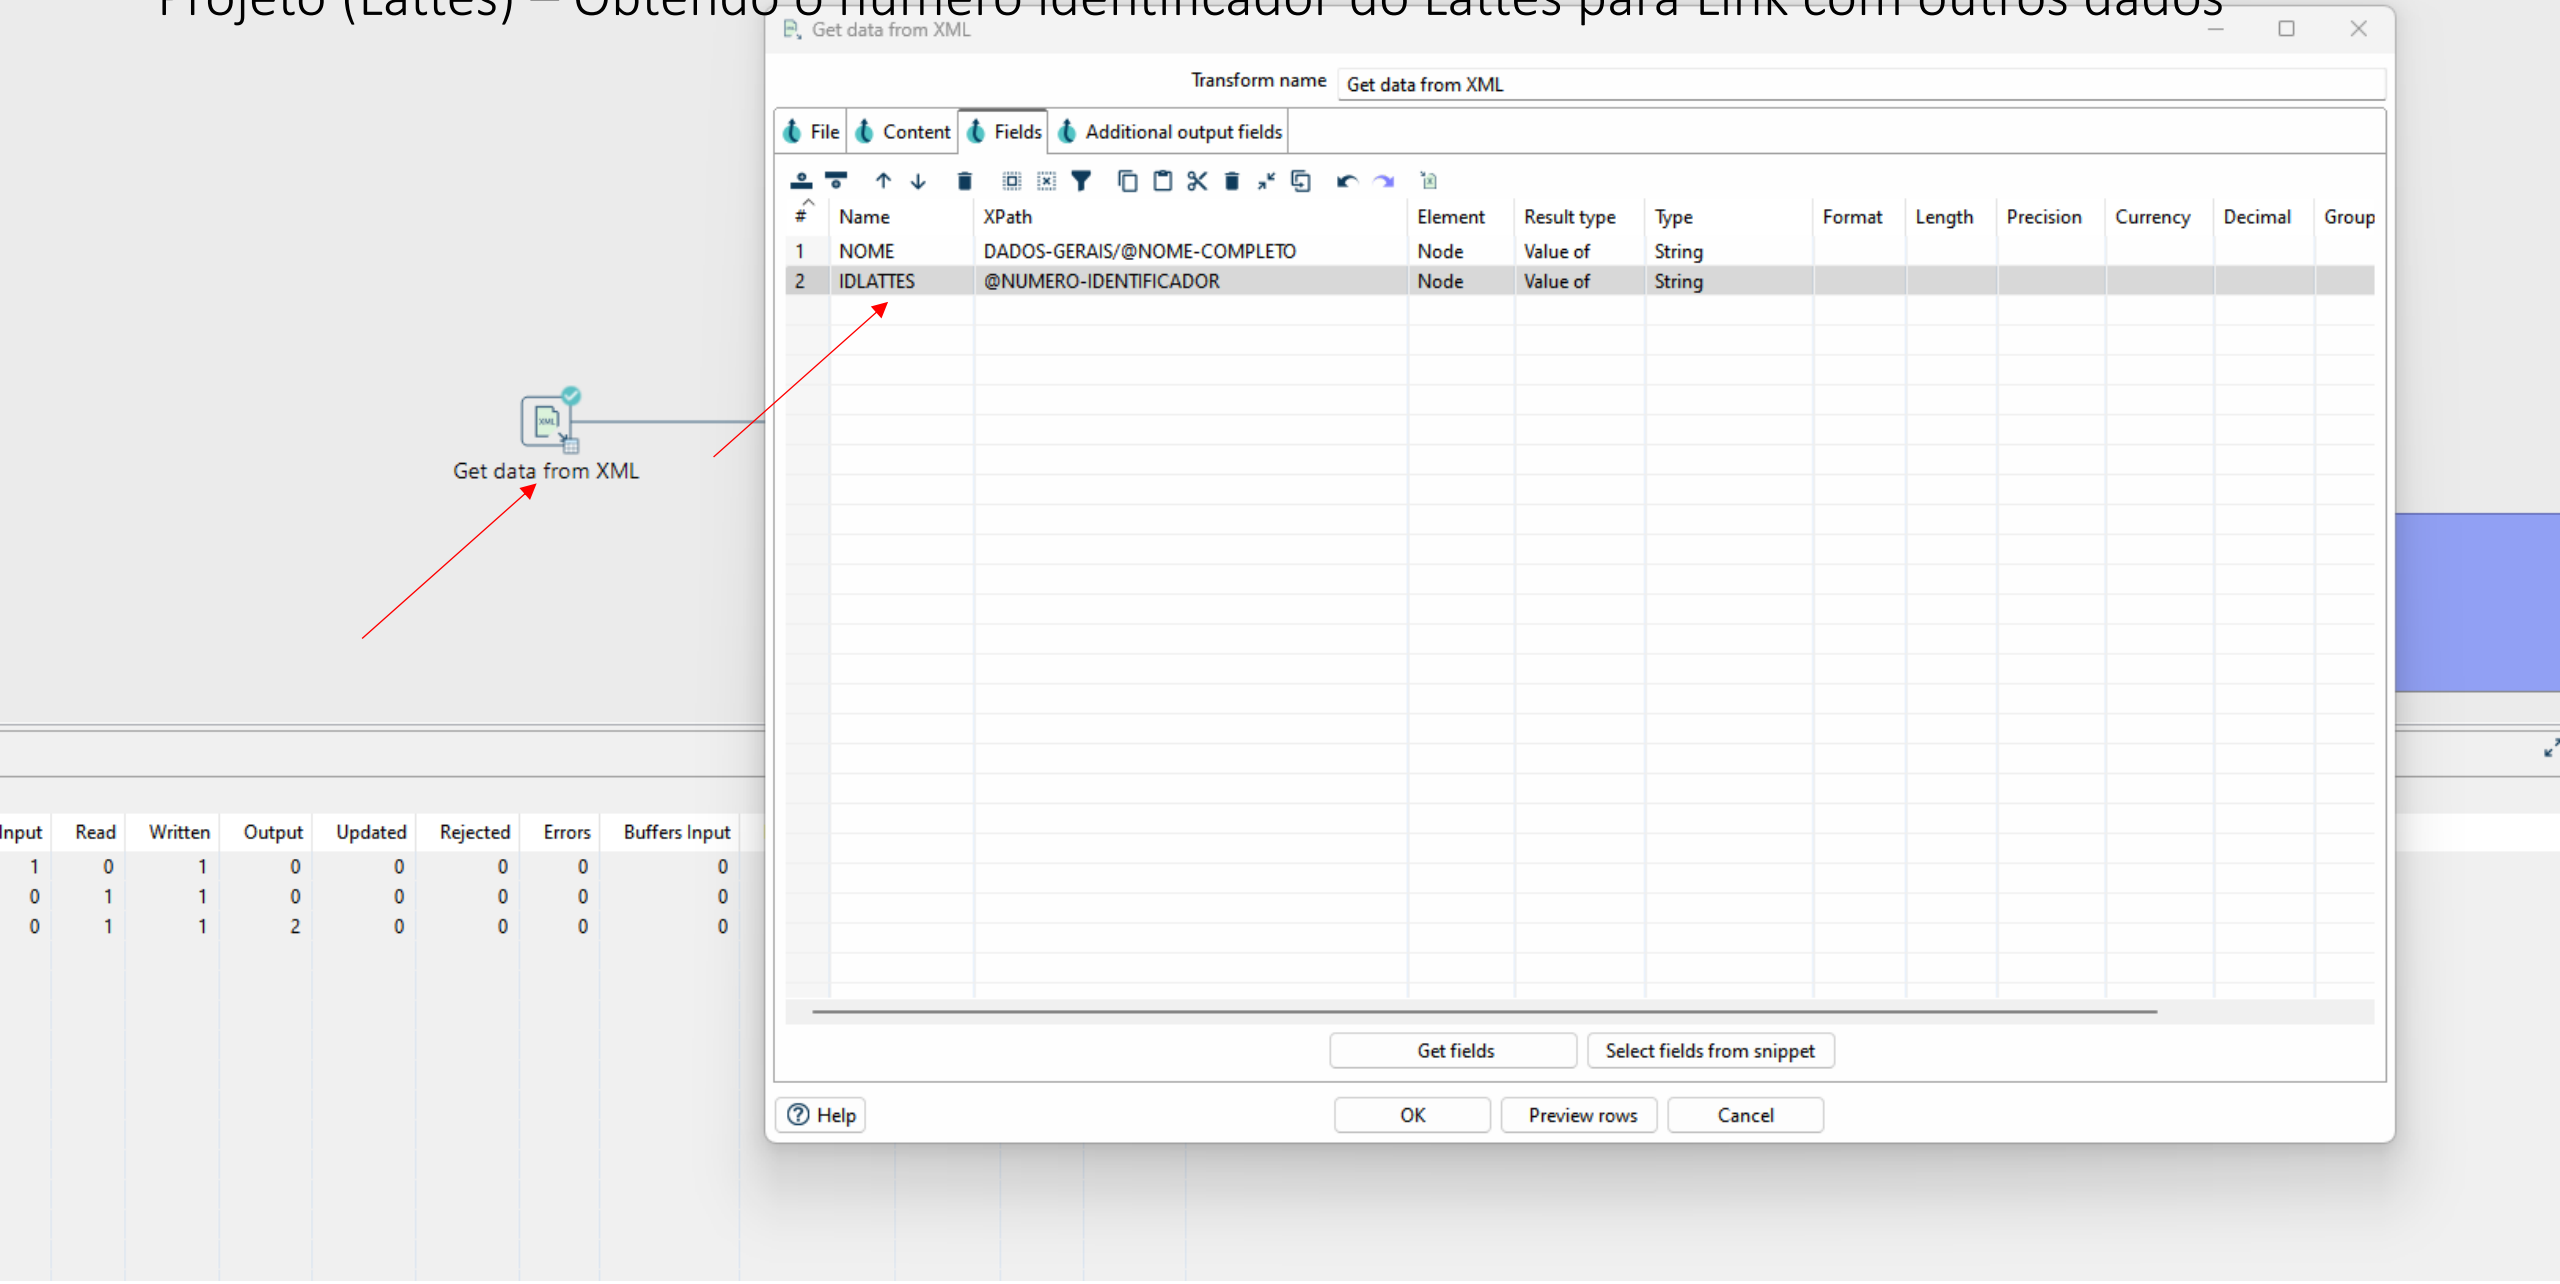

Testando se os dados estão Ok

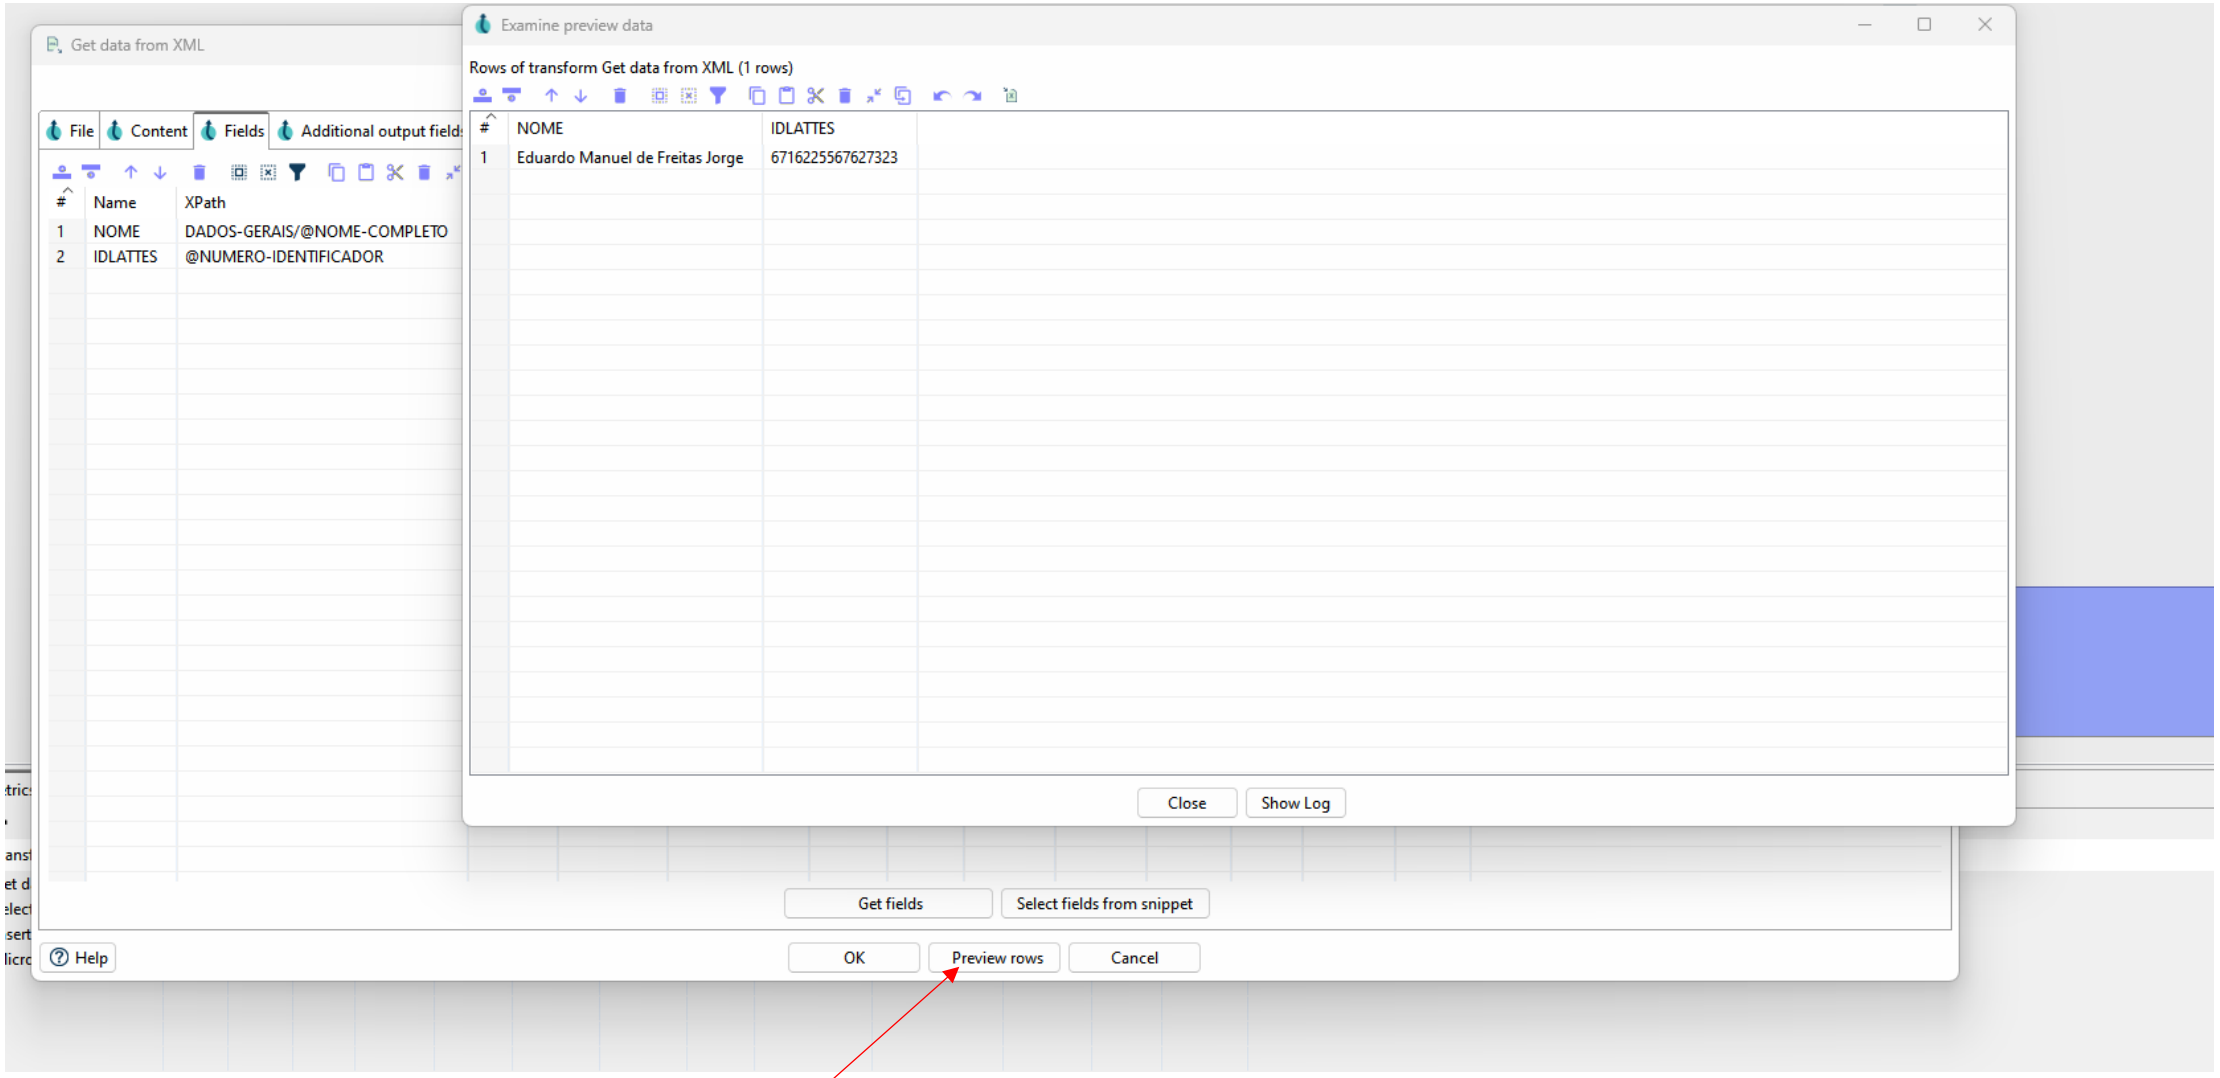

Pipeline Dados do Pesquisador (Lattes) – Preview Rows

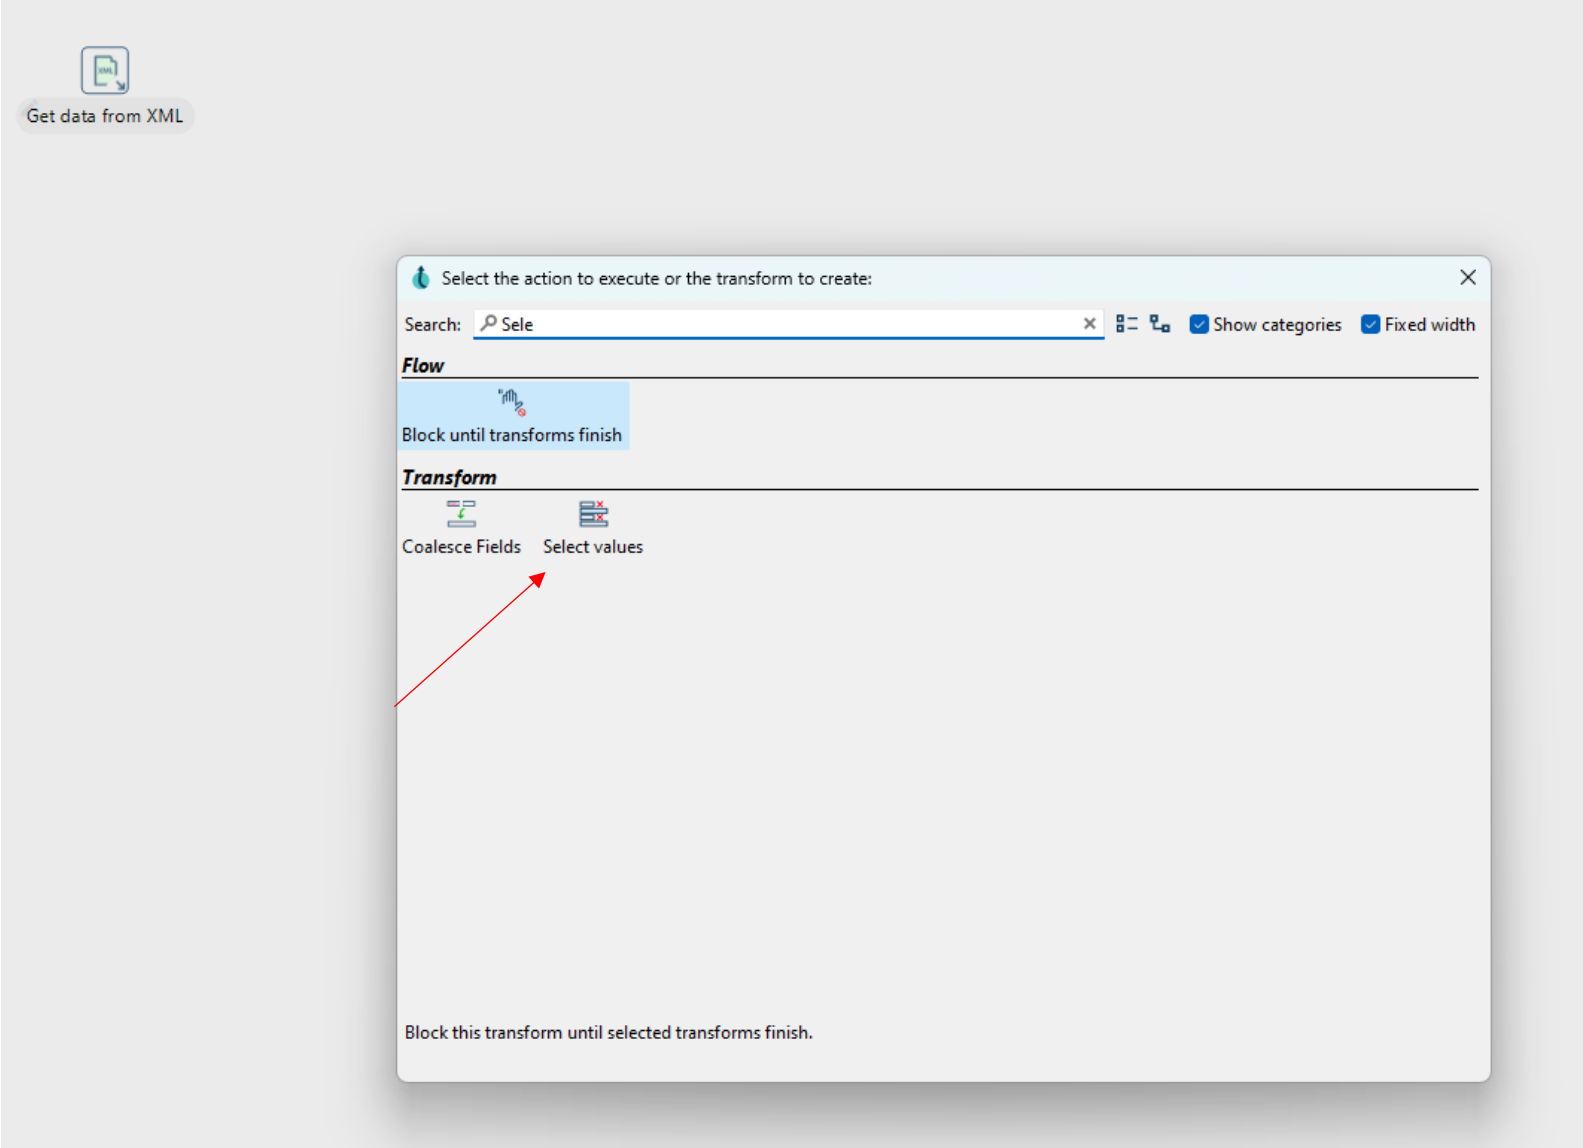

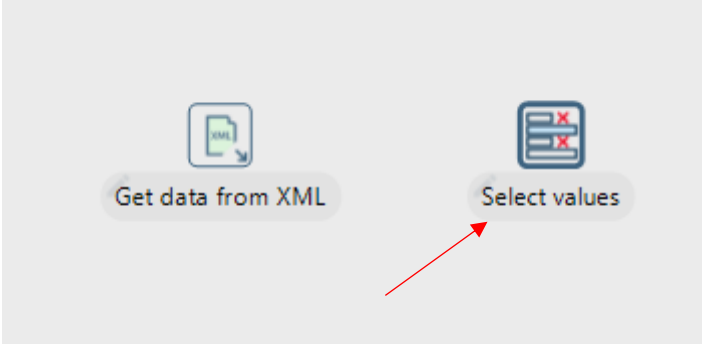

Pipeline Dados do Pesquisador (Lattes) – Ligação das Transformações (Tecla Shift)

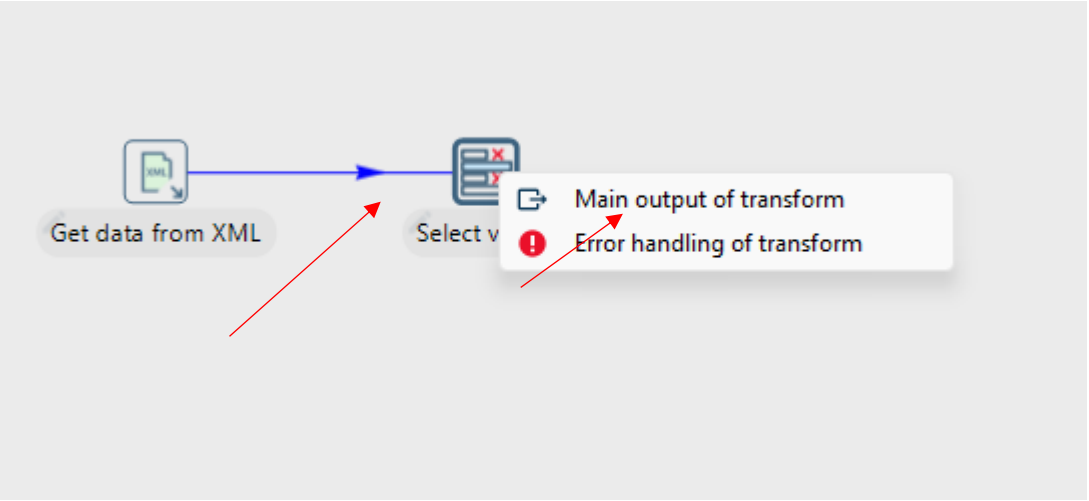

Pipeline Dados do Pesquisador (Lattes) – Vamos selecionar somente o nomeCompleto

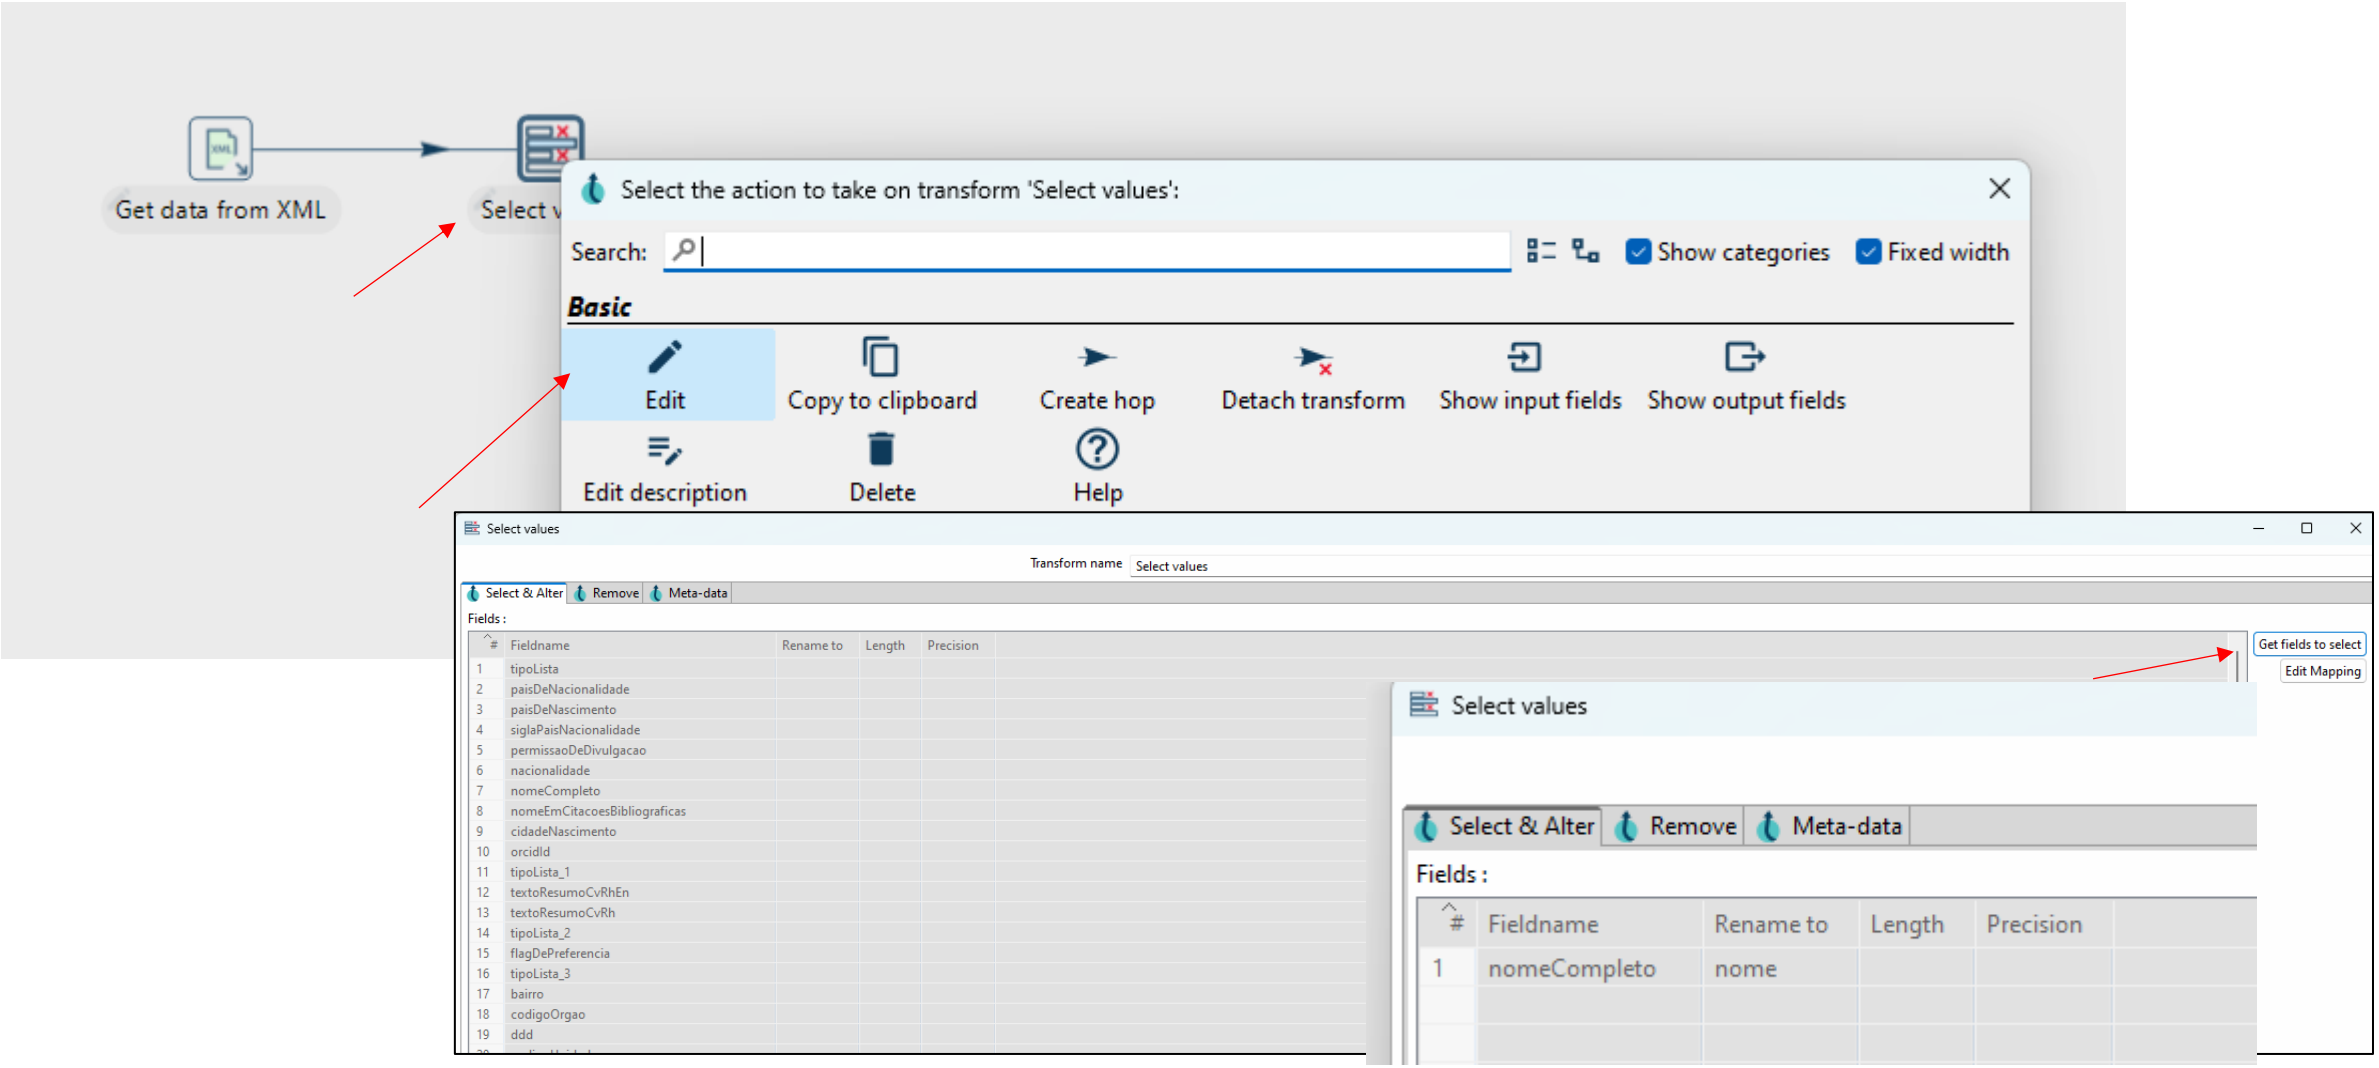

Projeto (Lattes) – Obtendo o número identificador do Lattes para Link com outros dados

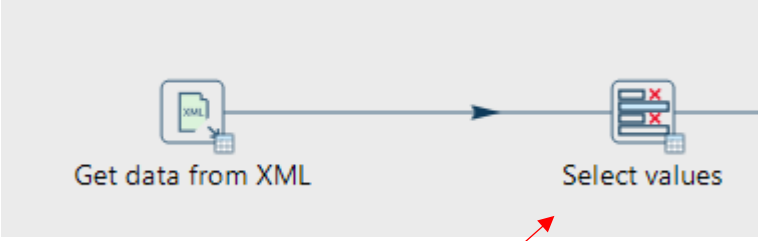

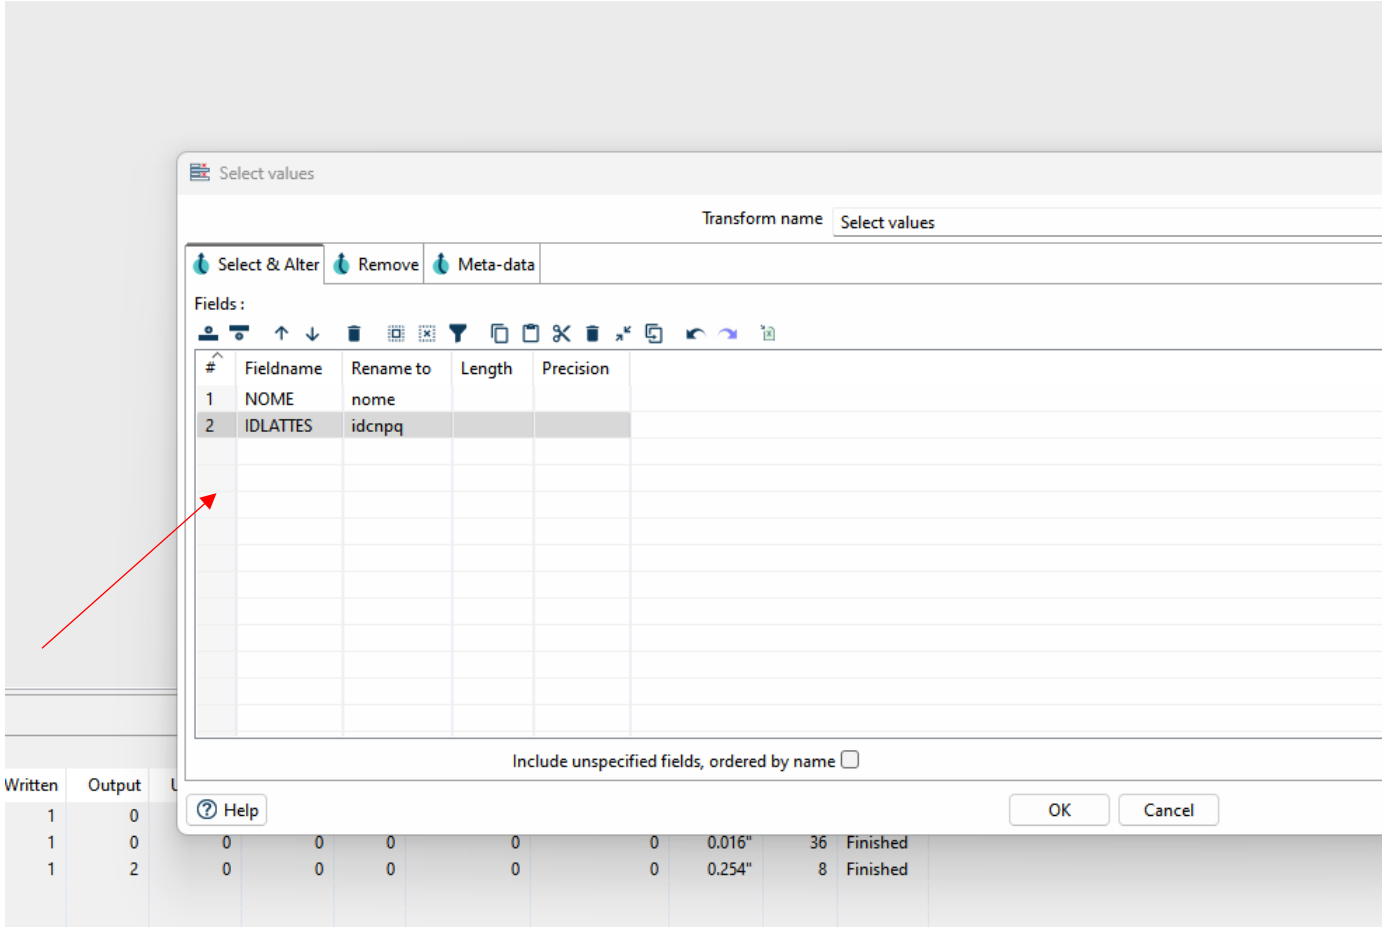

Pipeline Dados do Pesquisador (Lattes) – Executando o Projeto

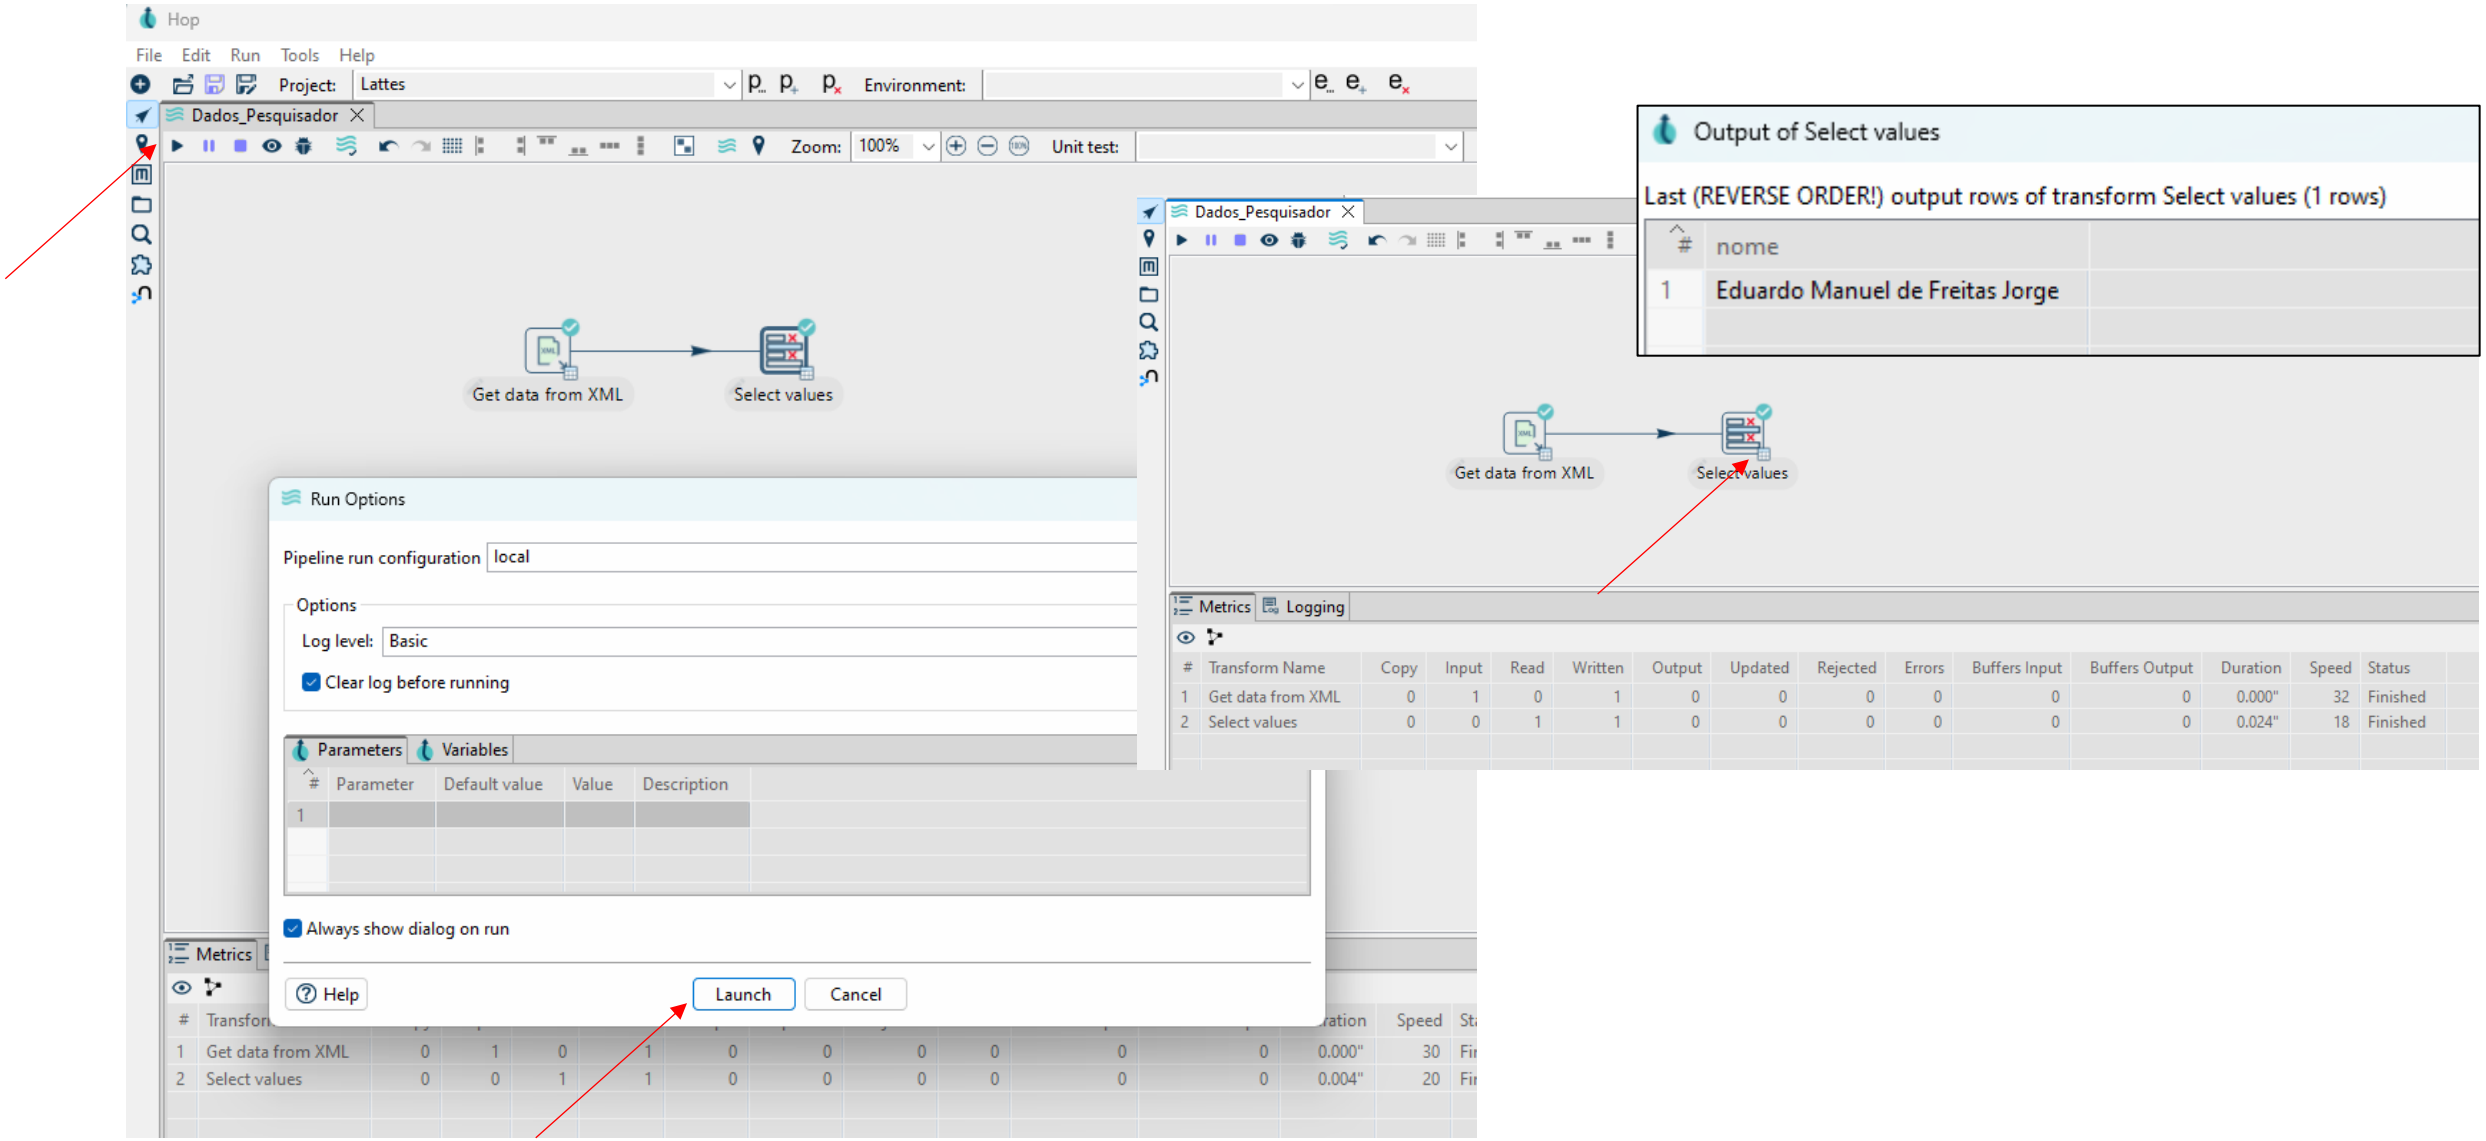

Pipeline Dados do Pesquisador (Lattes) – Gravando os dados no Banco de Dados

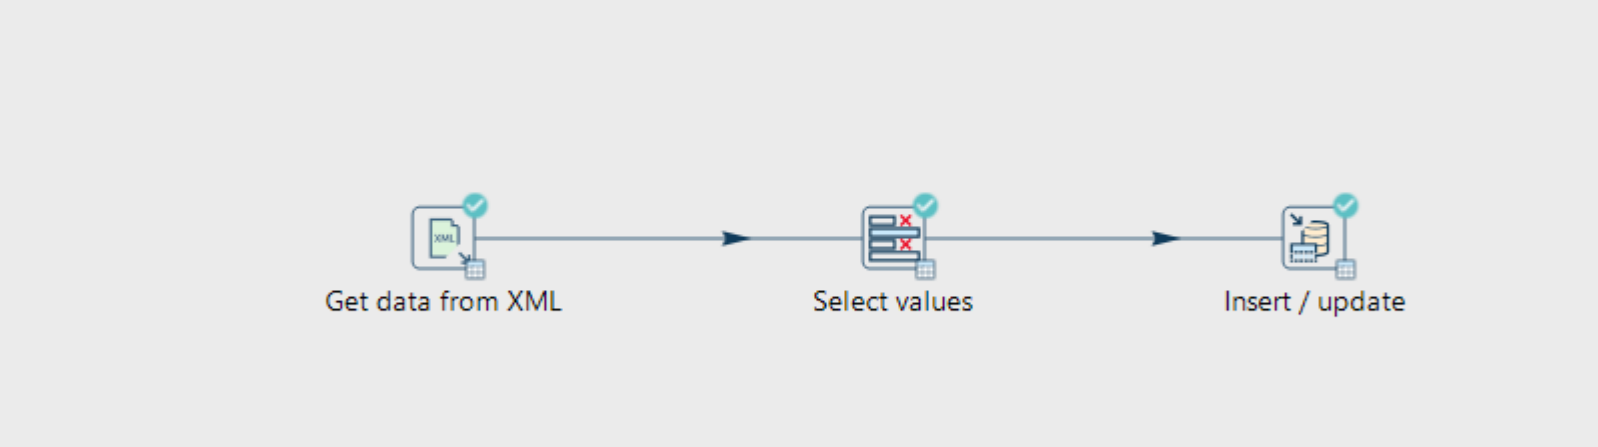

Pipeline Dados do Pesquisador (Lattes) – Gravando os dados

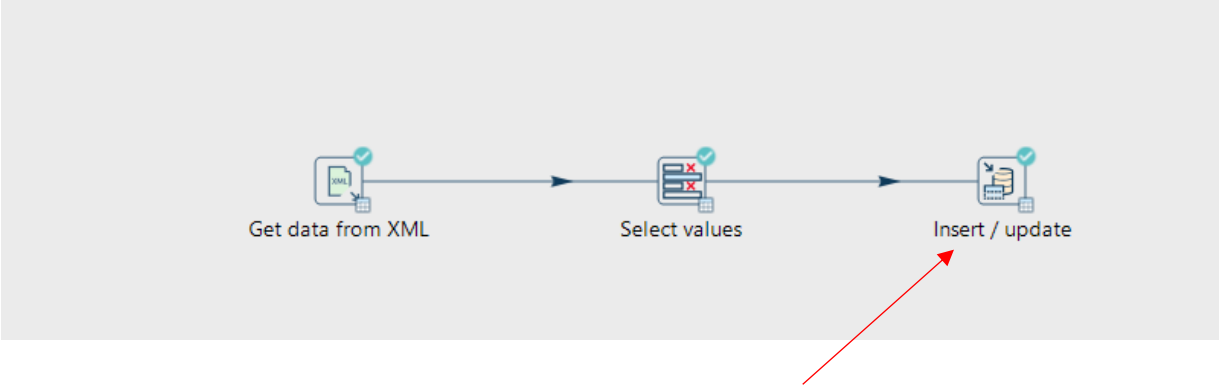

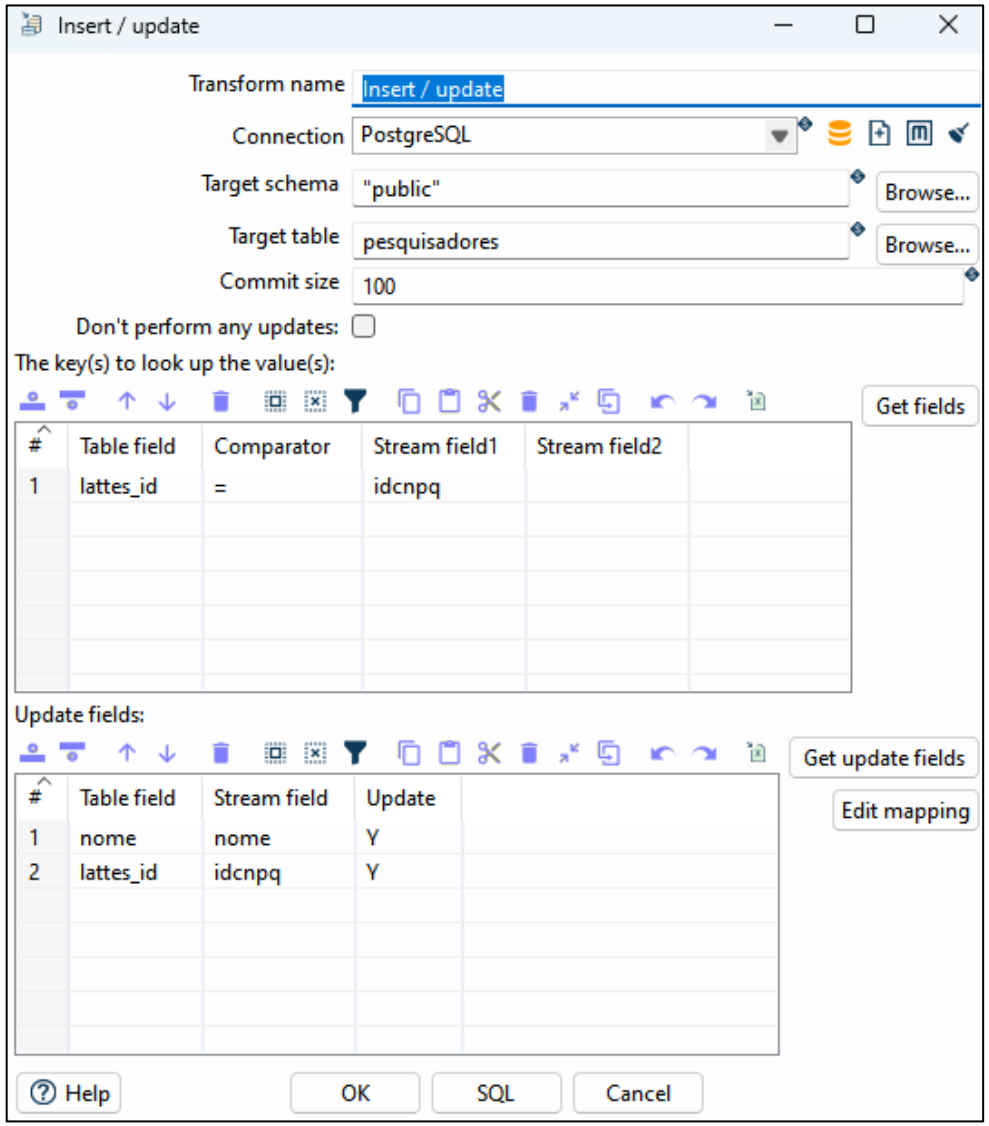

Projeto (Lattes) – Executando o Projeto

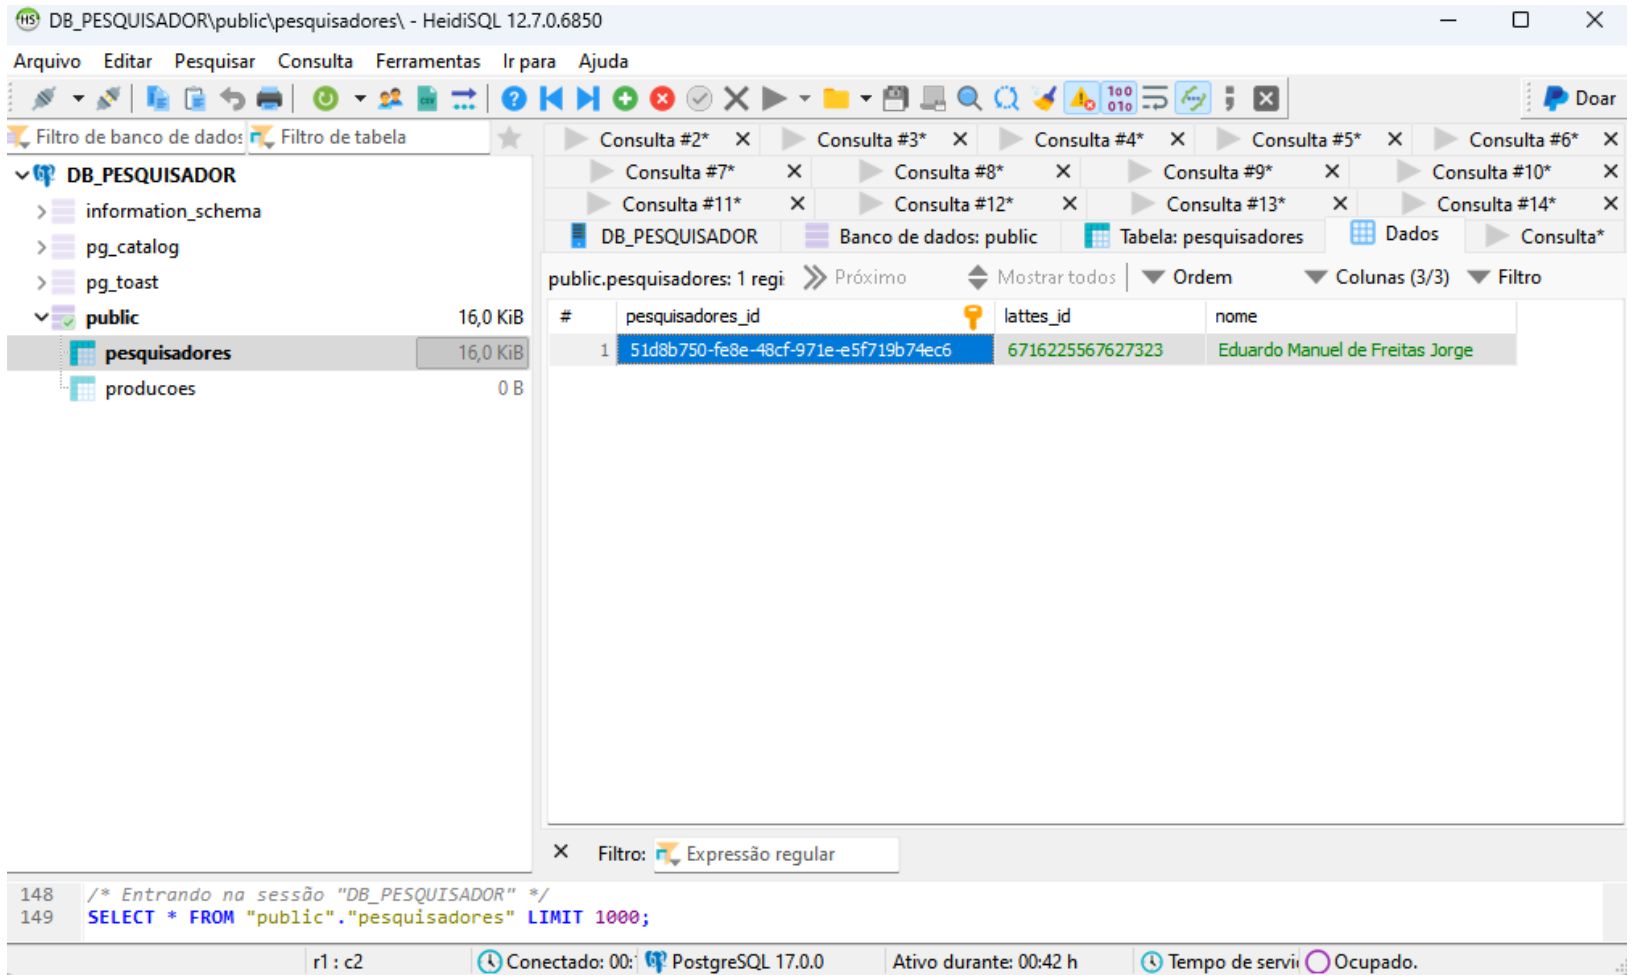

Exemplo II

Obtendo dados de vários Pesquisadores do Lattes

SAMBA

1º Simpósio Acadêmico Multidisciplinar de Big Data Analytics

Projeto (Lattes) – Pipeline Dados_Pesquisadores_Varios.hpl

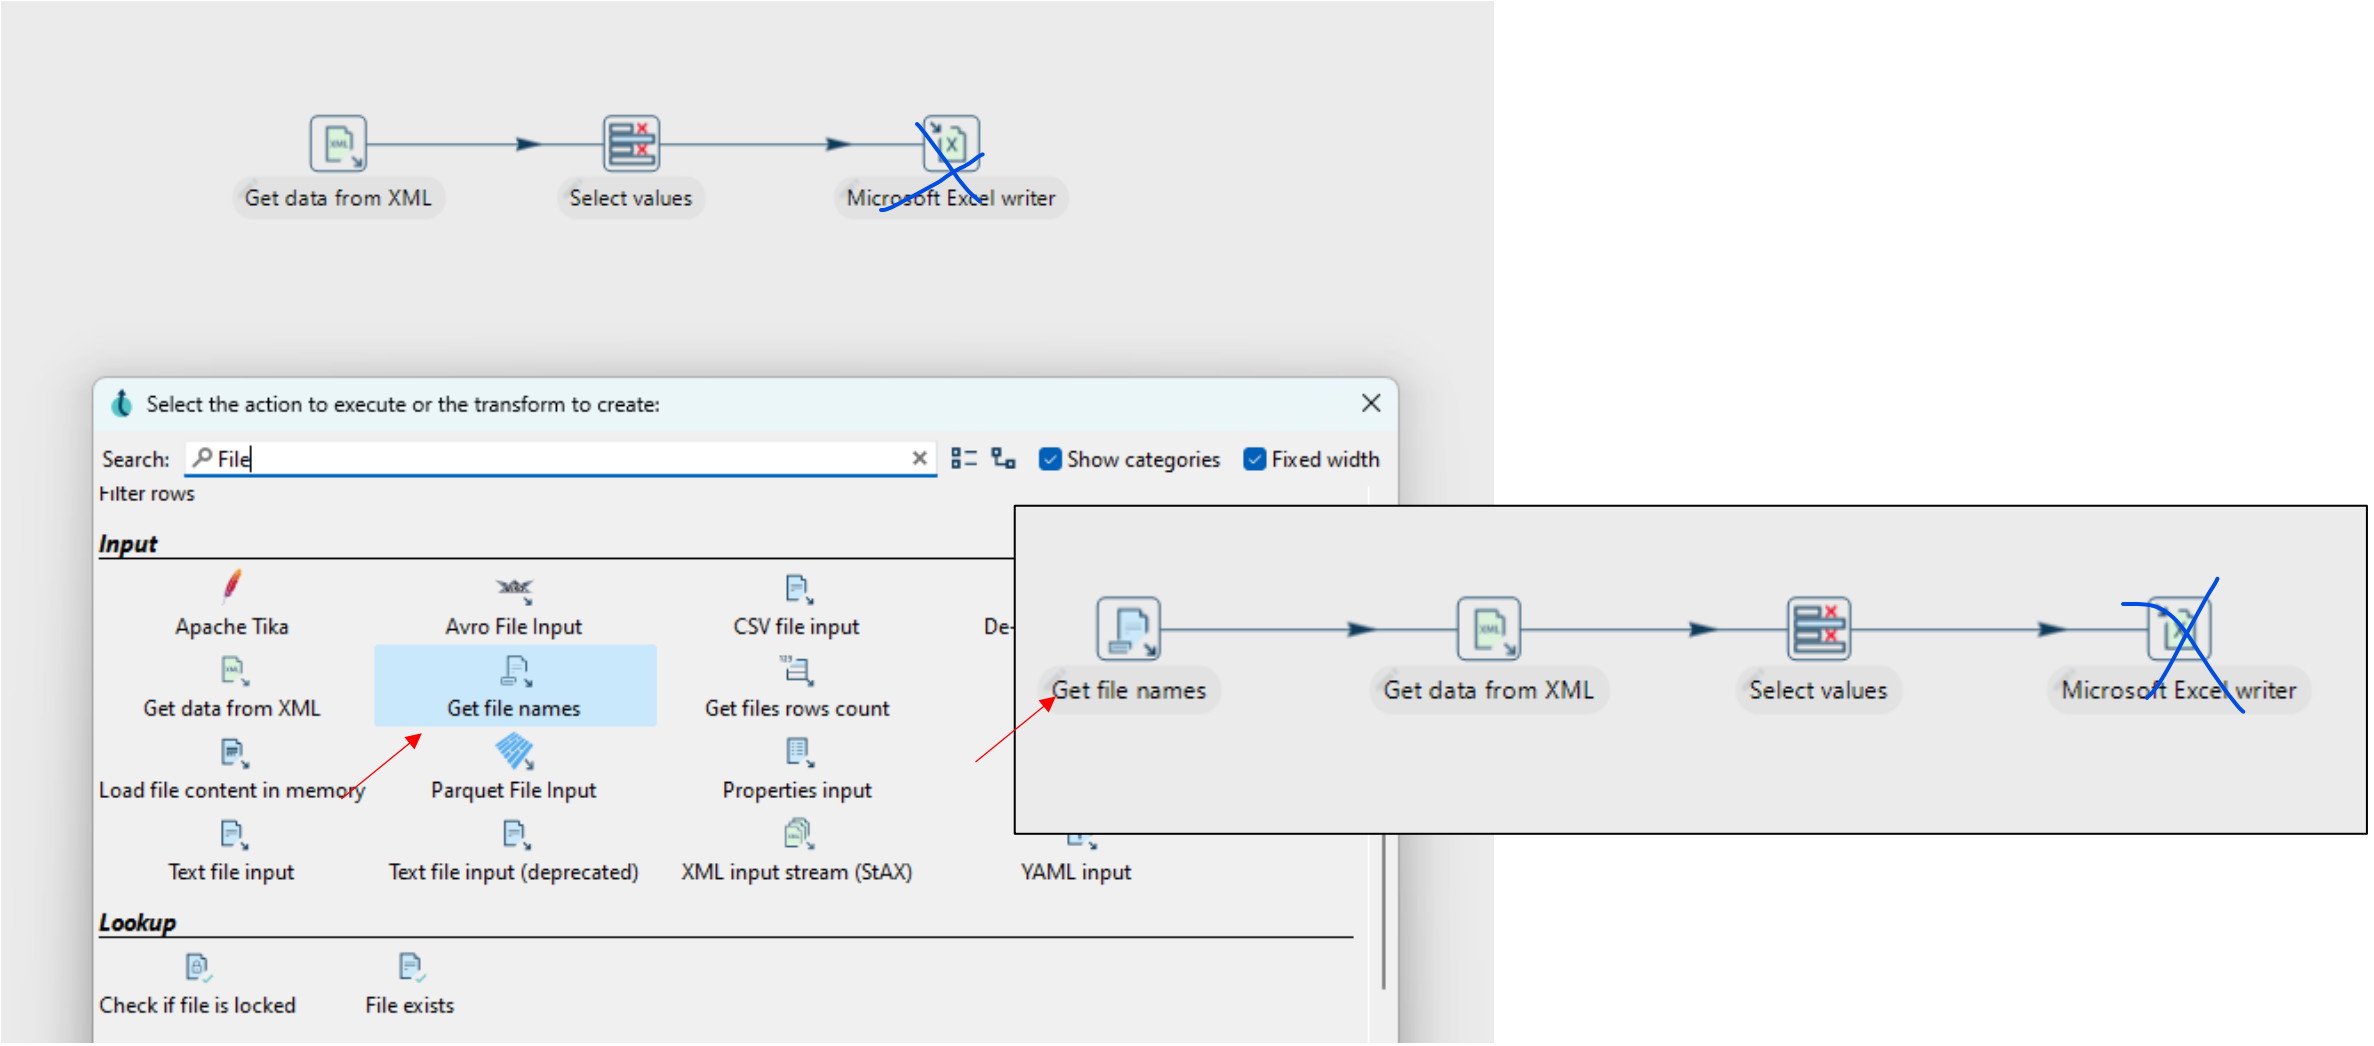

Projeto (Lattes) – Indicando a pasta para ler os arquivos XML

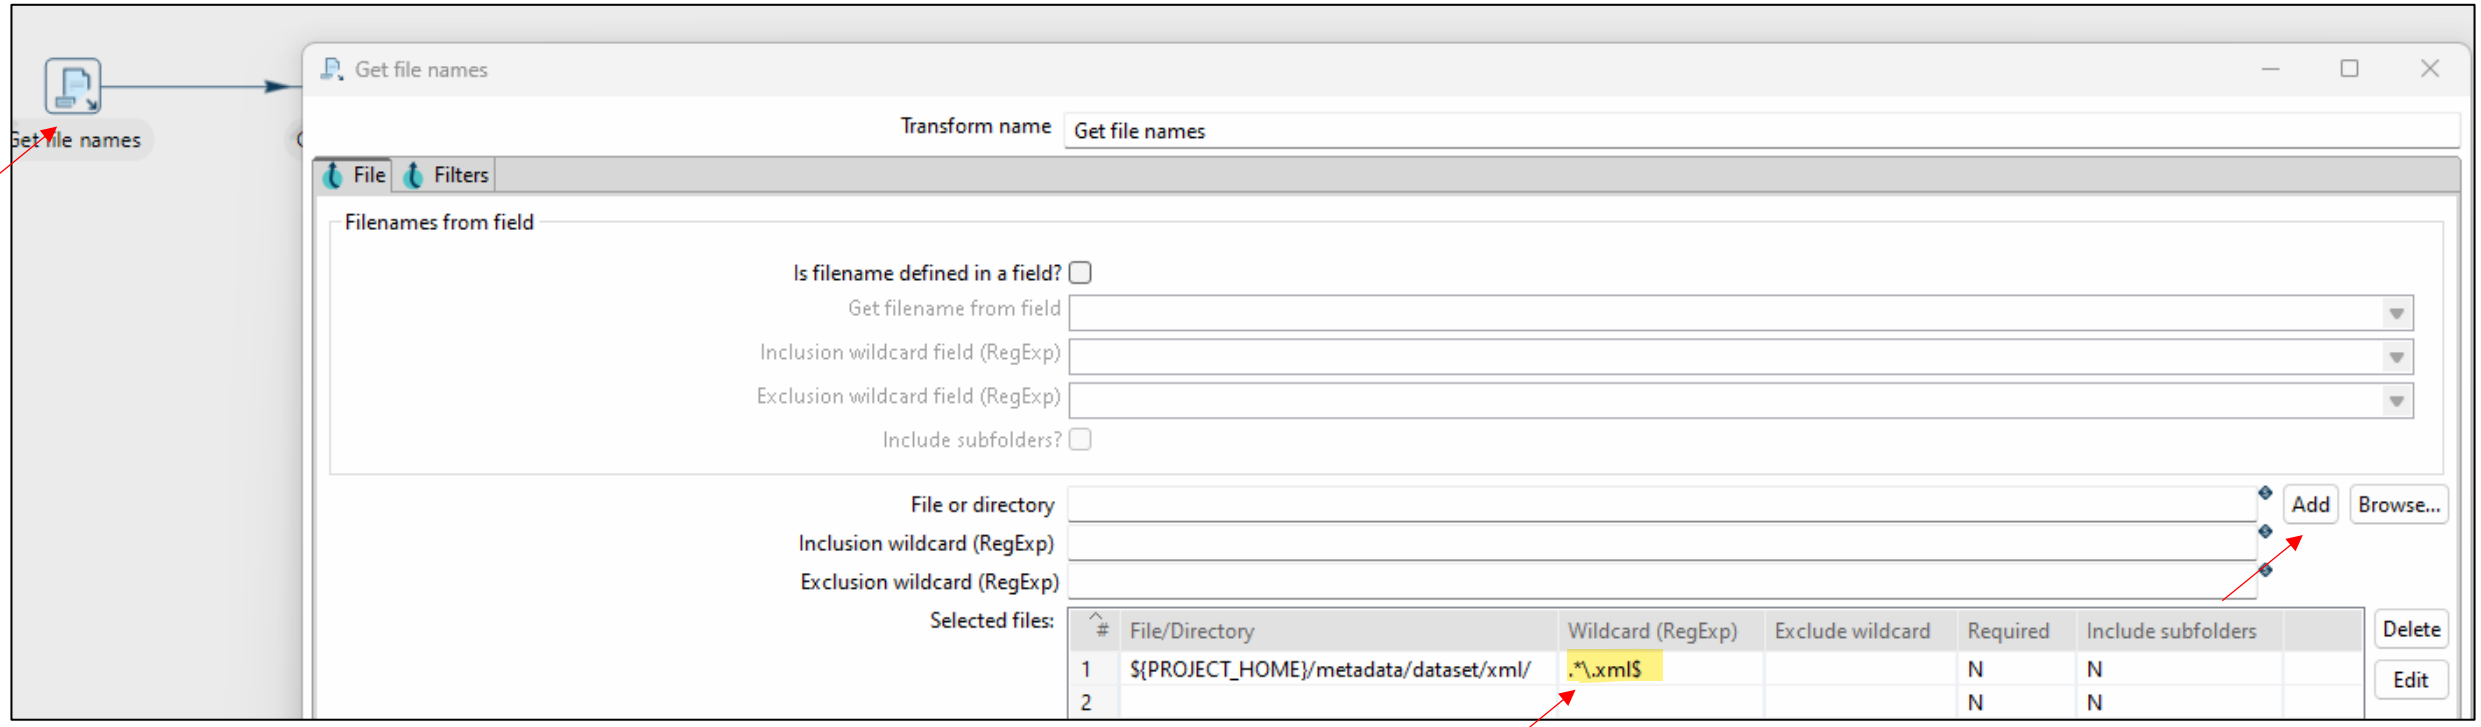

.*\.xml$

https://hop.apache.org/manual/latest/pipeline/transforms/getfilenames.html

FILE TAB

This tab defines the location of the files you want to retrieve filenames for. For more information about specifying file locations, see section "Selecting file using Regular Expressions" on the Text File Input transform.

Example: You have a static directory of c:\temp where you expect files with an extension of .dat to be placed. Under file/directory you would specify c:\temp and under Wildcard you would have a RegEx with something like .*\.dat$

Projeto (Lattes) – Indicando a pasta para ler os arquivos XML

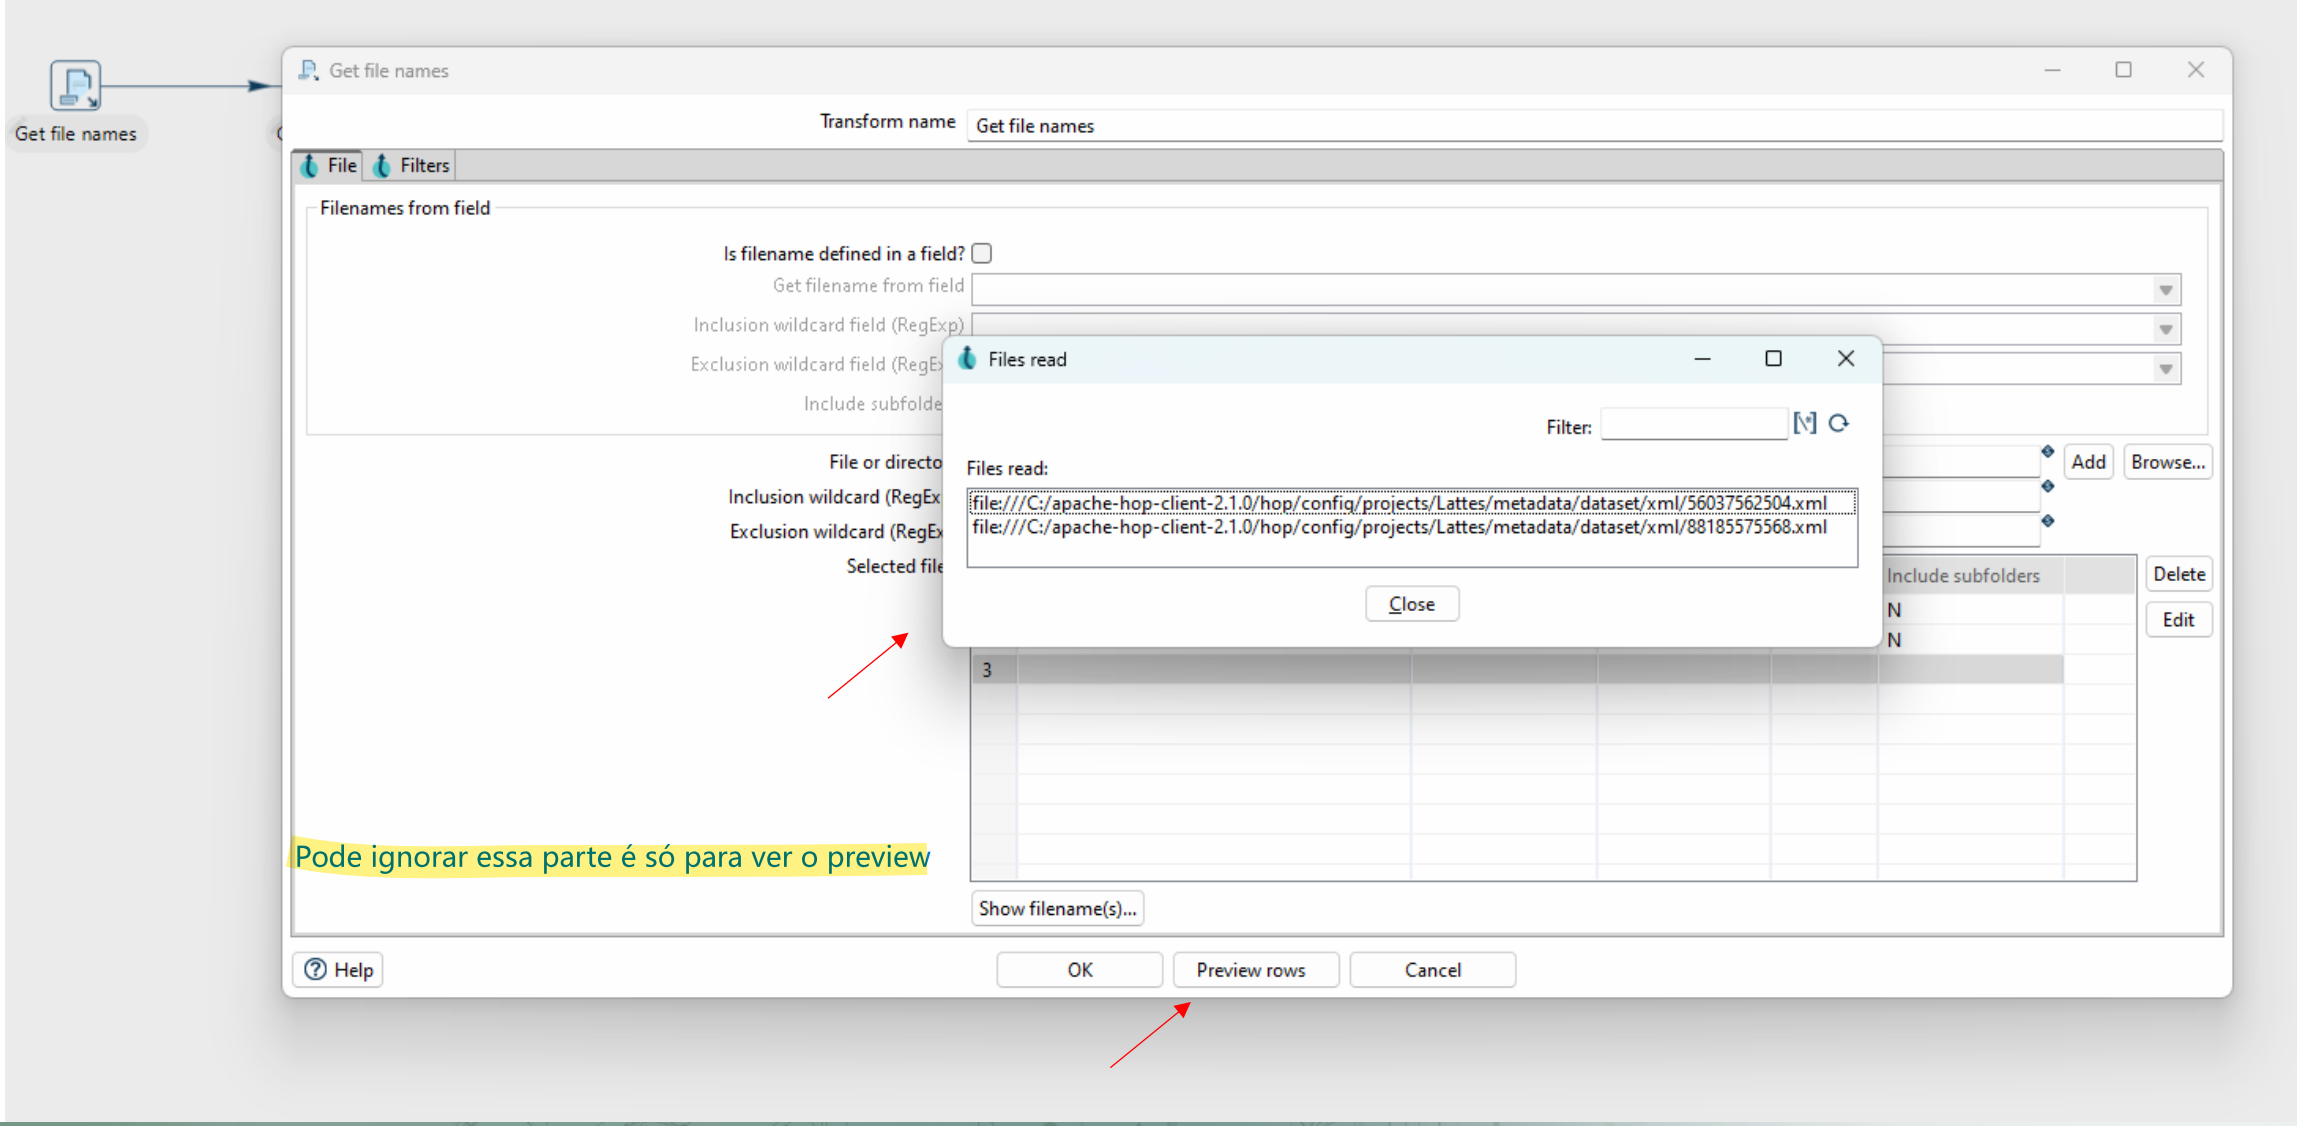

Pode ignorar essa parte é só para ver o preview

Projeto (Lattes) – Marcando a Opção para Pegar o Arquivo do Passo Anterior

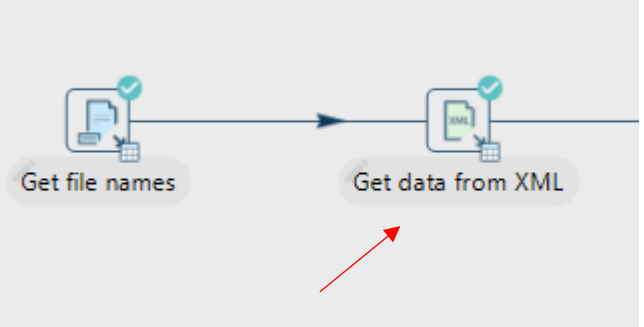

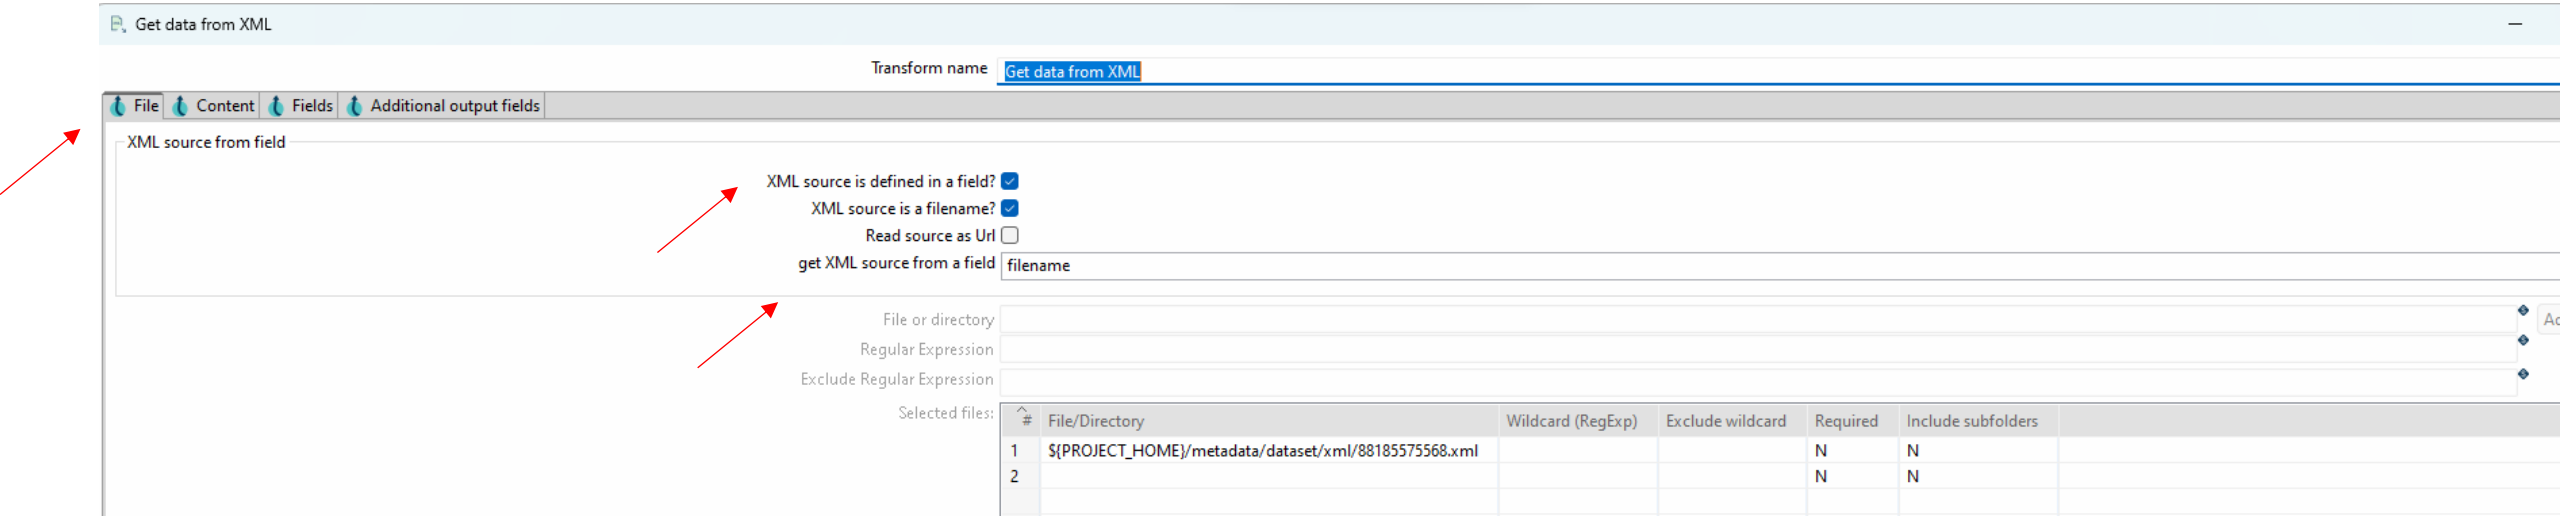

Projeto (Lattes) – Executando o Projeto

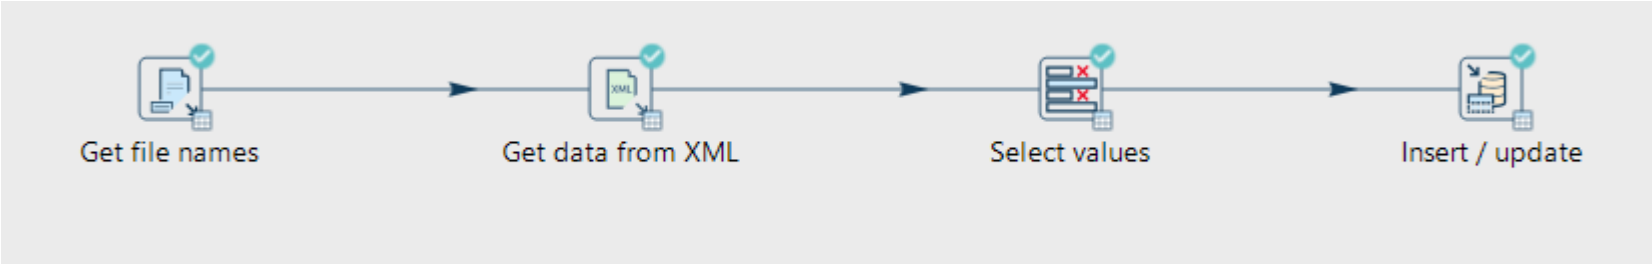

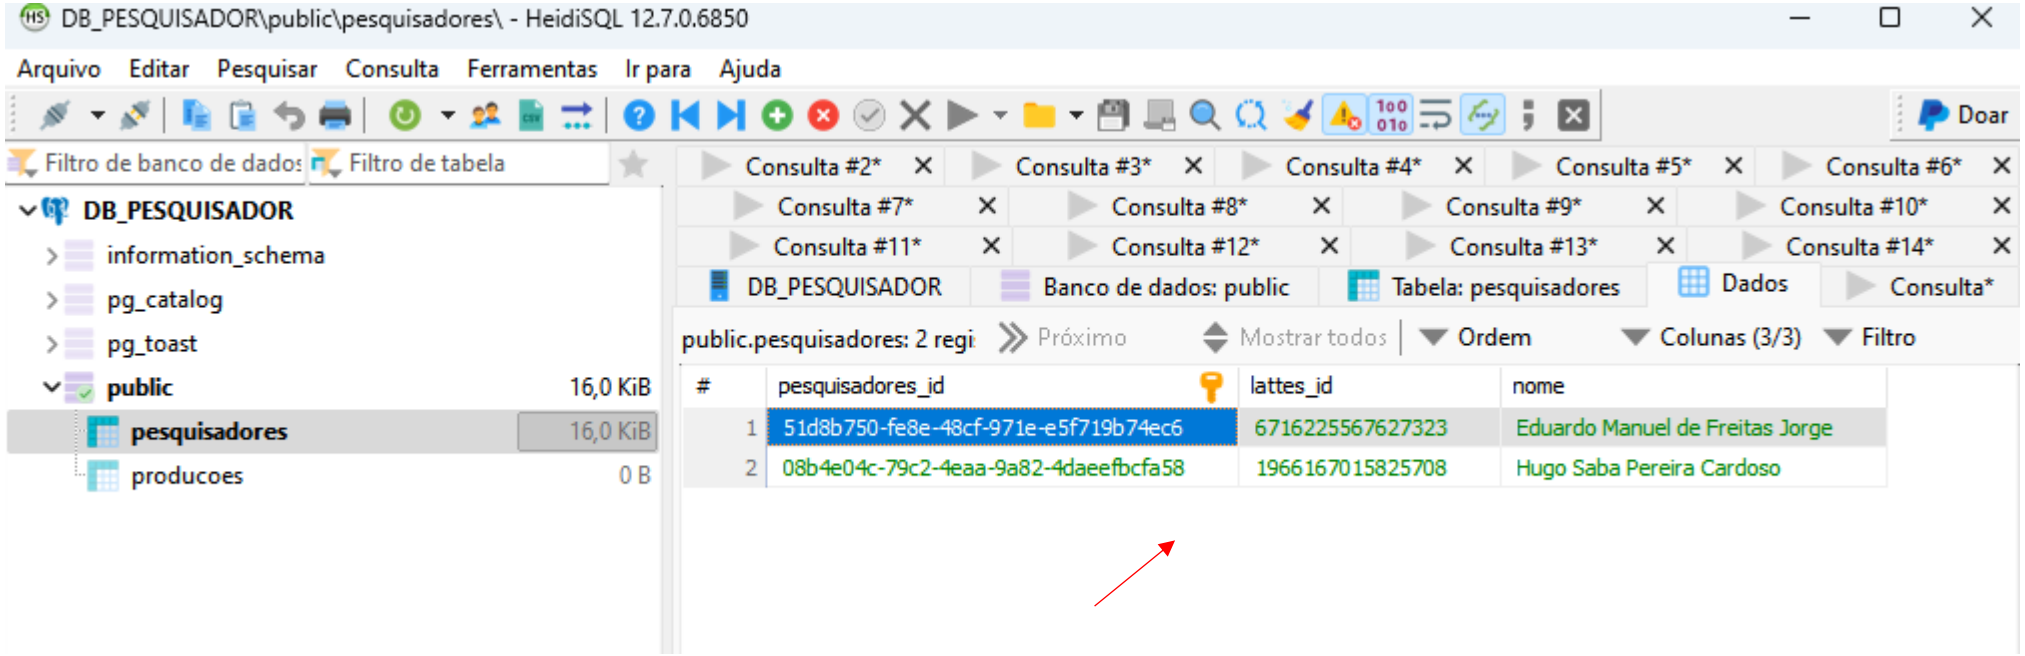

Exemplo III

Obtendo dados de Artigos Indexados de Vários Pesquisador do Lattes

Projeto (Lattes) – Dados de Artigos do XML

/CURRICULO-VITAE/PRODUCAO-BIBLIOGRAFICA/ARTIGOS-PUBLICADOS


```
  </DADOS-GERAIS>
▼<PRODUCAO-BIBLIOGRAFICA>
  ▶<TRABALHOS-EM-EVENTOS>
   ...
   </TRABALHOS-EM-EVENTOS>
  ▼<ARTIGOS-PUBLICADOS>
   ▼<ARTIGO-PUBLICADO SEQUENCIA-PRODUCAO="129" ORDEM-IMPORTANCIA="44">
      <DADOS-BASICOS-DO-ARTIGO NATUREZA="COMPLETO" TITULO-DO-ARTIGO="Correlation Between Transport and Occurrence of Dengue Cases in Bahia" ANO-DO-ARTIGO="2014" PAIS-DE-PUBLICACAO="" IDIOMA="Português" MEIO-DE-DIVULGACAO="VARIOS" HOME-PAGE-DO-TRABALHO="
      [http://davidpublishing.com/journals_info.asp?jId=2040]" FLAG-RELEVANCIA="NAO" DOI="" TITULO-DO-ARTIGO-INGLES="" FLAG-DIVULGACAO-CIENTIFICA="SIM"/>
      <DETALHAMENTO-DO-ARTIGO TITULO-DO-PERIODICO-OU-REVISTA="Journal of Communication and Computer" ISSN="15487709" VOLUME="11" FASCICULO="" SERIE="3" PAGINA-INICIAL="217" PAGINA-FINAL="221" LOCAL-DE-PUBLICACAO=""/>
      <AUTORES NOME-COMPLETO-DO-AUTOR="Hugo Saba Pereira Cardoso" NOME-PARA-CITACAO="SABA, Hugo" ORDEM-DE-AUTORIA="1" NRO-ID-CNPQ=""/>
      <AUTORES NOME-COMPLETO-DO-AUTOR="José Garcia Vivas Miranda" NOME-PARA-CITACAO="MIRANDA, J. G. V." ORDEM-DE-AUTORIA="2" NRO-ID-CNPQ="1608472474770322"/>
      <AUTORES NOME-COMPLETO-DO-AUTOR="Eduardo Manuel de Freitas Jorge" NOME-PARA-CITACAO="JORGE, E. M. F." ORDEM-DE-AUTORIA="3" NRO-ID-CNPQ="6716225567627323"/>
      <AUTORES NOME-COMPLETO-DO-AUTOR="Marcelo Albano Moret Simões Gonçalves" NOME-PARA-CITACAO="GONCALVES, M. A. M. S." ORDEM-DE-AUTORIA="4" NRO-ID-CNPQ="6903653527541008"/>
      <PALAVRAS-CHAVE PALAVRA-CHAVE-1="Aleatorização" PALAVRA-CHAVE-2="Correlação" PALAVRA-CHAVE-3="Transportes" PALAVRA-CHAVE-4="Dengue" PALAVRA-CHAVE-5="SOC" PALAVRA-CHAVE-6=""/>
     ▼<AREAS-DO-CONHECIMENTO>
        <AREA-DO-CONHECIMENTO-1 NOME-GRANDE-AREA-DO-CONHECIMENTO="CIENCIAS_SOCIAIS_APLICADAS" NOME-DA-AREA-DO-CONHECIMENTO="" NOME-DA-SUB-AREA-DO-CONHECIMENTO="" NOME-DA-ESPECIALIDADE=""/>
        <AREA-DO-CONHECIMENTO-2 NOME-GRANDE-AREA-DO-CONHECIMENTO="CIENCIAS_EXATAS_E_DA_TERRA" NOME-DA-AREA-DO-CONHECIMENTO="Ciência da Computação" NOME-DA-SUB-AREA-DO-CONHECIMENTO="" NOME-DA-ESPECIALIDADE=""/>
      </AREAS-DO-CONHECIMENTO>
    </ARTIGO-PUBLICADO>
   ▼<ARTIGO-PUBLICADO SEQUENCIA-PRODUCAO="132" ORDEM-IMPORTANCIA="45">
      <DADOS-BASICOS-DO-ARTIGO NATUREZA="COMPLETO" TITULO-DO-ARTIGO="Self-organized critical phenomenon as a" ANO-DO-ARTIGO="2014" PAIS-DE-PUBLICACAO="" IDIOMA="Inglês" MEIO-DE-DIVULGACAO="MEIO_DIGITAL" HOME-PAGE-DO-TRABALHO="
      [http://www.sciencedirect.com/science/article/pii/S0378437114005202]" FLAG-RELEVANCIA="NAO" DOI="10.1016/j.physa.2014.06.045" TITULO-DO-ARTIGO-INGLES="Self-organized critical phenomenon as a" FLAG-DIVULGACAO-CIENTIFICA="SIM"/>
      <DETALHAMENTO-DO-ARTIGO TITULO-DO-PERIODICO-OU-REVISTA="PHYSICA A-STATISTICAL MECHANICS AND ITS APPLICATIONS" ISSN="03784371" VOLUME="413" FASCICULO="" SERIE="" PAGINA-INICIAL="205" PAGINA-FINAL="211" LOCAL-DE-PUBLICACAO=""/>
      <AUTORES NOME-COMPLETO-DO-AUTOR="Hugo Saba Pereira Cardoso" NOME-PARA-CITACAO="SABA, H." ORDEM-DE-AUTORIA="1" NRO-ID-CNPQ=""/>
      <AUTORES NOME-COMPLETO-DO-AUTOR="MIRANDA, J.G.V." NOME-PARA-CITACAO="MIRANDA, J.G.V." ORDEM-DE-AUTORIA="2" NRO-ID-CNPQ="1608472474770322"/>
      <AUTORES NOME-COMPLETO-DO-AUTOR="MORET, M.A." NOME-PARA-CITACAO="MORET, M.A." ORDEM-DE-AUTORIA="3" NRO-ID-CNPQ="6903653527541008"/>
      <PALAVRAS-CHAVE PALAVRA-CHAVE-1="SOC" PALAVRA-CHAVE-2="Dengue" PALAVRA-CHAVE-3="Correlação" PALAVRA-CHAVE-4="Aleatorização" PALAVRA-CHAVE-5="" PALAVRA-CHAVE-6=""/>
     ▼<AREAS-DO-CONHECIMENTO>
        <AREA-DO-CONHECIMENTO-1 NOME-GRANDE-AREA-DO-CONHECIMENTO="CIENCIAS_SOCIAIS_APLICADAS" NOME-DA-AREA-DO-CONHECIMENTO="" NOME-DA-SUB-AREA-DO-CONHECIMENTO="" NOME-DA-ESPECIALIDADE=""/>
      </AREAS-DO-CONHECIMENTO>
    </ARTIGO-PUBLICADO>
   ▼<ARTIGO-PUBLICADO SEQUENCIA-PRODUCAO="135" ORDEM-IMPORTANCIA="2">
      <DADOS-BASICOS-DO-ARTIGO NATUREZA="COMPLETO" TITULO-DO-ARTIGO="Spatio-temporal correlation networks of dengue in the state of Bahia" ANO-DO-ARTIGO="2014" PAIS-DE-PUBLICACAO="" IDIOMA="Inglês" MEIO-DE-DIVULGACAO="MEIO_DIGITAL" HOME-PAGE-DO-TRABALHO="
      [http://www.biomedcentral.com/1471-2458/14/1085/email?from=email]" FLAG-RELEVANCIA="SIM" DOI="10.1186/1471-2458-14-1085" TITULO-DO-ARTIGO-INGLES="Spatio-temporal correlation networks of dengue in the state of Bahia" FLAG-DIVULGACAO-
      CIENTIFICA="SIM"/>
      <DETALHAMENTO-DO-ARTIGO TITULO-DO-PERIODICO-OU-REVISTA="BMC Public Health (Online)" ISSN="14712458" VOLUME="14" FASCICULO="" SERIE="1" PAGINA-INICIAL="1085" PAGINA-FINAL="" LOCAL-DE-PUBLICACAO=""/>
      <AUTORES NOME-COMPLETO-DO-AUTOR="Hugo Saba Pereira Cardoso" NOME-PARA-CITACAO="SABA, HUGO" ORDEM-DE-AUTORIA="1" NRO-ID-CNPQ=""/>
      <AUTORES NOME-COMPLETO-DO-AUTOR="VALE, VERA C" NOME-PARA-CITACAO="VALE, VERA C" ORDEM-DE-AUTORIA="2" NRO-ID-CNPQ=""/>
```

Projeto (Lattes) – Novo Pipeline Dados_Producoes_Pesquisadores_Varios.hlp copia do Dados_Pesquisador_Varios.hpl

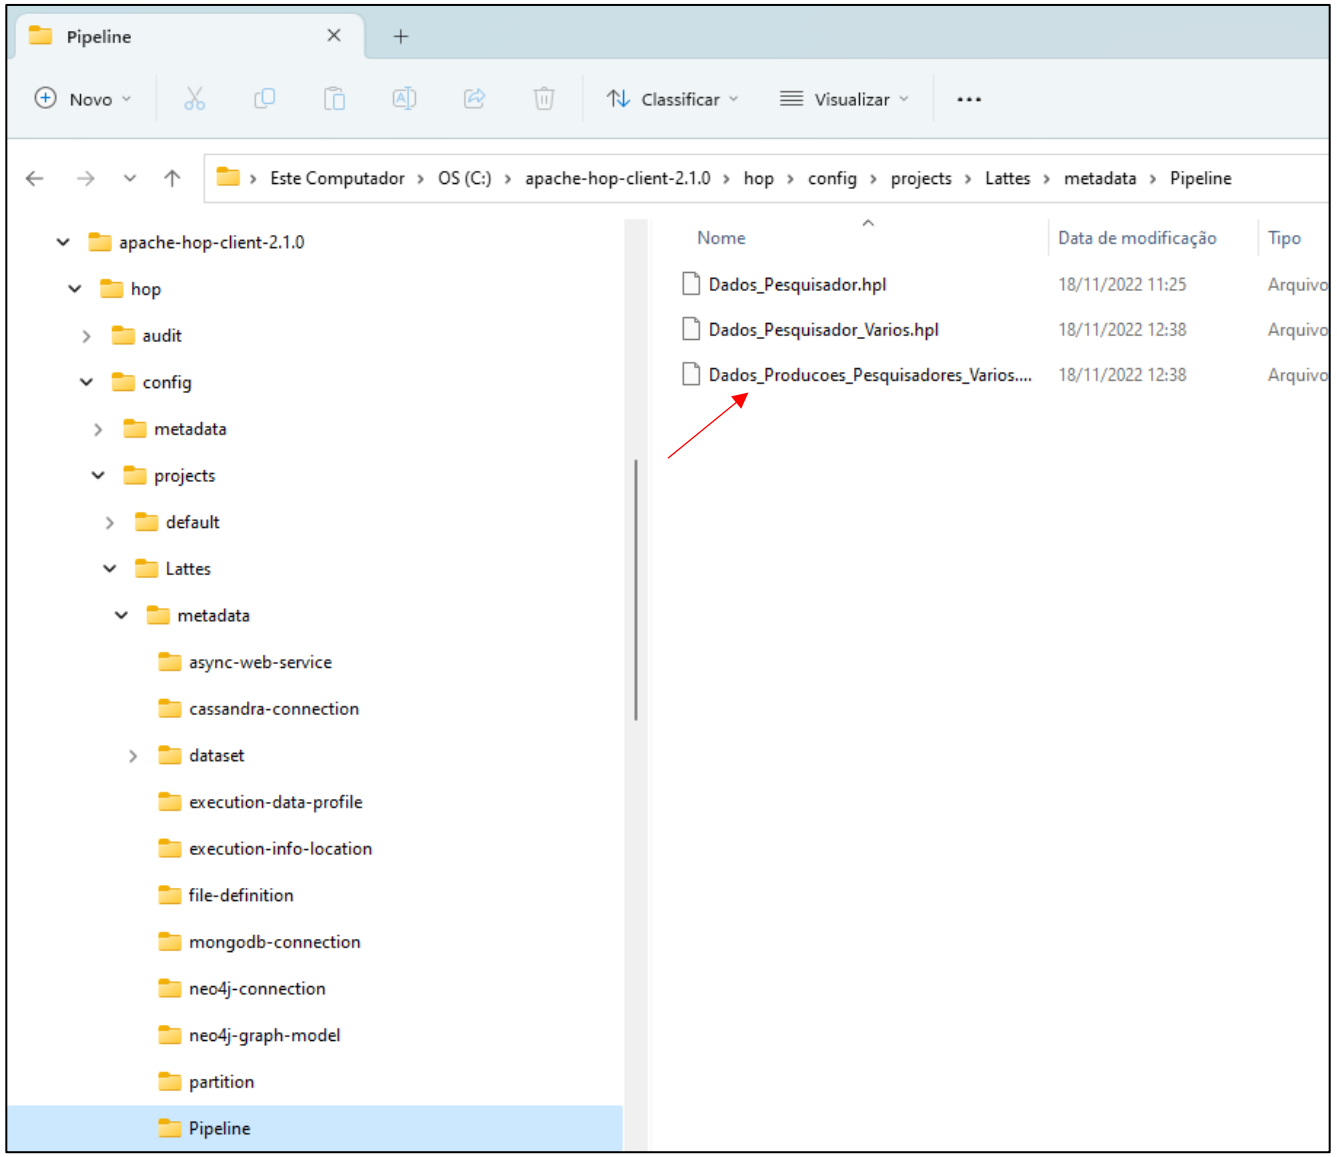

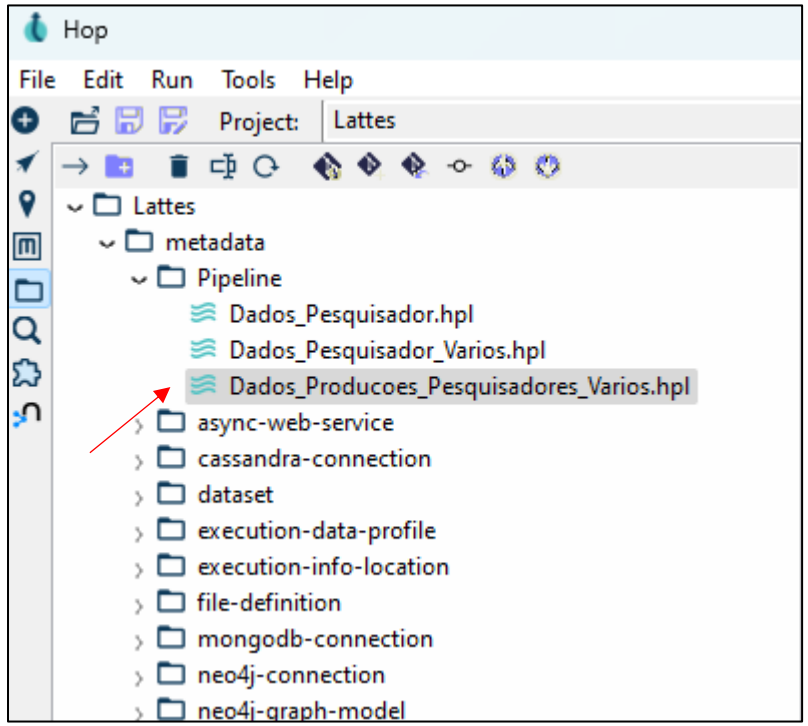

Projeto (Lattes) – Deletando um link entre etapas do fluxo

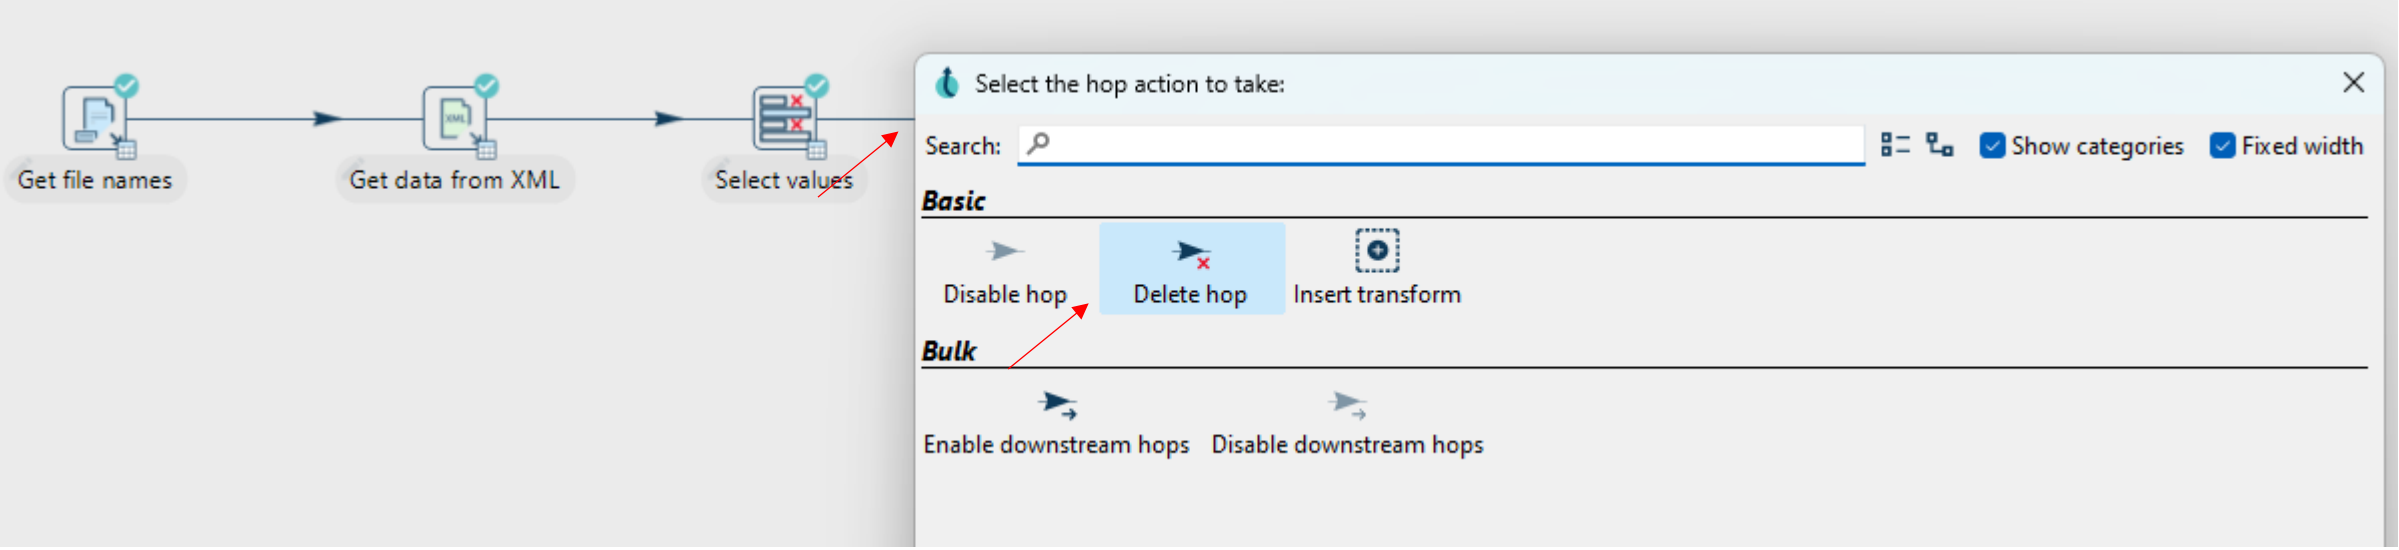

Projeto (Lattes) – Lendo Vários Arquivos

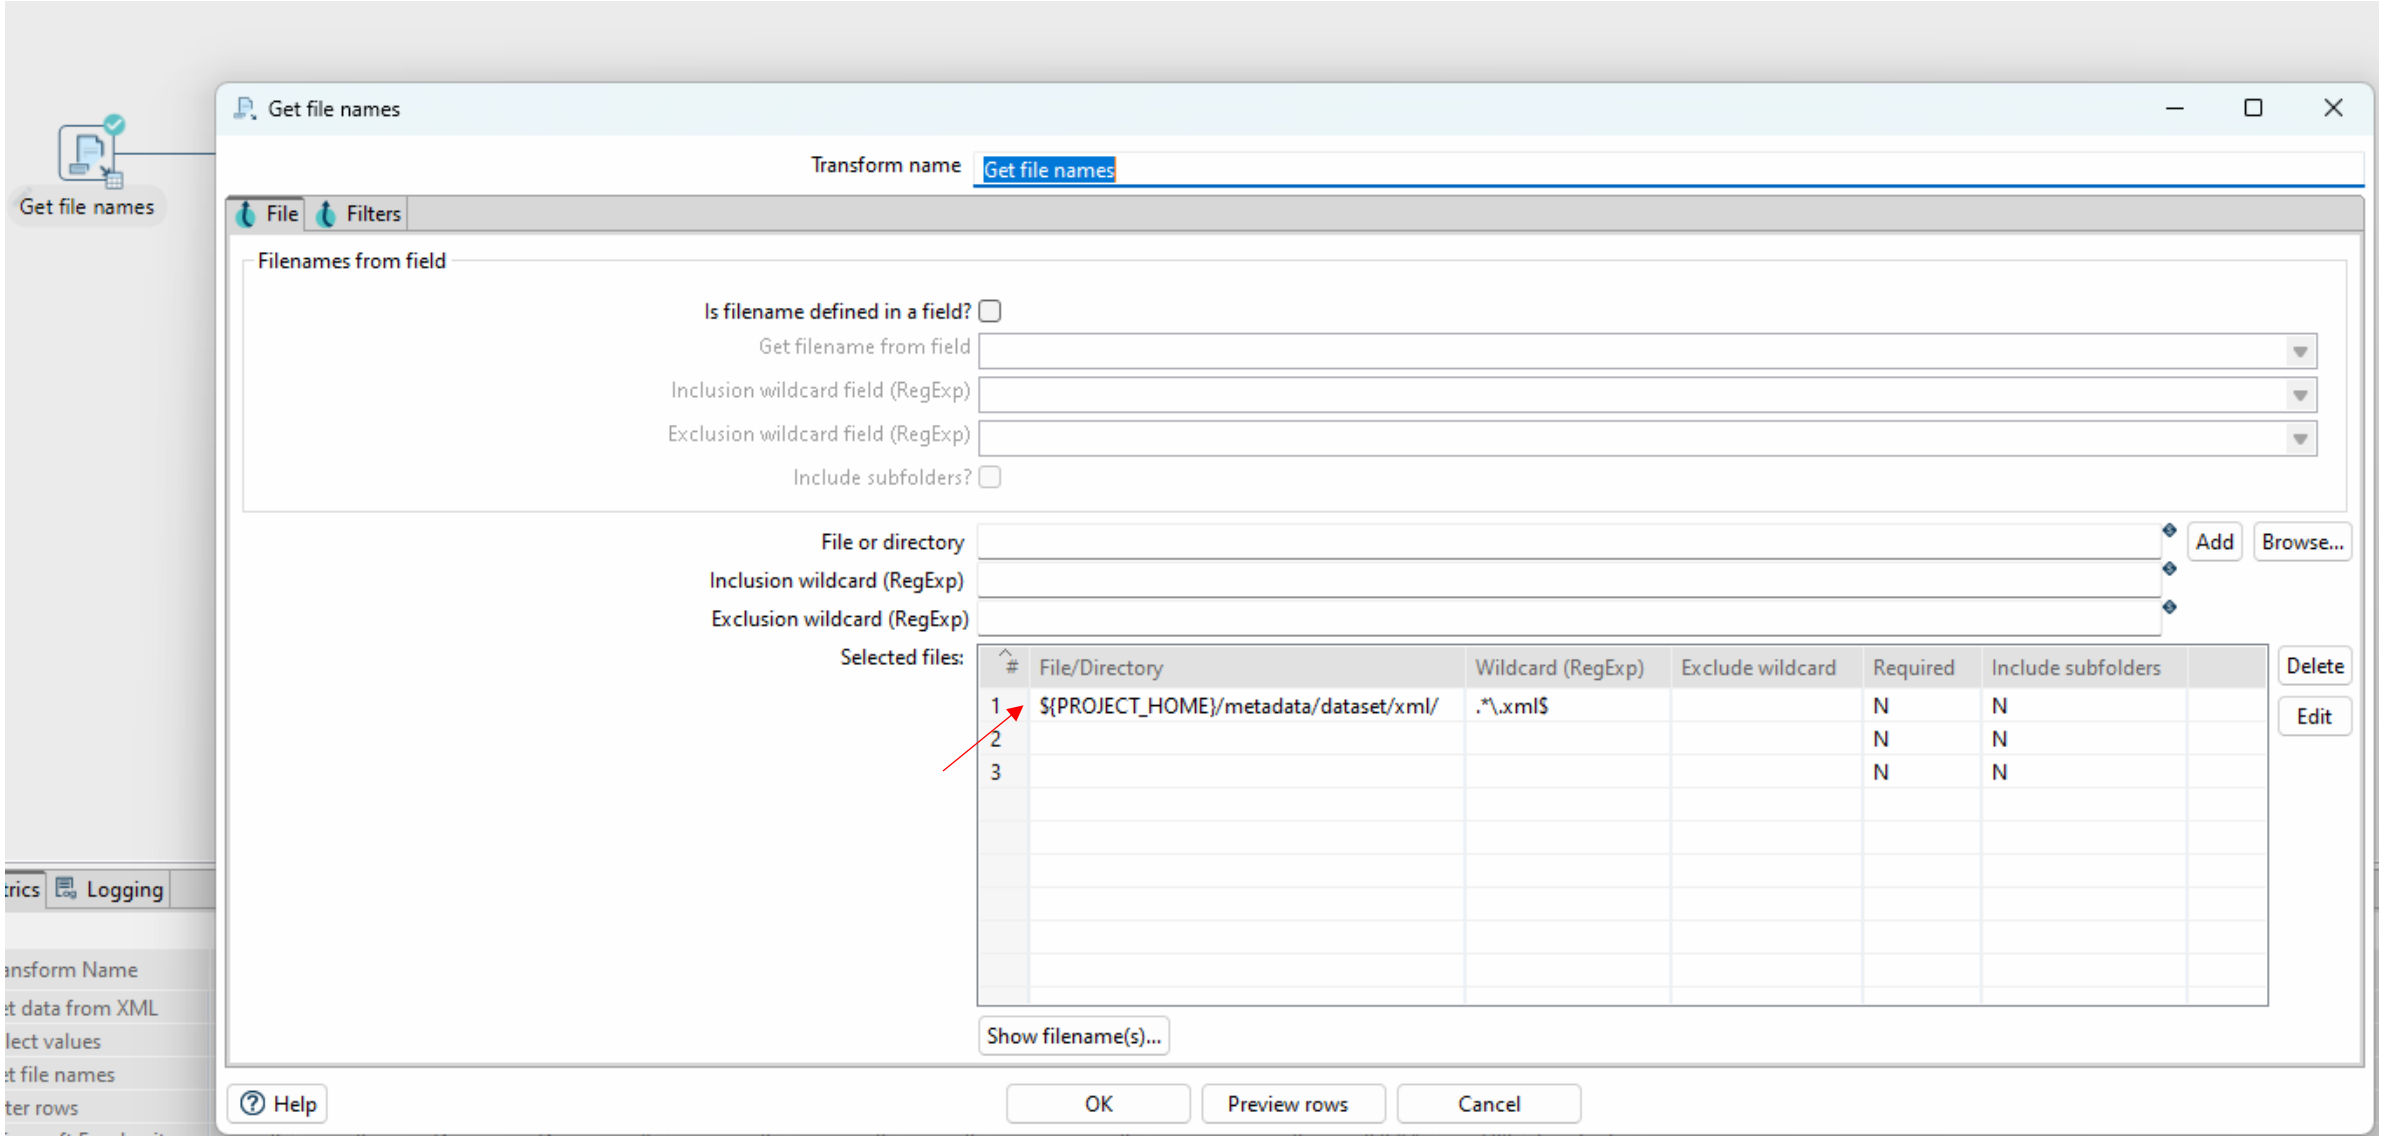

Projeto (Lattes) – Caminho XML para Dados do Artigo

/root/producaoBibliografica/item/item

Get data from XML

Transform name: Get data from XML

File | Content | Fields | Additional output fields

Settings

Loop XPath: /CURRICULO-VITAE/PRODUCAO-BIBLIOGRAFICA/ARTIGOS-PUBLICADOS/ARTIGO-PUBLICADO [Get XPath nodes]

Encoding: ~~x-iso-8859-1~~ usa o utf8 mesmo

Namespace aware? ☐

Ignore comments? ☐

Validate XML? ☐

Use token ☐

Ignore empty file ☐

Do not raise an error if no files ☑

Limit: 0

Prune path to handle large files:

Additional fields

Include filename in output? ☐ Filename fieldname

Rownum in output? ☐ Rownum fieldname

Add to result filename

Add files to result filesname ☐

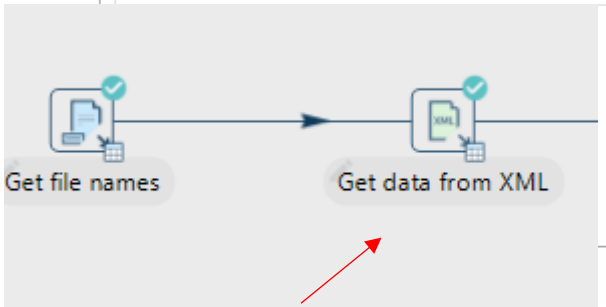

OK | Preview rows | Cancel

Projeto (Lattes) – Caminho XML para Dados do Artigo

Get data from XML

Transform name: Get data from XML

File | Content | Fields | Additional output fields

#	Name	XPath	Element	Result type	Type	Format	Length	Precision	Currency	Decimal	Group	Trim type	Repeat
1	TITULO-DO-ARTIGO	DADOS-BASICOS-DO-ARTIGO/@TITULO-DO-ARTIGO	Node	Value of	String							none	N
2	ANO-DO-ARTIGO	DADOS-BASICOS-DO-ARTIGO/@ANO-DO-ARTIGO	Node	Value of	String							none	N
3	ISSN	DETALHAMENTO-DO-ARTIGO/@ISSN											
4	IDLATTES	/CURRICULO-VITAE/@NUMERO-IDENTIFICADOR											

Get fields | Select fields from snippet

Help | OK | Preview rows | Cancel

Colocamos o idcnpq para fazer o link do artigo com os dados do pesquisador

Projeto (Lattes) – Etapa Select Values Produções

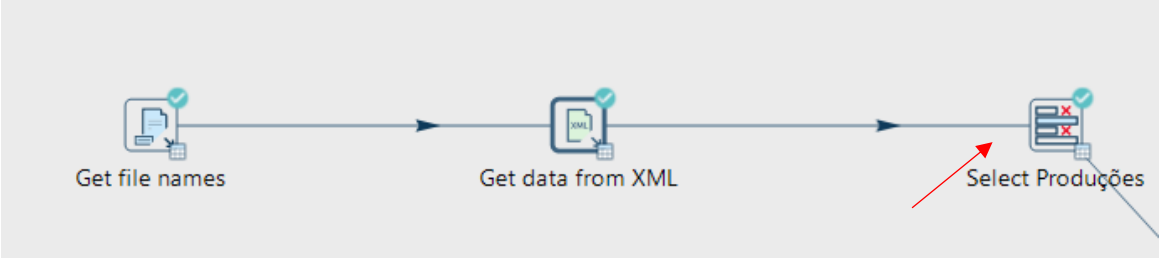

Select values

Transform name

Select & Alter | Remove | Meta-data

Fields :

#	Fieldname	Rename to	Length	Precision
1	TITULO-DO-ARTIGO			
2	ANO-DO-ARTIGO			
3	ISSN			
4	IDLATTES	idcnpq		

Include unspecified fields, ordered by name

Help | OK | Cancel

Select values

Transform name: Select Produções

Select & Alter | Remove | Meta-data

Fields to alter the meta-data for :

#	Fieldname	Rename to	Type	Length	Precision	Binary to Normal?	Format	Date Format Lenient?
1	ANO-DO-ARTIGO	anoartigo	Integer			N		N

Help

Projeto (Lattes) – Executando o Projeto

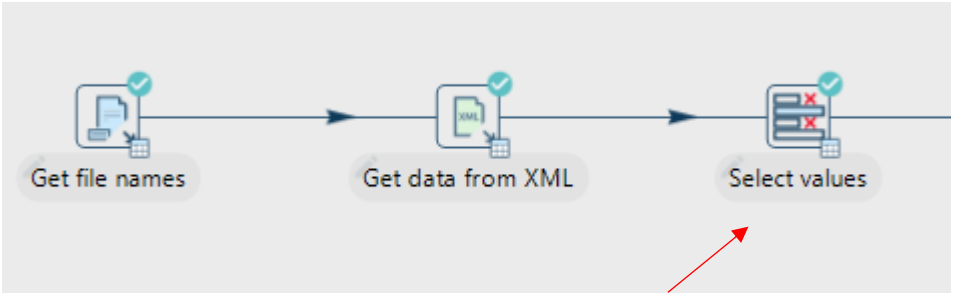

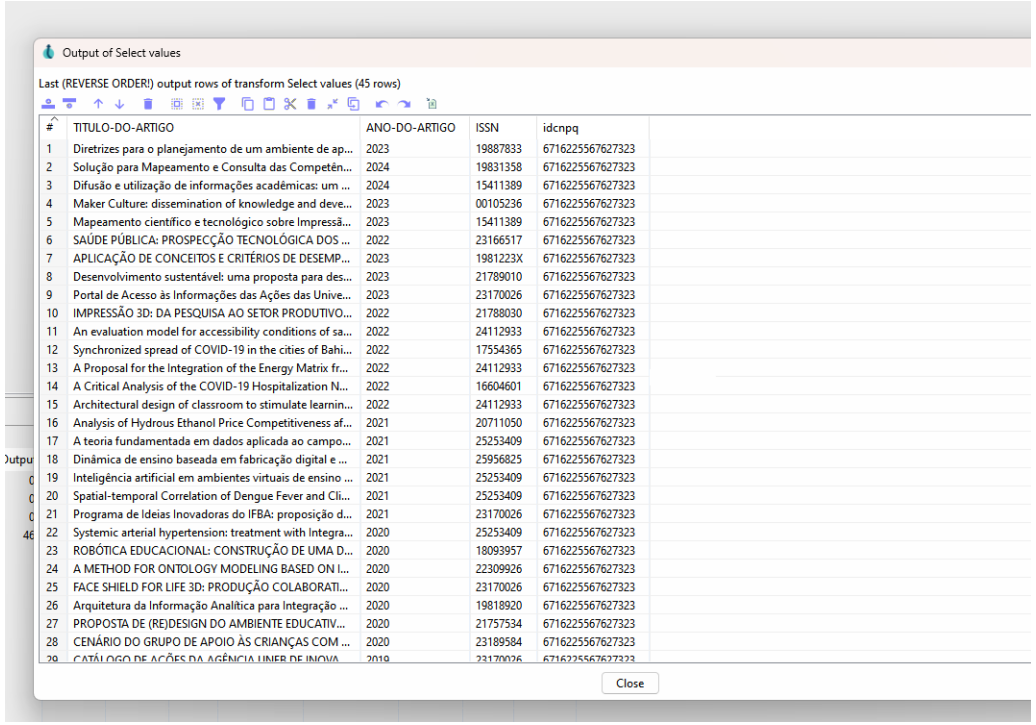

#	TITULO-DO-ARTIGO	ANO-DO-ARTIGO	ISSN	idcnpq
1	Diretrizes para o planejamento de um ambiente de ap...	2023	19887833	6716225567627323
2	Solução para Mapeamento e Consulta das Competên...	2024	19831358	6716225567627323
3	Difusão e utilização de informações acadêmicas: um ...	2024	15411389	6716225567627323
4	Maker Culture: dissemination of knowledge and deve...	2023	00105236	6716225567627323
5	Mapeamento científico e tecnológico sobre Impressã...	2023	15411389	6716225567627323
6	SAÚDE PÚBLICA: PROSPECÇÃO TECNOLÓGICA DOS ...	2022	23166517	6716225567627323
7	APLICAÇÃO DE CONCEITOS E CRITÉRIOS DE DESEMP...	2023	1981223X	6716225567627323
8	Desenvolvimento sustentável: uma proposta para des...	2023	21789010	6716225567627323
9	Portal de Acesso às Informações das Ações das Unive...	2023	23170026	6716225567627323
10	IMPRESSÃO 3D: DA PESQUISA AO SETOR PRODUTIVO...	2022	21788030	6716225567627323
11	An evaluation model for accessibility conditions of sa...	2022	24112933	6716225567627323
12	Synchronized spread of COVID-19 in the cities of Bahi...	2022	17554365	6716225567627323
13	A Proposal for the Integration of the Energy Matrix fr...	2022	24112933	6716225567627323
14	A Critical Analysis of the COVID-19 Hospitalization N...	2022	16604601	6716225567627323
15	Architectural design of classroom to stimulate learnin...	2022	24112933	6716225567627323
16	Analysis of Hydrous Ethanol Price Competitiveness af...	2021	20711050	6716225567627323
17	A teoria fundamentada em dados aplicada ao campo...	2021	25253409	6716225567627323
18	Dinâmica de ensino baseada em fabricação digital e ...	2021	25956825	6716225567627323
19	Inteligência artificial em ambientes virtuais de ensino ...	2021	25253409	6716225567627323
20	Spatial-temporal Correlation of Dengue Fever and Cli...	2021	25253409	6716225567627323
21	Programa de Ideias Inovadoras do IFBA: proposição d...	2021	23170026	6716225567627323
22	Systemic arterial hypertension: treatment with Integra...	2020	25253409	6716225567627323
23	ROBÓTICA EDUCACIONAL: CONSTRUÇÃO DE UMA D...	2020	18093957	6716225567627323
24	A METHOD FOR ONTOLOGY MODELING BASED ON I...	2020	22309926	6716225567627323
25	FACE SHIELD FOR LIFE 3D: PRODUÇÃO COLABORATI...	2020	23170026	6716225567627323
26	Arquitetura da Informação Analítica para Integração ...	2020	19818920	6716225567627323
27	PROPOSTA DE (RE)DESIGN DO AMBIENTE EDUCATIV...	2020	21757534	6716225567627323
28	CENÁRIO DO GRUPO DE APOIO ÀS CRIANÇAS COM ...	2020	23189584	6716225567627323
29	CATÁLOGO DE AÇÕES DA AGÊNCIA UNEB DE INOVA...	2019	23170026	6716225567627323

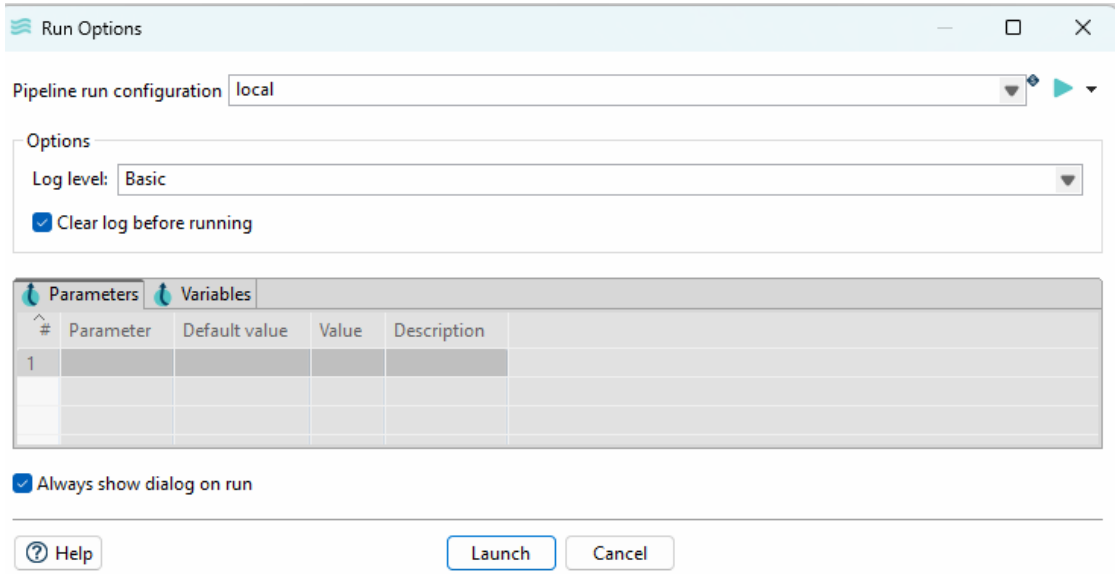

Projeto (Lattes) – Ordenando pela chave do id_lattes para fazer uma junção

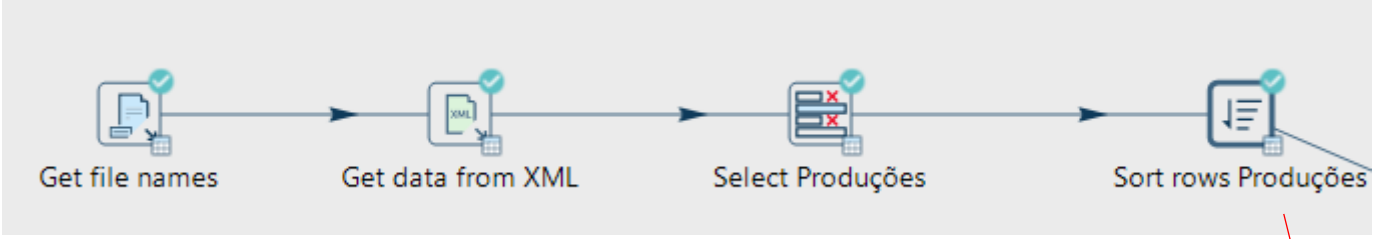

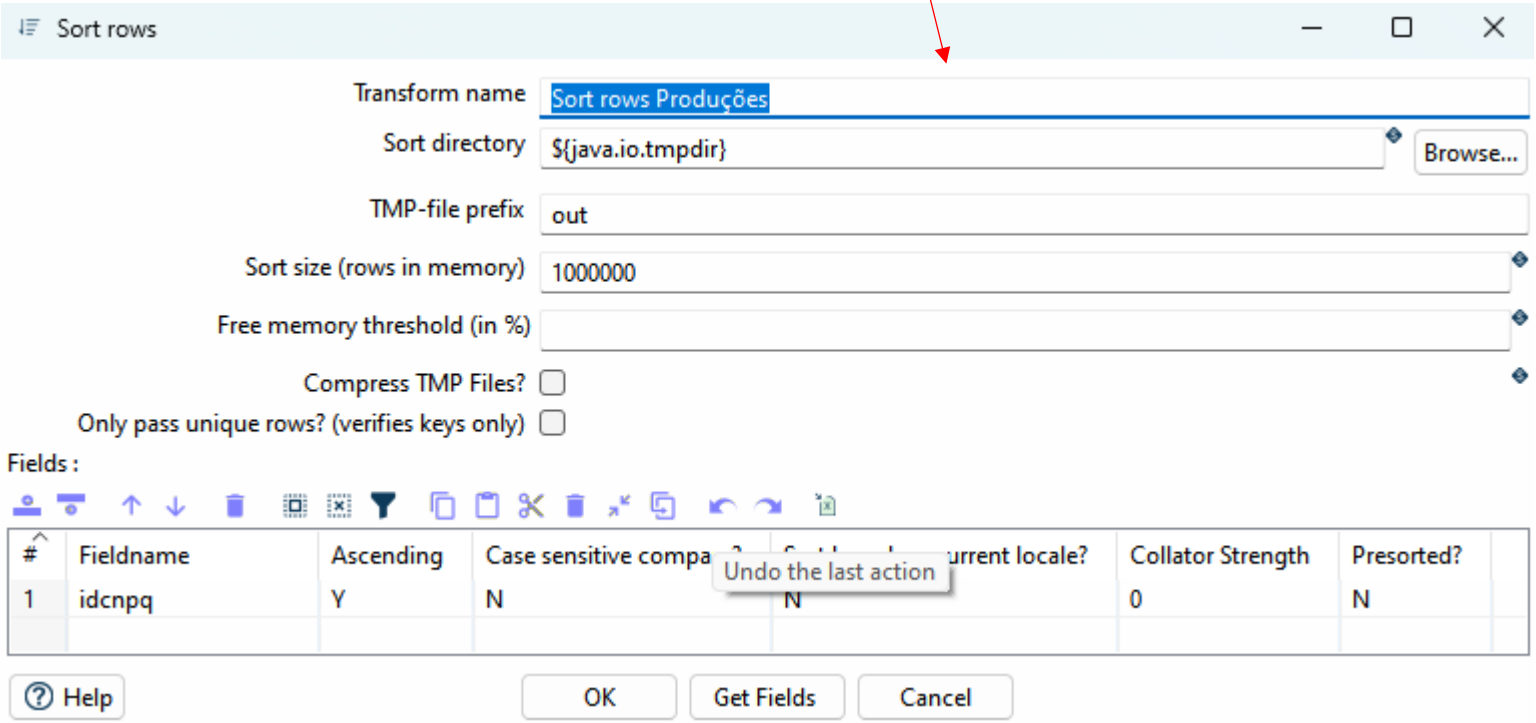

Projeto (Lattes) – Obtendo a Tabela de Pesquisadores para fazer a junção com as Produções

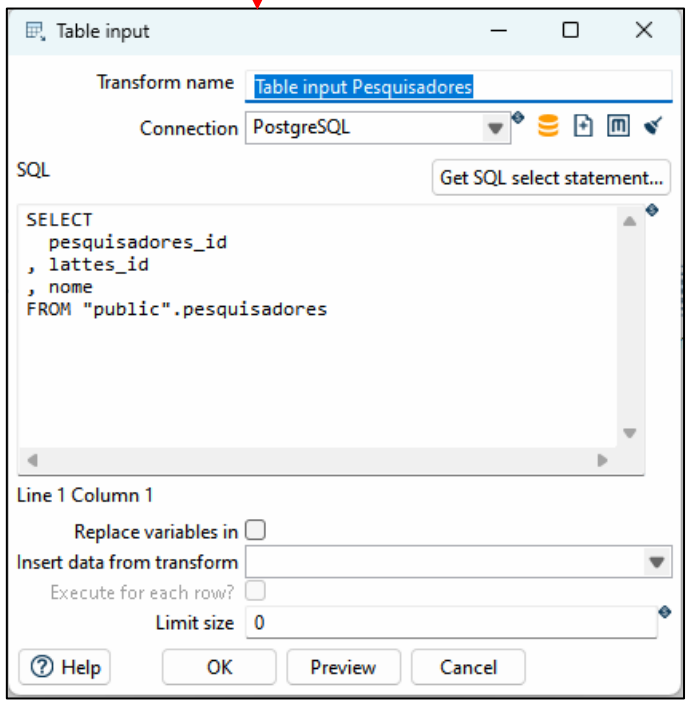

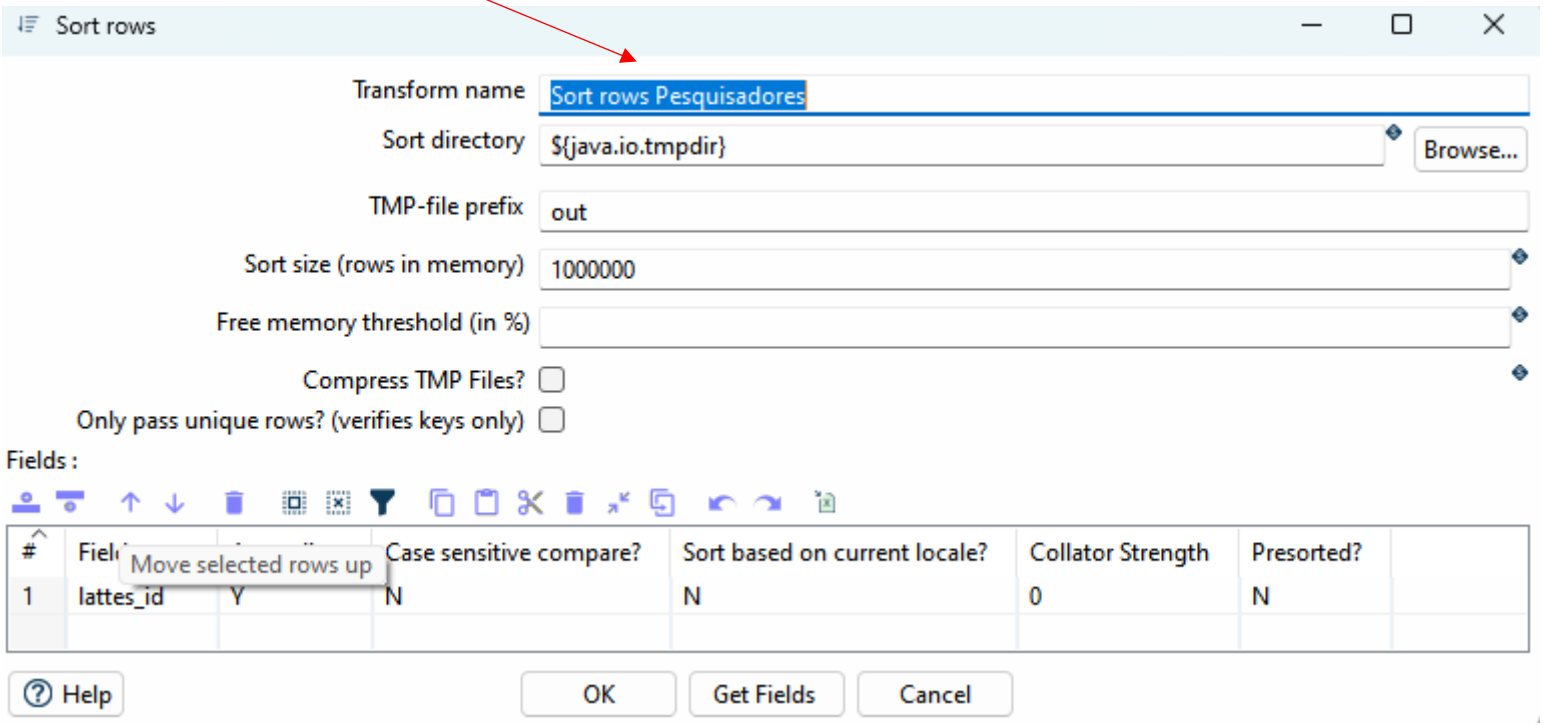

Projeto (Lattes) – Fazendo a junção das tabelas pelo id_lattes

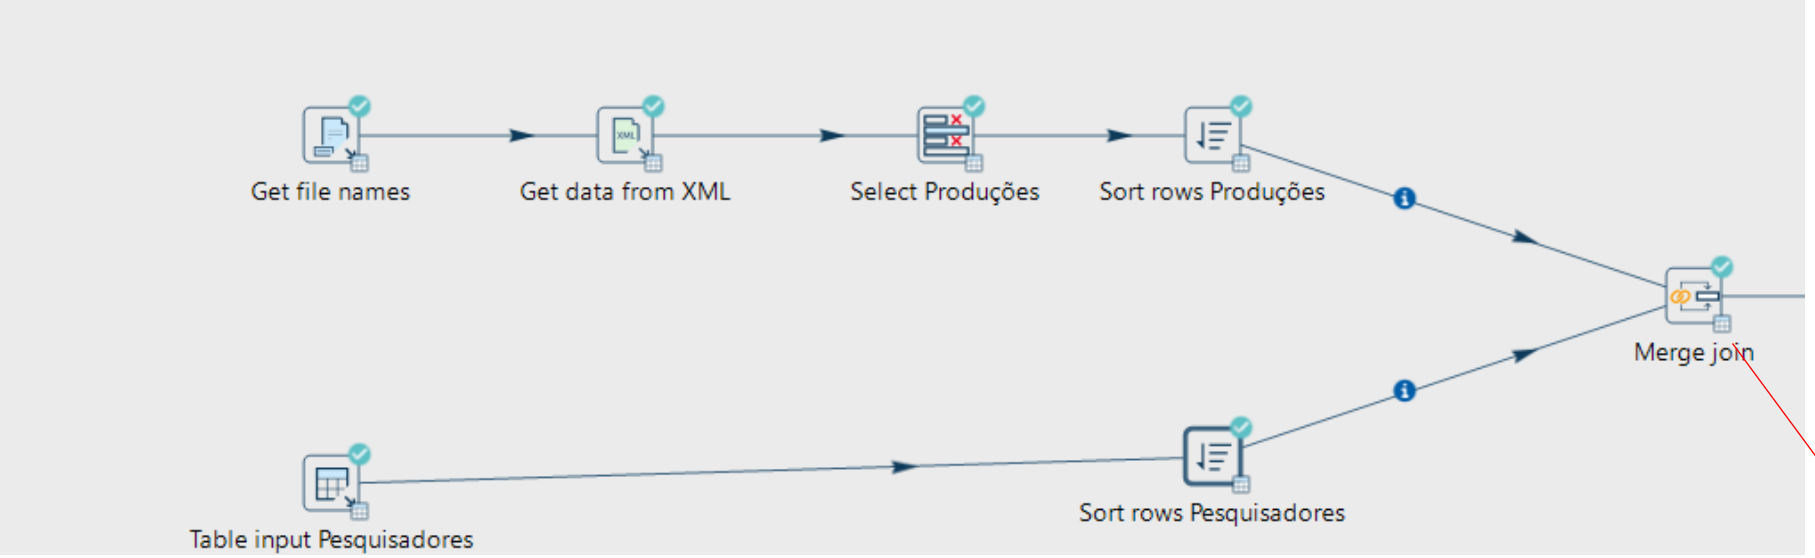

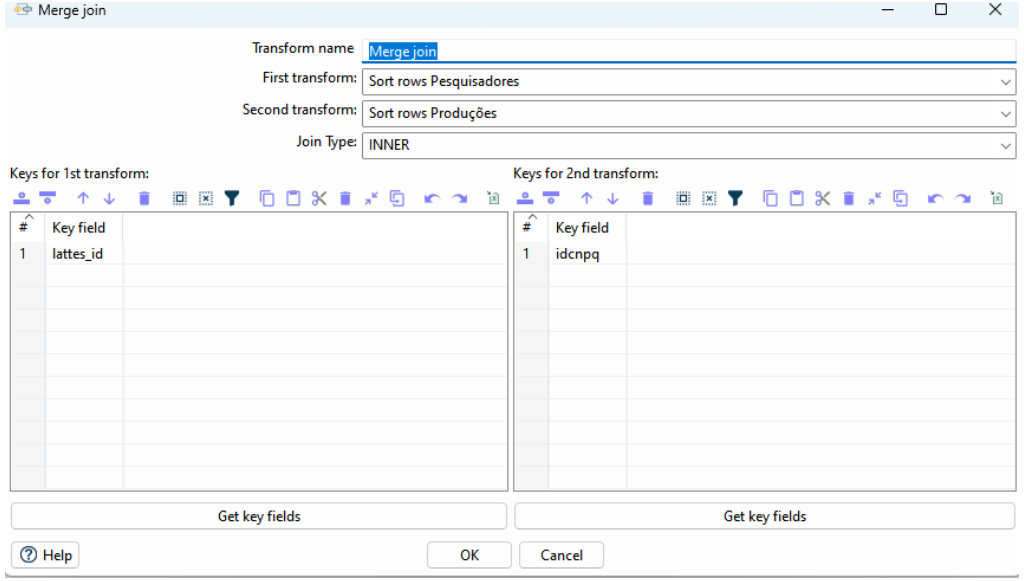

Projeto (Lattes) – Inserindo na Tabela de Produções

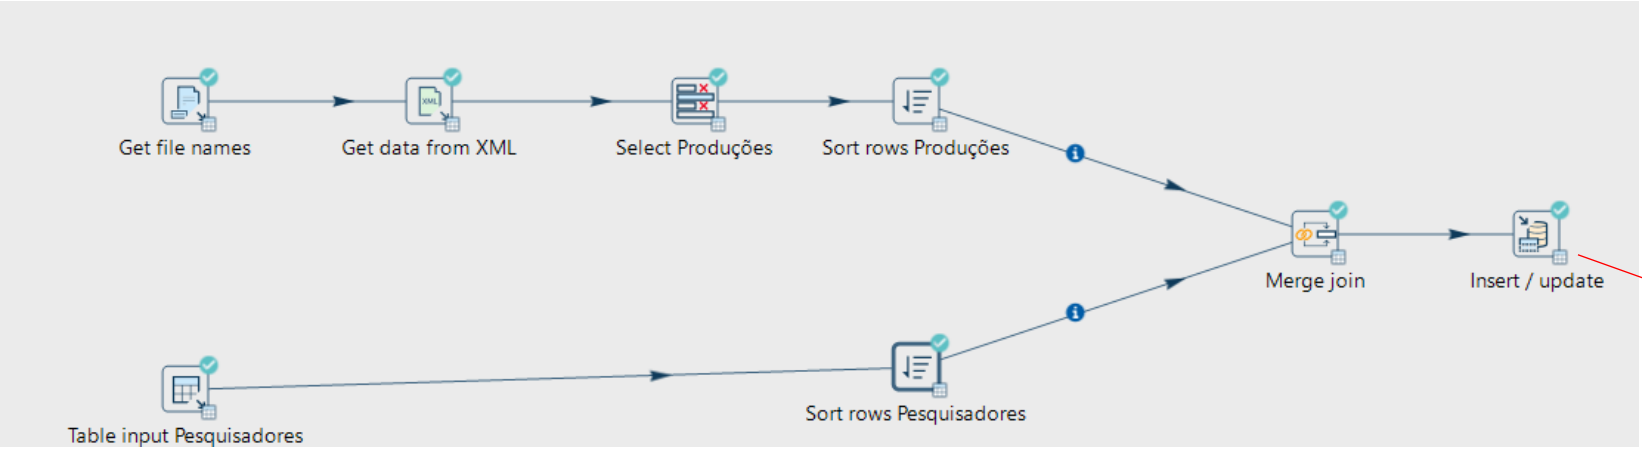

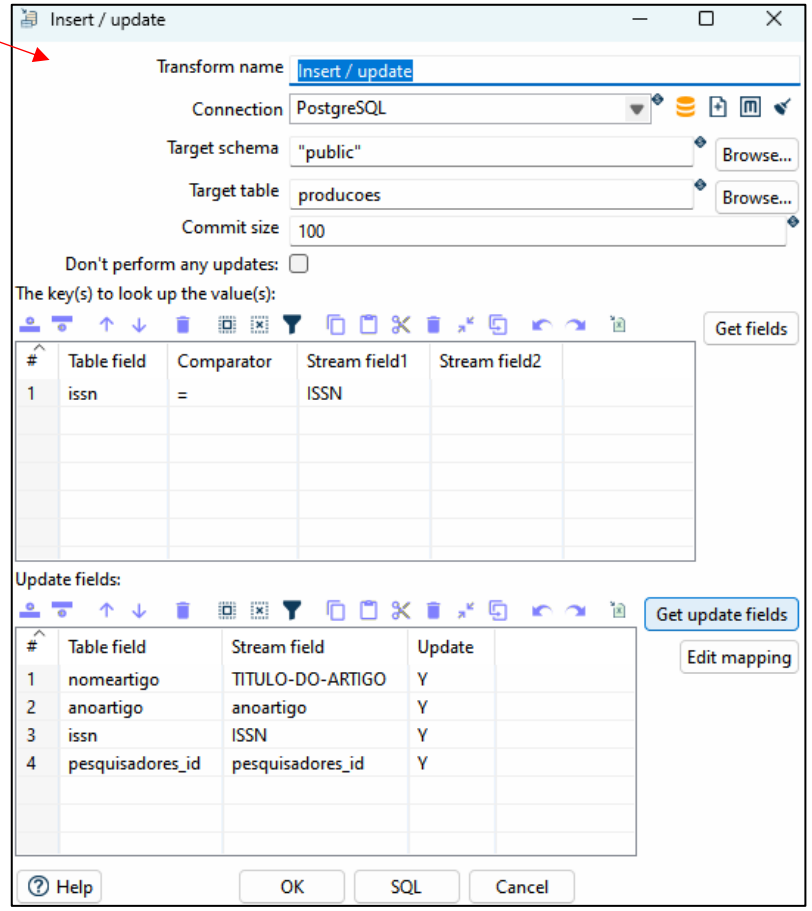

Projeto (Lattes) – Executando

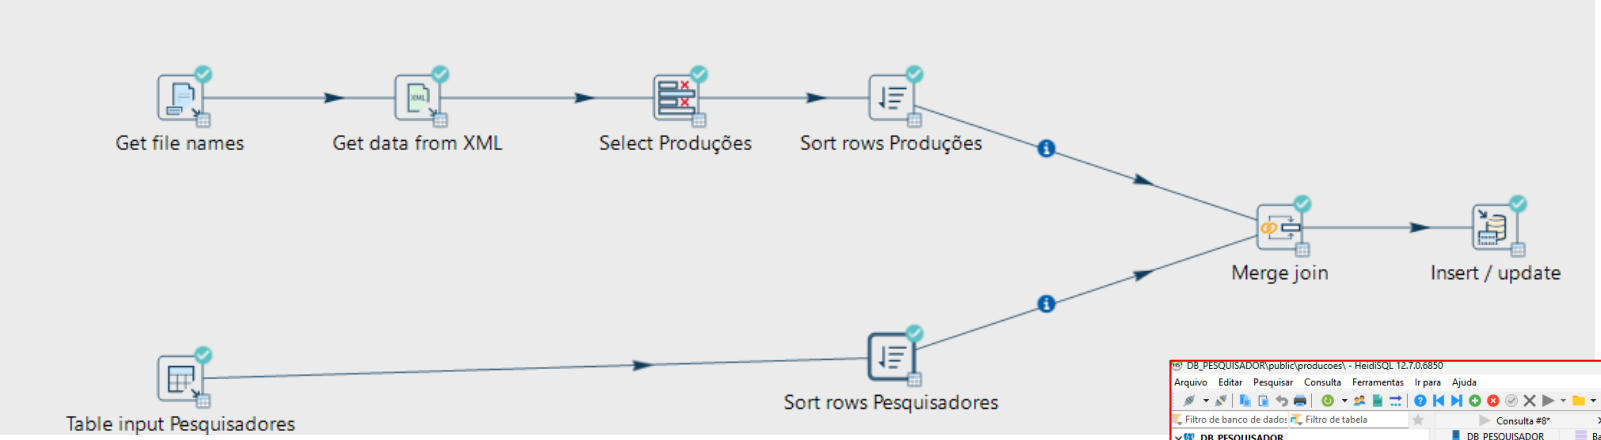

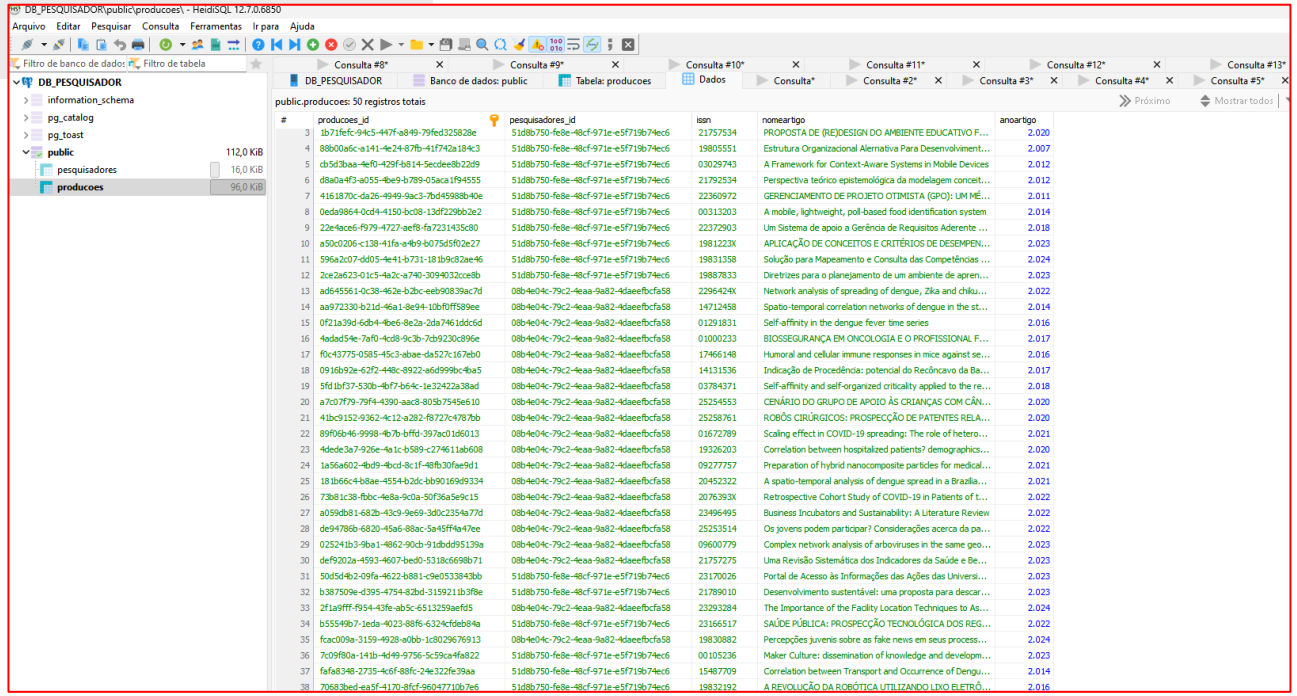

Projeto (Lattes) – Criando Workflow

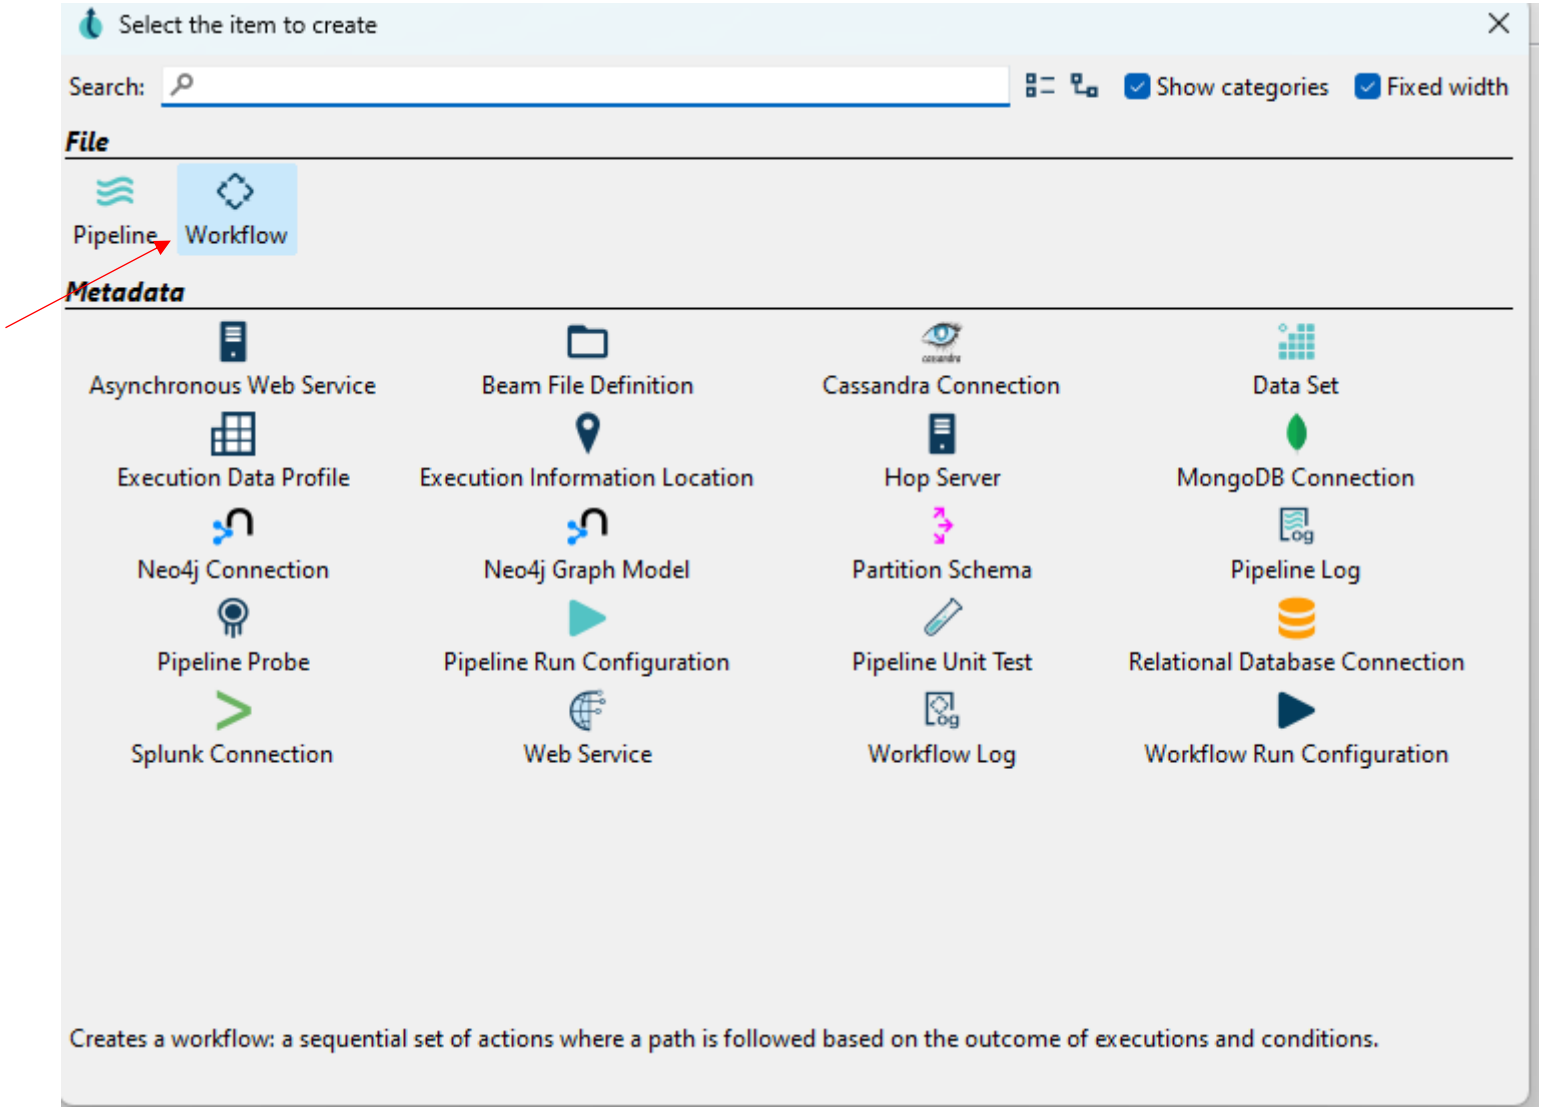

Projeto (Lattes) – Criando Workflow

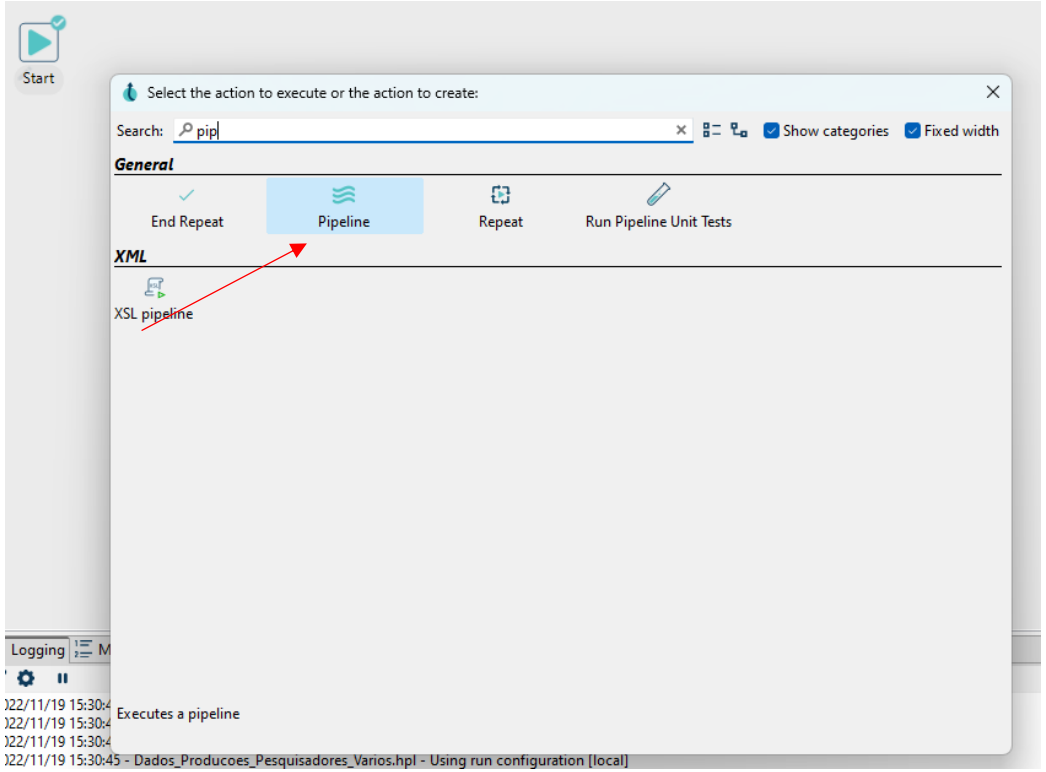

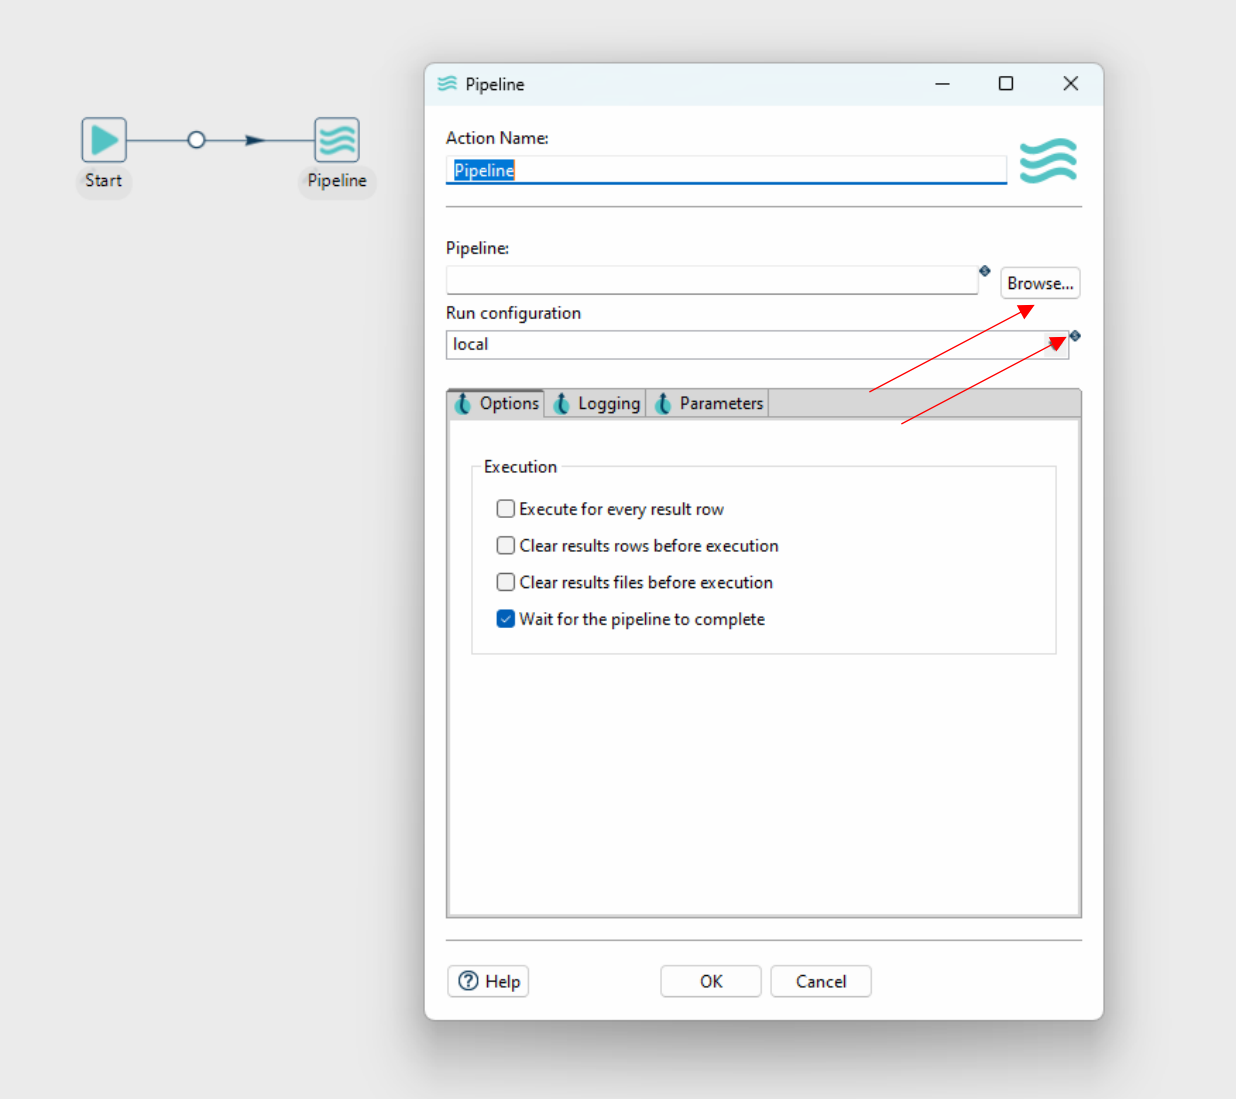

Projeto (Lattes) – Criando Workflow

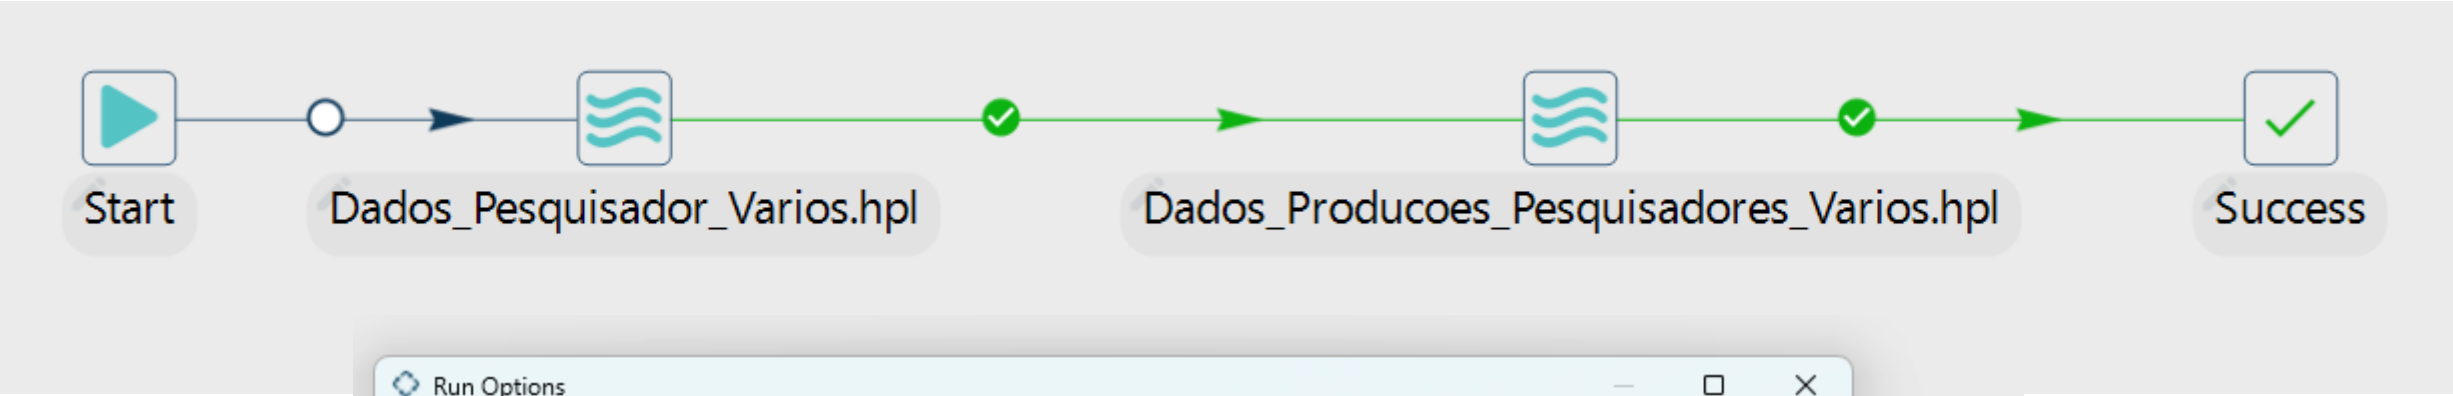

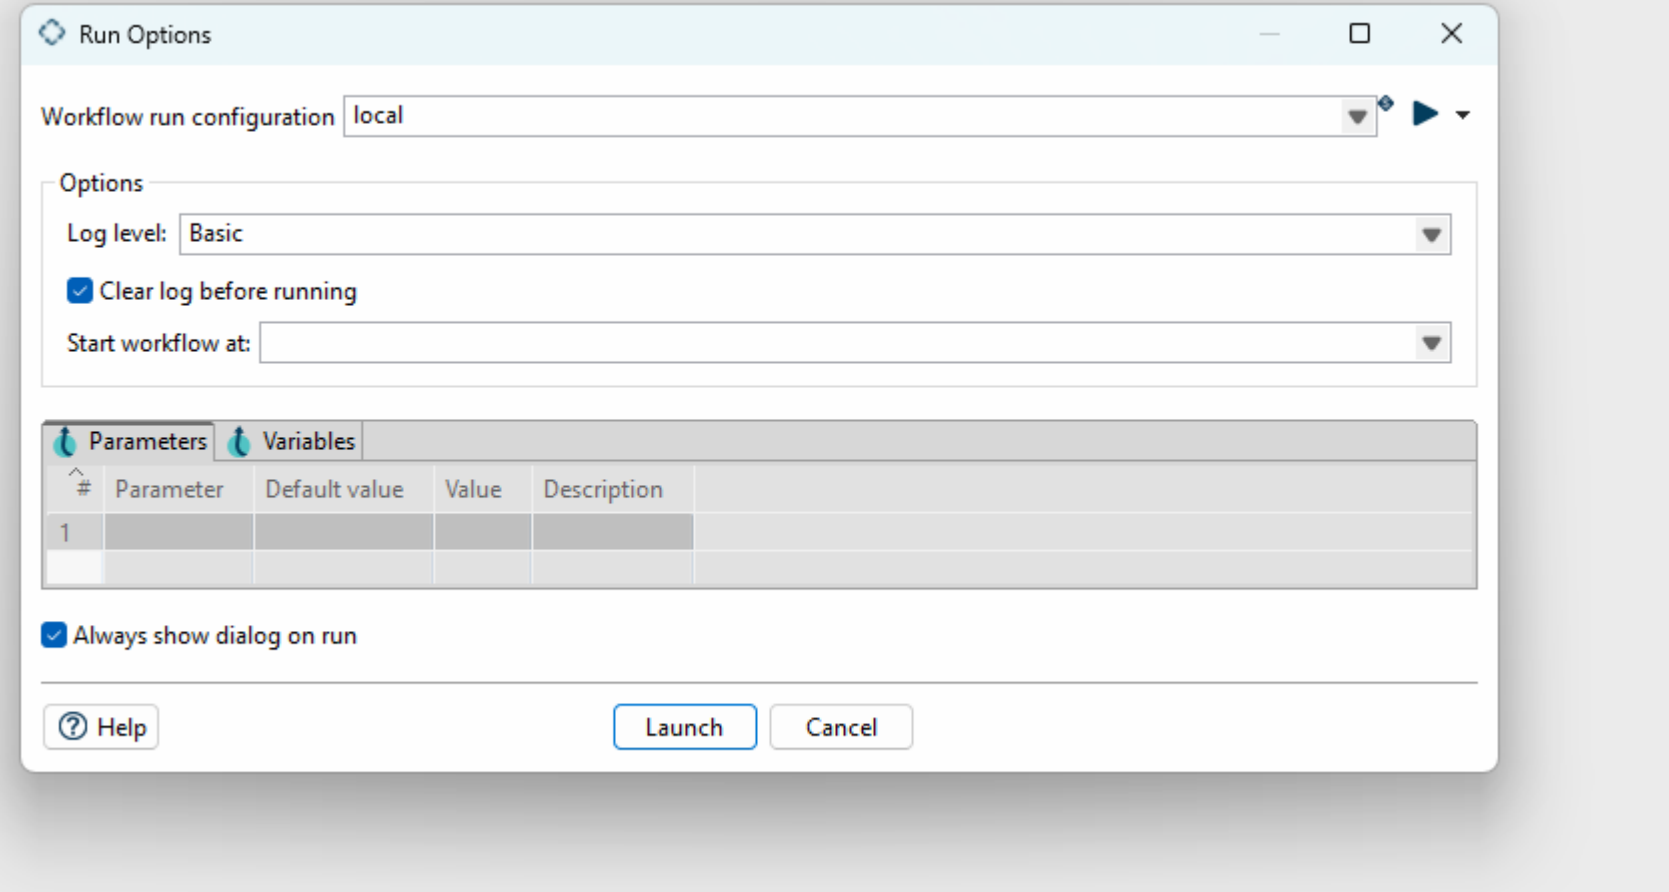

EU SOU DO SAMBA

Power BI

Exibindo dados

Conectando o PostgreSQL no Power bi

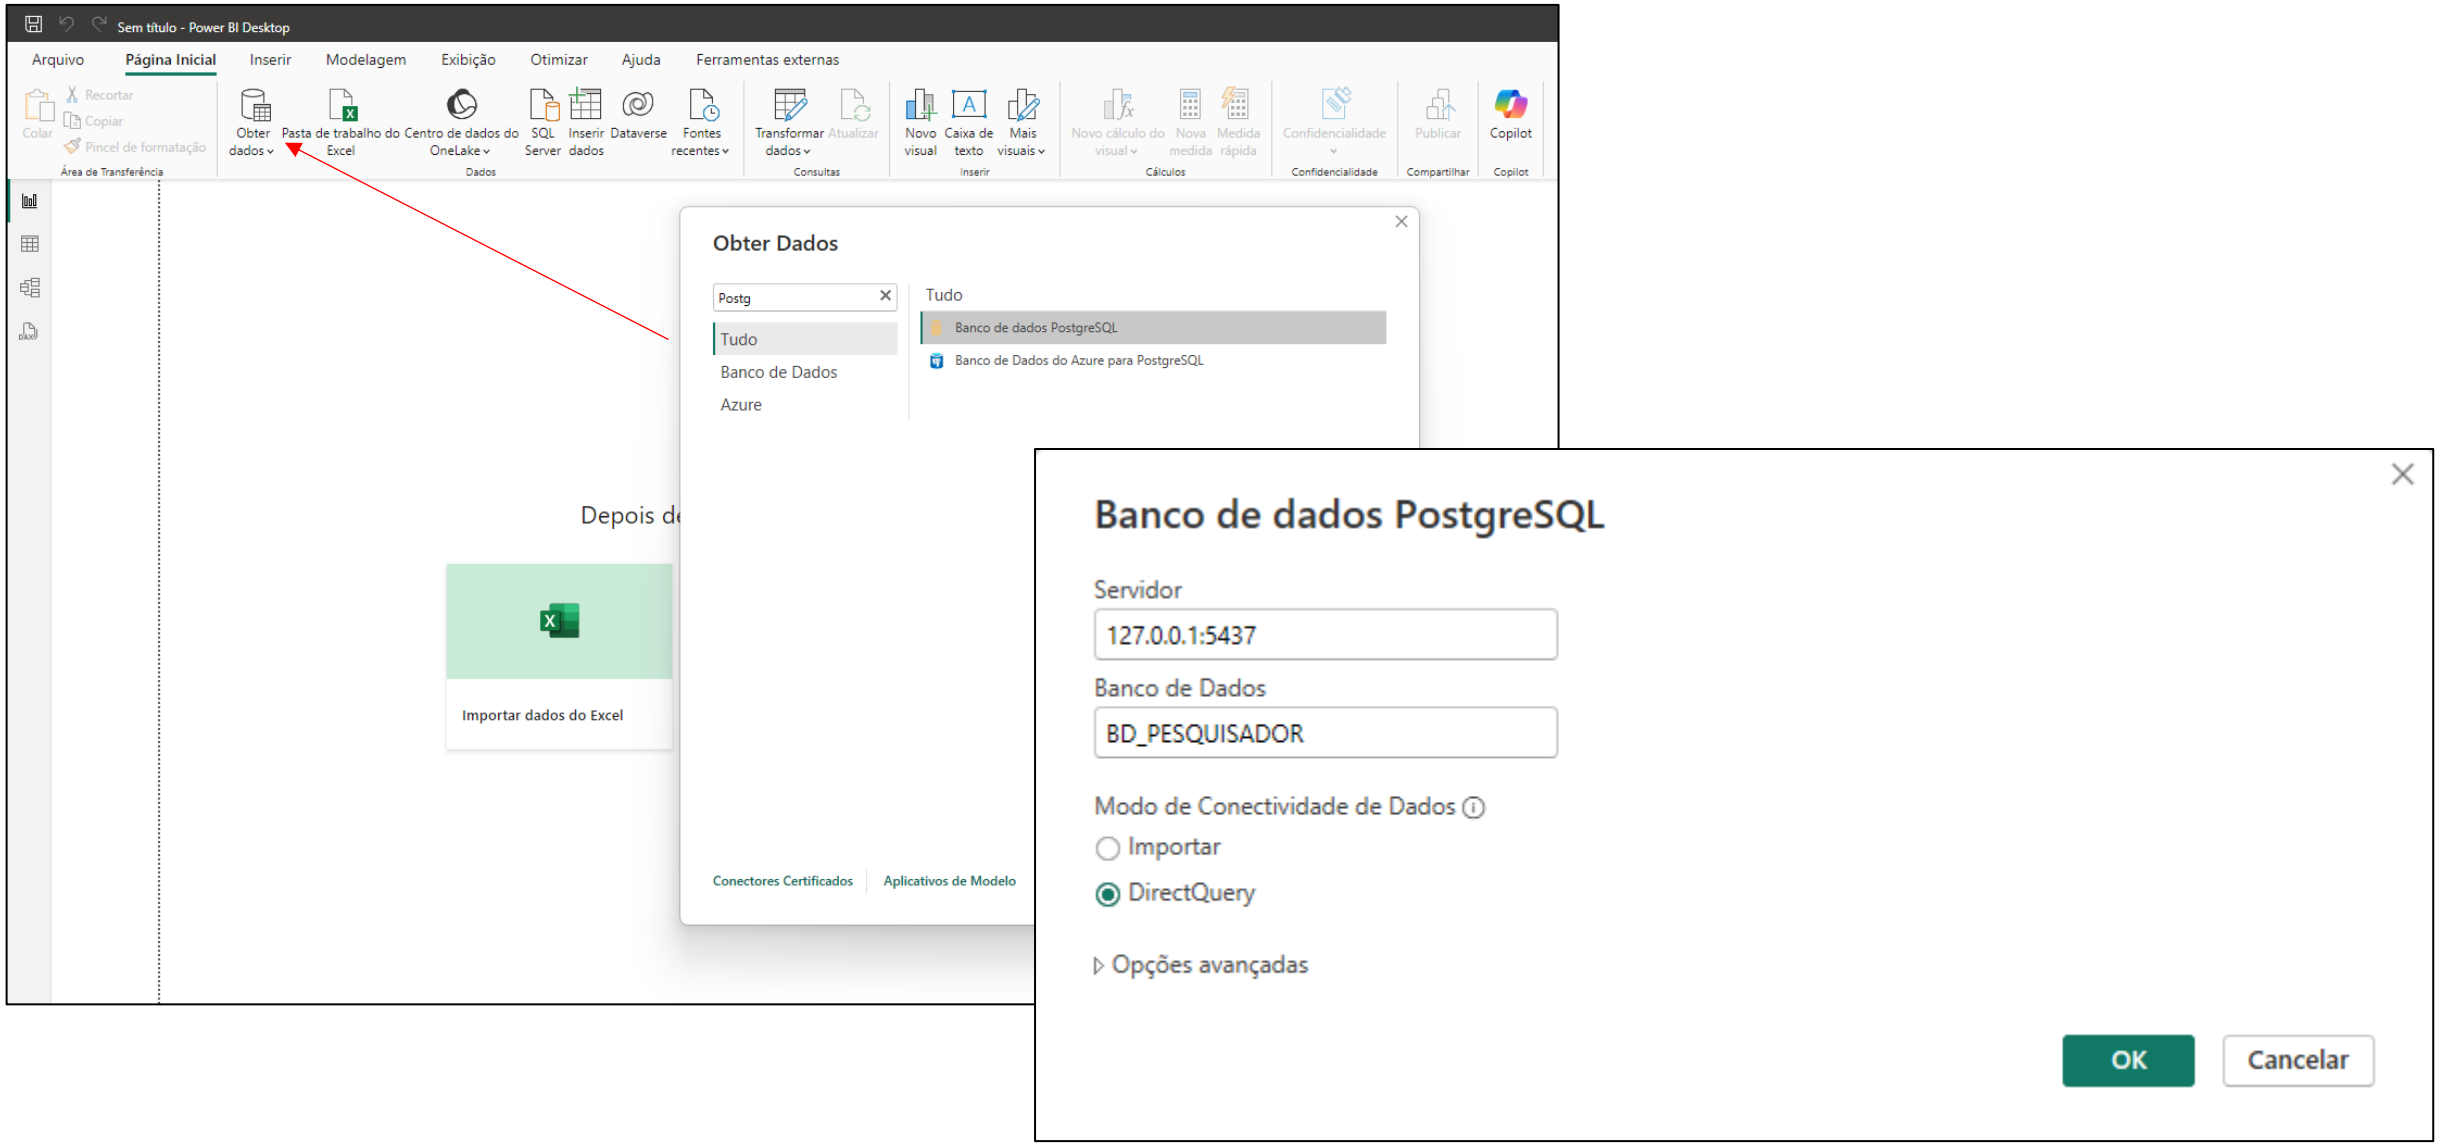

Conectan

Banco de Dados

Navegador

Opções de Exibição

- 127.0.0.1:5437: BD_PESQUISADOR [2]
  - public.pesquisadores
  - public.producoes

public.producoes

producoes_id	pesquisadores_id	issn
0eda9864-0cd4-4150-bc08-13df229bb2e2	51d8b750-fe8e-48cf-971e-e5f719b74ec6	00313
10505766-1d57-4093-8751-7ef20165b58b	51d8b750-fe8e-48cf-971e-e5f719b74ec6	18093
1b71fefc-94c5-447f-a849-79fed325828e	51d8b750-fe8e-48cf-971e-e5f719b74ec6	21757
1f9eeaab-cd98-4e65-ae26-aee1cfca9698	51d8b750-fe8e-48cf-971e-e5f719b74ec6	24112
22e4ace6-f979-4727-aef8-fa7231435c80	51d8b750-fe8e-48cf-971e-e5f719b74ec6	22372
2b5eaddc-1aa9-4369-9b42-a0c375bf307c	51d8b750-fe8e-48cf-971e-e5f719b74ec6	22309
2c0126c2-44ee-41d5-a732-c0665010a2c6	51d8b750-fe8e-48cf-971e-e5f719b74ec6	16604
2ce2a623-01c5-4a2c-a740-3094032cce8b	51d8b750-fe8e-48cf-971e-e5f719b74ec6	19887
4161870c-da26-4949-9ac3-7bd45988b40e	51d8b750-fe8e-48cf-971e-e5f719b74ec6	22360
50d5d4b2-09fa-4622-b881-c9e0533843bb	51d8b750-fe8e-48cf-971e-e5f719b74ec6	23170
528482d4-c535-4dd4-a6f2-50a20e1c0b71	51d8b750-fe8e-48cf-971e-e5f719b74ec6	25253
596a2c07-dd05-4e41-b731-181b9c82ae46	51d8b750-fe8e-48cf-971e-e5f719b74ec6	19831
5d3b322d-0681-4b69-8cc9-52df4941ea14	51d8b750-fe8e-48cf-971e-e5f719b74ec6	00489
6d628c01-a5f0-4127-a3c2-994d3c909ba6	51d8b750-fe8e-48cf-971e-e5f719b74ec6	20711
70683bed-ea5f-4170-8fcf-96047710b7e6	51d8b750-fe8e-48cf-971e-e5f719b74ec6	19832
788ac0ca-c851-4e4c-8a4d-e80c6f92c410	51d8b750-fe8e-48cf-971e-e5f719b74ec6	19818
7c09f80a-141b-4d49-9756-5c59ca4fa822	51d8b750-fe8e-48cf-971e-e5f719b74ec6	00105
7c5b74ae-dca2-453e-aef7-5fd80f8724b2	51d8b750-fe8e-48cf-971e-e5f719b74ec6	15411
88b00a6c-a141-4e24-87fb-41f742a184c3	51d8b750-fe8e-48cf-971e-e5f719b74ec6	19805
926bdc31-8fcd-4e02-ad16-1d6a5365c8e3	51d8b750-fe8e-48cf-971e-e5f719b74ec6	21788
9c5b54ca-a149-46fa-a939-a8df11fd6973	51d8b750-fe8e-48cf-971e-e5f719b74ec6	25956
a50c0206-c138-41fa-a4b9-b075d5f02e27	51d8b750-fe8e-48cf-971e-e5f719b74ec6	19812
b387509e-d395-4754-82bd-3159211b3f8e	51d8b750-fe8e-48cf-971e-e5f719b74ec6	21789

Selecionar Tabelas Relacionadas

Carregar | Transformar Dados | Cancelar

Verificando o relacionamento entre as tabelas (pesquisador_id)

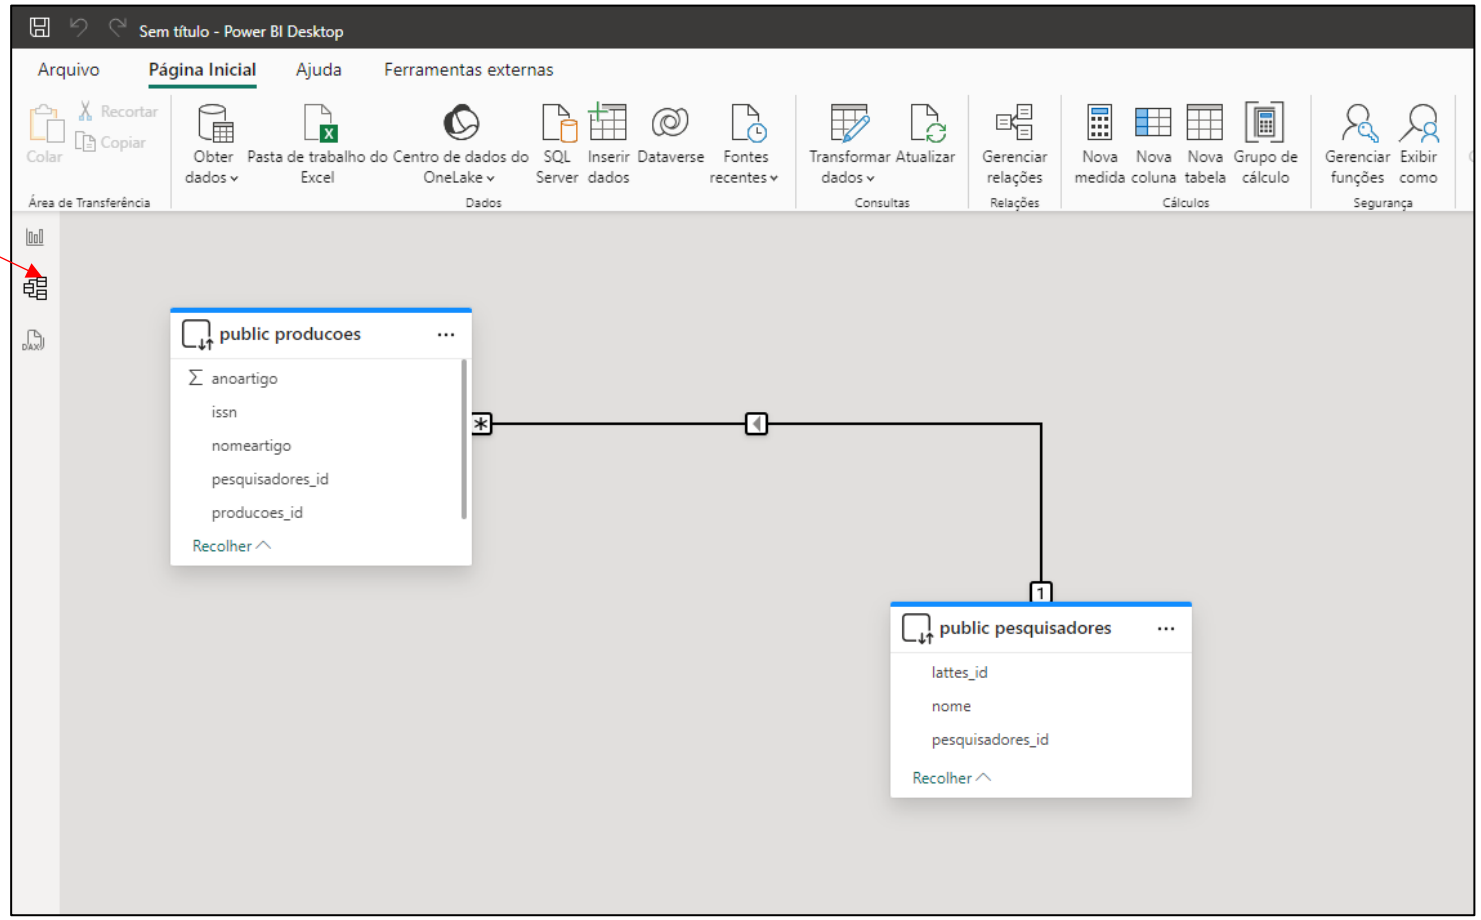

Adicionando gráfico de coluna clusterizado

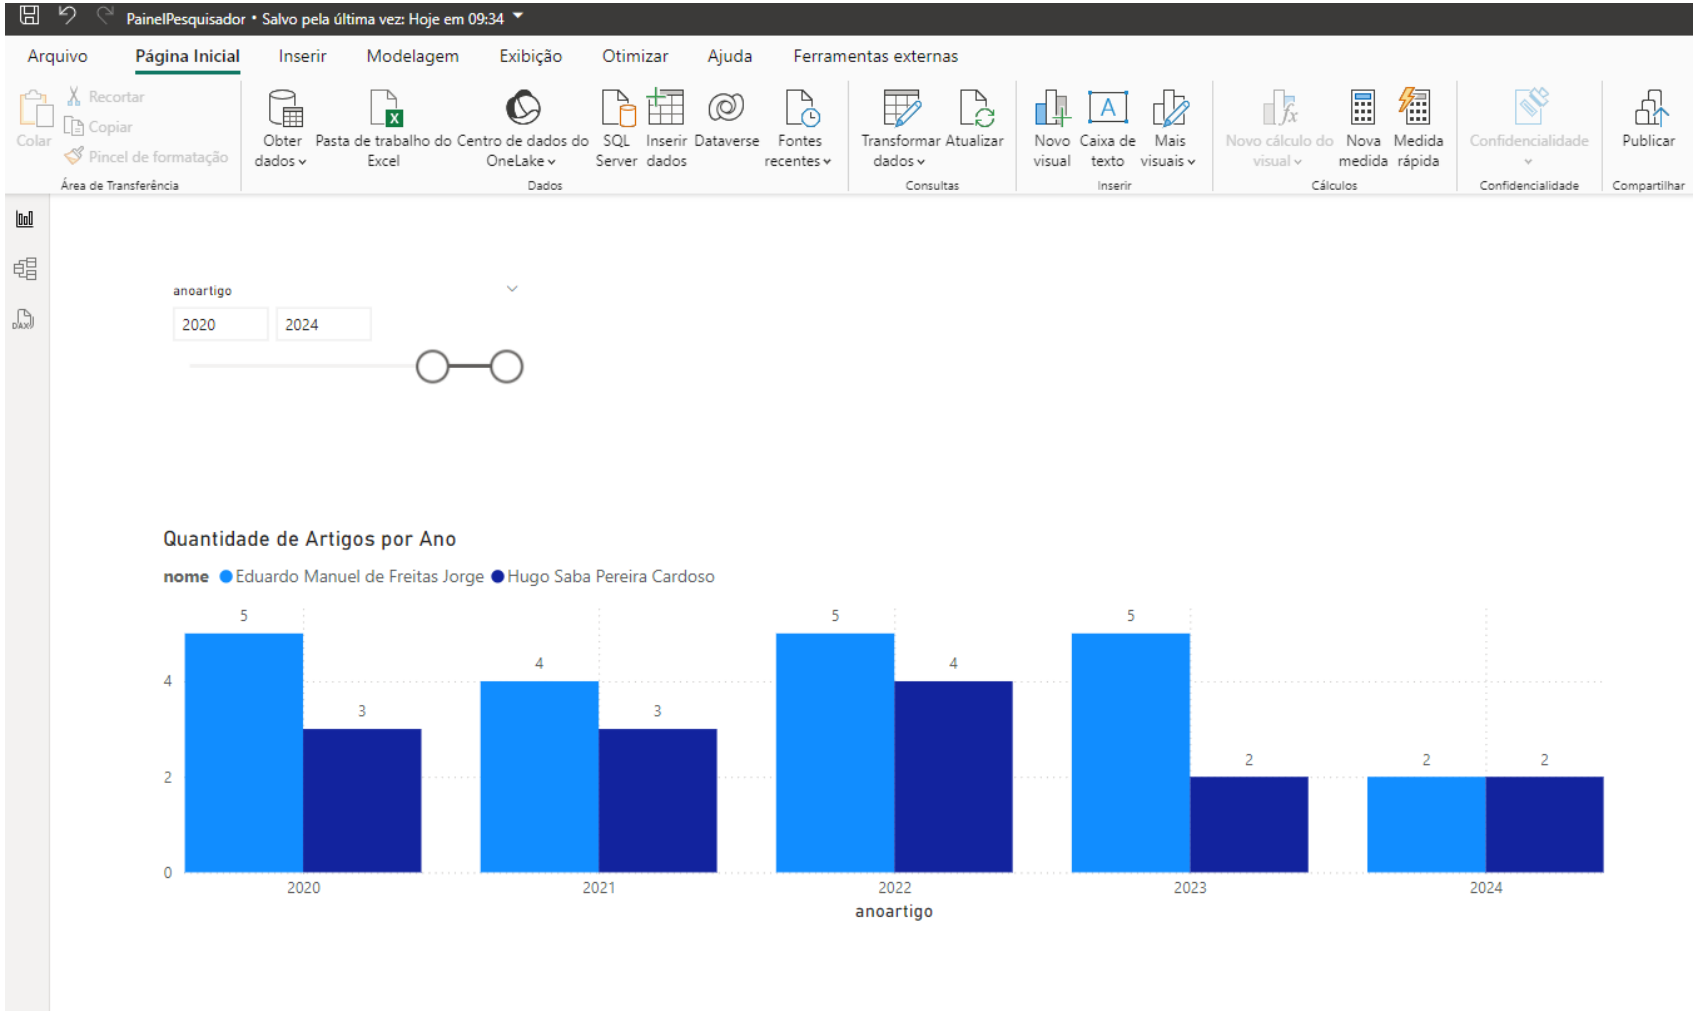

Obrigado

emjorge1974@gmail.com